

CCS 到底在优化什么？一个更简单的损失函数复现并超越了它

NeurIPS 2023：拆开 Contrast-Consistent Search 的损失函数，用「位移-中点」
权衡给出更清晰的解释

大模型越来越强，但它们仍然会一本正经地说错话。一个自然的想法是：既然模型内部似乎「知道」一句话是真是假，能不能直接从它的激活里把这个「真值方向」读出来？Contrast-Consistent Search (CCS) 就是沿着这个思路提出的探针方法：它不需要任何标签，只依赖一个简单约束——一句话和它的否定必须给出相反的判断——就能在激活空间里找到一个方向，把「真」和「假」区分开。

CCS 出人意料地好用，但一个基础问题一直没有答案：它的损失函数究竟在优化什么？如果连这一点都说不清，我们就很难信任它，也很难改进它。这篇来自 Independent、Oxford University 与 King's College London 的 NeurIPS 2023 工作（作者 Hugo Fry、Seamus Fallows、Ian Fan、Jamie Wright、Nandi Schoots）把 CCS 的损失函数拆开来看，先纠正了两个流传已久的误解，再给出一个更干净的解释，并据此设计出一个新的损失函数 Midpoint-Displacement (MD，位移-中点损失)。

结论很直接：把 MD 的一个超参数调成模仿 CCS，它找到的探针方向和真实 CCS 探针几乎重合；把同一个超参数调向准确率，它就能反过来超过 CCS。换句话说，CCS 之所以有效，靠的不是它那个特定形式的损失公式，而是对比样本对 (contrast pair) 里蕴含的位移信息。

论文链接：<https://arxiv.org/abs/2311.00488> 代码：<https://github.com/ash-ai-safety-hub/g3-nandi>

先纠正两个误解

在解释 CCS 之前，作者指出此前对它的两种常见描述都具有误导性。第一个误解是把 CCS 想成在激活上学一个「分隔超平面」，像普通线性分类器那样把真假两簇分到超平面两侧。实际上，CCS 的分类只取决于一句话与其否定之间的位移向量 (displacement) 在探针方向上的投影，这个量对激活的整体平移是不变的。如图 1 所示，真假样本在原始激活里并不能被一条超平面干净地分开，CCS 依然能工作——因为它读的是「样本对之间的差」，而不是「样本落在超平面哪一侧」。




图 1：T5-base 在 BoolQ 上的激活。横轴是激活在第一主成分上的投影，纵轴是激活在 CCS 方向 θ 上的投影，红点为「真」、蓝点为「假」，黑色横线是 CCS 输出 0.5 的分界。真假样本沿 CCS 方向（纵轴）被分开，但整体并不存在一条能干干净分开两类的分隔超平面。

第二个误解是把 CCS 的输出当作校准过的「真值概率」，并默认它必须把概率推向 0 和 1 两端才算成功。图 2 反驳了这一点：同一个 UnifiedQA T5-Large 模型，编码器（encoder）的 CCS 输出高度自信地堆在 0 和 1 两端，测试准确率却只有 0.523；而解码器（decoder）的输出大量聚集在 0.5 附近、看起来毫不自信，准确率反而高达 0.978。可见「概率是否两极分化」和「探针准不准」根本不是一回事。




图 2：UnifiedQA T5-Large 在 BoolQ 上的 CCS 探针输出直方图。(a) 编码器：输出极度自信地集中在 0 和 1，但测试准确率仅 0.523；(b) 解码器：输出大量聚集在 0.5 附近、看似不自信，测试准确率却高达 0.978。自信程度与准确率脱钩。

CCS 真正在优化的：位移与中点的权衡

作者提出用两个沿探针方向 θ 测量的简单统计量来刻画 CCS 的行为。第一个是位移方差 σ_d^2 ：一句话的正例激活 φ^+ 与其否定的激活 φ^- 之差 $u = \varphi^+ - \varphi^-$ ，衡量样本对被拉开的幅度。第二个是中点方差 σ_m^2 ：两者之和 $v = \varphi^+ + \varphi^-$ ，衡量样本对的中点离原点有多远。

关键观察是：CCS 的损失里用了一个两端都会饱和的 sigmoid，这迫使优化陷入一种权衡——它想把每一对样本沿探针方向尽量拉开（增大 σ_d^2 ），同时又要把它们的中点压到接近原点（减小 σ_m^2 ）。于是作者把这个隐含的权衡直接写成一个显式的损失函数 Midpoint-Displacement： $L_{MD} = (\lambda - 1) \cdot \sigma_d^2 + \lambda \cdot \sigma_m^2$ ，其中 $\lambda \in [0, 1]$ 、探针方向为单位向量。一个超参数 λ 就控制了「拉开位移」与「压低中点」之间的相对权重。

由此得到两个变体：MD-CCS 把 λ 调到模仿 CCS 的取值，MD-Acc 则把 λ 调到最有利于准确率。两者唯一的区别就是这个 λ ，因此它们天然构成一组对照实验。作为对照，作者还比较了 Mean Absolute（MA）、Square Mean Root（SMR）、PCA、随机方向以及有监督探针等基线，覆盖四个模型和五个数据集。

实验结果：MD 是 CCS 的忠实代理

核心证据来自方向的相似度。MD-CCS 学到的权重方向与真实 CCS 探针的平均余弦相似度约为 0.63。0.63 听上去似乎不算高，但要注意两点：其一，CCS 探针彼此之间的自相似度也只有 0.78；其二，在 1024 维空间里，两个随机单位向量达到 0.63 余弦相似度的概率约为 10^{-237} 。相比之下，其他同样准确的损失函数（MA、SMR、PCA）与 CCS 的余弦相似度只有 0.14 到 0.17。也就是说，这种「像 CCS」是 MD 独有的，而不是任何高准确率探针都会附带的副产品。

准确率方面，MD-Acc 的平均测试准确率为 0.7557，高于 CCS 的 0.7105，在四个模型中的三个上都更优，平均领先约 4%。有监督探针的平均准确率为 0.8674，代表了这些激活能达到的实际上限。

表 1：不同损失函数的测试准确率（五个数据集平均）。MD-Acc 在四个模型中的三个上超过 CCS，平均领先约 4%。

模型	CCS	MD-CCS	MD-Acc	有监督
UQA (E)	0.6863	0.6902	0.7414	0.8839
UQA (D)	0.8305	0.8200	0.8180	0.9140
DeBERTa	0.7740	0.7855	0.8735	0.9135
GPT-Neo	0.5510	0.5755	0.5898	0.7580
平均	0.7105	0.7178	0.7557	0.8674

表 2：各损失函数所得方向与 20 个 CCS 探针方向的平均余弦相似度。只有 MD-CCS 接近 CCS 自相似度（0.78），其余高准确率损失只有 0.14–0.17。

模型	CCS	MD-CCS	MD-Acc	MA	SMR	PCA
UQA (E)	0.8359	0.7034	0.2995	0.1448	0.1991	0.2406
UQA (D)	0.8787	0.7269	0.5303	0.1687	0.2432	0.1792
DeBERTa	0.8643	0.6209	0.2786	0.2309	0.2024	0.0741
GPT-Neo	0.5277	0.4830	0.4164	0.0226	0.0485	0.1901

平均	0.7767	0.6336	0.3812	0.1418	0.1733	0.1710
----	--------	--------	--------	--------	--------	--------

λ 的消融：权衡决定了 CCS 的目标

由于 MD-CCS 和 MD-Acc 只在 λ 上不同，它们给出了一个干净的消融。调成模仿 CCS 时，方向的平均余弦相似度约为 0.63；调向准确率时，这一相似度就掉到约 0.38。这说明 σ_d^2 与 σ_m^2 之间的权衡，正是决定「CCS 在优化什么」的那个旋钮。而把 MD-CCS 的 λ 换成偏准确率的取值，平均测试准确率会从 0.7178 升到 0.7557。此外，模仿 CCS 所需的 λ 在不同数据集和模型间几乎不变，说明这个代理优化目标相当稳健。

小结与局限

这篇工作把一个「黑箱式好用」的探针方法讲清楚了：CCS 的成功来自对比样本对数据里的位移信息——也就是一句话与其否定之间的差异——而不是它那个特定形状的损失公式。一个简单的 Midpoint-Displacement 损失既能忠实复现 CCS，又能在重新调参后超过它。对做可解释性和真值探测的研究者来说，这意味着损失公式本身在高准确率探针之间是大体可以互换的，真正的杠杆是「把样本对拉开多远」与「让中点长多大」之间的权衡。

需要注意的是，论文对 CCS 优化目标的解释是启发式的，而非严格证明；实验覆盖四个模型和五个数据集，MD-Acc 也并非在每个模型上都胜出（UQA 解码器上 CCS 略高）。即便如此，「位移-中点权衡」为理解与改进这类无监督真值探针提供了一个清晰而可操作的视角。