

ICLR 2023 | 只用 2D 照片，学出一个能任意拆 开控制的 3D 可变形生成器

UCL 与 Alan Turing Institute 提出 StyleMorph：无需任何 3D 扫描、姿态标注或手工模板，就让 StyleGAN 拥有形状、姿态与外观的独立旋钮。

如今的 3D-aware GAN 能生成质量极高、视角一致的人像，但它们生成的图像几乎是「不可编辑」的。因为这类模型把几何和外观揉进了同一套隐编码里，你想转一下人脸的角度，往往连身份也会跟着变；想换个背景，前景人物也会被扰动。画面很漂亮，可是控制旋钮全都黏在了一起。

图形学界其实早就解决了「控制」这件事，靠的是 3D 可变形模型（3D Morphable Model，简称 3DMM），它是影视特效与 AR 虚拟形象背后的主力工具，能给美术师提供姿态、表情、外观各自独立的旋钮。问题出在怎么造出这样一个模型：传统 3DMM 需要 3D 扫描设备，还要在大量样本之间做繁琐的手工对齐，这正是它长期以来基本只覆盖人脸这一个类别的原因。

来自 University College London 与 Alan Turing Institute 的 StyleMorph 提出了一个问题：能不能把 3DMM 式的控制能力搬进现代生成器，而且只从无结构的 2D 照片里学出来？他们给出的答案，是一个能把图像的四个因素干净拆开的模型，即物体的 3D 形状、相机姿态、前景外观和背景，每一个都可以独立编辑；与此同时，它的图像质量还能与那些完全不提供这种控制的最强 3D-aware GAN 相媲美。




图 1 StyleMorph 的解耦控制。从最左侧的一个合成样本出发，每一列只改变一个因素：姿态、形状、前景外观或背景，最右列则同时改变全部四个因素。几何条件信号（最上和最下行）在前景、背景两列中保持不变，因此这两处变化完全来自各自的外观编码。

论文地址：<https://openreview.net/forum?id=Ojpb1y8jflw> · 项目主页：<https://stylemorph.github.io/stylemorph/>

为什么 3D-aware GAN 会「纠缠」，而可变形模型能带来什么

从 GIRAFFE 到 EG3D，近年这批 3D-aware GAN 的真实感来自一个共同做法：把 3D 先验直接内置进生成器，用神经辐射场或隐式占据网络以体渲染的方式绘制场景，于是不同视角天然保持一致。代价就是「纠缠」。一个 style 向量或一份共享的特征体，会同时驱动形状和纹理，你根本没有一个入口能只改一个因素而不动其它。一些混合方法实现了部分解耦，但都没有学出一个可复用、可跨类别、可 morph 的形状模型。

而可变形模型恰恰就是这块缺失的拼图：一个标准模板，加上一套学到的形变空间，把模板 warp 成每一个具体实例。如果能在没有 3D 监督的情况下，为任意类别得到这样一个模型，就能同时拿到两个世界的好处，既有 GAN 的照片级真实感，又有 3DMM 那种「精准可编辑」。StyleMorph 的贡献，正是让这个可变形模型本身成为网络通过反向传播、只从 2D 图像里学出来的东西。

核心思路：把所有几何信息压进一个纯几何瓶颈

StyleMorph 由两半组成，它们在一个刻意设计得很窄的接口处相接。第一半是负责几何的「可变形渲染器」（Morphable Renderer）。它把一个不含形变的物体学成一个常量隐式场，存放在一个标准的模板空间里。一个由形状编码驱动的 SIREN 形变场，会给每条相机光线加上一个预测出的偏移量，把它从世界空间 warp 到模板空间，即 $\hat{r}(t) = r(t) + g_s(r(t))$ 。沿光线积分模板坐标，就得到一张 2D 图，作者称之为 TOCS 图（Template Object Coordinates，模板物体坐标）。

TOCS 是全文的概念核心。它是 Normalized Object Coordinates (NOCS) 的一个可变形版本：每个表面点在模板空间里都有一个稳定的身份，因此这张图是对 3D 形状的一种「形变等变」描述子。关键在于，一张 TOCS 图是纯几何的。它编码了形状形变、相机姿态和透视投影三者叠加后的效果，却完全不含任何纹理或颜色信息。这就是所谓的瓶颈：把所有几何因素都逼着经过这一张 2D 图，且只让几何经过它，StyleMorph 就在结构上保证了外观必须从别处进入流程。




图 2 StyleMorph 的两个部分。左侧：模板形状、形状编码 z_s 、相机姿态 (ϕ, θ) 与透视投影共同生成一张 2D TOCS 图，把所有几何变化收束到这一个瓶颈里。右侧：TOCS 图连同相互独立的前景 (z_{fg}) 与背景 (z_{bg}) 外观编码送入延迟神经渲染器（Deferred Neural Renderer），在判别器的监督下生成高分辨率图像。

第二半才是外观所在之处。一个基于 StyleGAN2 的延迟神经渲染器（Deferred Neural Renderer，DNR）接收几何 TOCS 图，再加上两个相互独立的外观编码，一个管前景物体、一个管背景场景，合成出高分辨率图像。前景和背景分别生成，最后通过一张预测出的 alpha 掩码「后融合」在一起，即 $I = A \odot I_{fg} + (1 - A) \odot I_{bg}$ 。由于形状和姿态只能经由 TOCS 图抵达渲染器，而两个外观编码又从不触碰几何，这四个因素在设计上就天然分开了，而不是靠某个正则化惩罚项硬凑出来的。

训练分两个阶段。第一阶段，可变形体渲染器被当作一个低分辨率（ 64^2 ）的 RGBA 图像生成器来训练，从而学到一个真实的形状模型，其间只用到来自现成 Labels4free 掩码的弱轮廓监督。第二阶段，冻结这个渲染器并剪掉它的 RGB 分支，此时它只负责输出 64^2 的 TOCS 图；DNR 则在全分辨率下训练，学着把这些 TOCS 图连同外观编码变成照片级的输出。这样分工，让昂贵的体渲染模型保持小而省，而由 2D 渲染器来扛分辨率。

解耦真的成立吗

第一项检验，是看学到的形状空间是否足够丰富，以及渲染器是否真的尊重它。固定视角和外观编码、只改变形状编码，理应改变脸型与发型的几何，同时让渲染出的纹理与新形状对齐。




图 5 固定视角下的形状控制。四个不同的形状编码产生四张不同的 TOCS 图（对应不同发型和脸型），渲染出的 RGB 与之紧密对齐。画在模板坐标上的等值线（equiconours）显示出跨形状仍然成立的稠密表面对应关系。

等值线把这一点说得很清楚：同一个模板坐标，在差异很大的不同人脸上，都会落在同一个语义位置上，而这正是一个真正的可变形模型所应保证的。下一项检验，是完整的四因素编辑，以及它能否推广到人脸之外、那些经典 3DMM 从未覆盖过的类别。



图 6 在人脸、猫、野生动物上逐一独立编辑单个因素。从源样本（黄框）出发，StyleMorph 在保持其余因素不变的前提下，分别改变形状（绿框）、前景外观（蓝框）和背景（红框）。

改变前景编码，会在不移动几何的情况下给对象换一套外观；改变背景编码，会在不触碰对象的情况下重绘场景；改变形状编码，则改变底层的 3D 形态。在猫和野生动物上也是同样的表现，这说明 StyleMorph 实际上为每个类别都学到了一个无监督的可变形模型，而不只是针对人脸。

拿到解耦，却几乎没有牺牲画质

最亮眼的实验结论是：这一切控制能力，在 FID 上几乎是「免费」的。在 256² 分辨率的 FFHQ 人脸上，StyleMorph 的 FID 达到 7.91，稳稳处在最强一批 3D-aware GAN 之列。而最值得一比对手是 Disentangled3D，它是此前唯一同样用可变形模板来表示形状的方法：StyleMorph 的 7.91 大幅领先于它的 28.18，而且 StyleMorph 还额外做到了前景与背景的分离，这一点是它所不具备的。

表 1 FFHQ 与 AFHQ 上 256² 分辨率的 FID（越低越好）。StyleMorph 在增加了完整四因素解耦和一个可学习的可变形模板的同时，仍与最强的混合方法保持竞争力。横线表示论文未报告该项。EG3D 使用弱 3D 监督（一个预训练的姿势估计器）且不提供任何因素解耦；Disentangled3D 是另一个唯一带可变形模板的方法。

方法	FFHQ	AFHQ Cats	AFHQ Wild	AFHQ Dogs
StyleMorph (本文)	7.91	4.29	3.49	13.95
Disentangled3D	28.18	-	-	-
GiraffeHD	11.93	12.36	-	-
EG3D (弱 3D 监督)	4.80	3.88	-	-

在动物上故事同样成立：Cats 4.29、Wild 3.49、Dogs 13.95。EG3D 在人脸上的原始 FID 更低，但它依赖一个预训练的姿势估计器来提供弱 3D 监督，也完全不具备 StyleMorph 的因素控制，所以两者并不是在做同一件事。这张表想说明的，不是要在每一列都拿第一，而是：加入一个可学习的模板和四向可编辑能力，并不需要以画质为代价。

编辑的是真实照片，而不只是采样结果

解耦控制最有用的场景，是能把它对准一张真实图像。通过反演（inversion）整条流程，StyleMorph 能恢复出一张真实输入照片的隐编码和底层 3D 结构，再以每个旋钮各自独立的方式，为它重新渲染出新的姿态、前景、背景或形状。




图 8 通过反演编辑真实照片。StyleMorph 把目标图像（最左）反演回它的隐编码并恢复出底层 3D 结构，随后以独立可控的方式改变姿态、前景、背景和形状，重新渲染。

消融实验证实了什么

在统一的 96 小时训练预算下，消融实验逐一隔离出每个设计选择的作用。在其它部分完全不变的前提下，把 TOCS 换成普通的 NOCS，会让 FID 从 8.31 变差到 8.90，条件信号也明显变糊，这说明真正让画质和解耦都变锐利的，是「模板空间坐标」，而不仅仅是物体坐标。去掉可变形模块、改用一个直接的占据网络，FID 相近，但形状与外观一致性会被严重破坏。而从后融合（late fusion）改为前融合（early fusion），FID 会略微下降，却损害了 alpha 一致性（88.65% 降到 85.87%），让前景和背景相互渗透，这也正是 StyleMorph 坚持把两者分开、直到最终合成才融合的原因。

还有一个值得如实点明的取舍。直接优化一个可微的视角一致性损失，确实能把该指标大幅改善（从 15.84 降到 8.12），但代价是画质，会把 FID 推高到 12.31。StyleMorph 的默认配置选择了照片级真实感，而不是把最后一点视角一致性也榨出来，这是一个合理的取舍，而论文对此是坦诚说明的，并没有回避。

小结

StyleMorph 在一个当前顶尖的图像生成器内部，交付了 3DMM 式的控制能力，而且完全从普通的 2D 照片里学到，不需要任何 3D 扫描、姿态标注或预定义模板。通过对一个学到的标准模板做形变，并把它渲染成一张纯几何的 TOCS 图，它给 StyleGAN 渲染器递上了一个干净的几何信号，于是形状、姿态、前景外观和背景都能各自独立编辑，而不牺牲照片级真实感。

更宏观地看，StyleMorph 实际上为一般物体类别构建了一个无监督的 3D 可变形模型。经典的可变形模型需要扫描设备，也几乎只存在于人脸这一个类别；而在这里，模板及其形变空间是通过反向传播、从一批无标注图像中自行学到的。这把影视特效美术师长期依赖的那种精细可控性，从人脸拓展到了猫、狗和野生动物，也让「可编辑、可跨类别的 3D-aware 合成」变得只需要一批照片、而不再需要一间采集棚。

它的边界也是这条研究线上常见的那些：结果都展示在单物体、大致居中的类别上，消融实验也如实呈现了画质与视角一致性之间可测量的取舍，并非两头通吃的免费午餐。但作为一个例证，它说明了解耦与照片级真实感可以共存，也说明可变形模型可以被「学出来」而不必「手工搭出来」，这让 StyleMorph 成为迈向可控生成建模的一个干净而实用的步骤。