

ICML 2023 | 高精地图不必先画格子、再费力连线

清华、上海期智研究院、MIT 与理想汽车提出 VectorMapNet：第一个端到端矢量化高精地图学习框架

自动驾驶离不开高精（HD）语义地图：它标出车道分隔线、道路边界和人行横道，是规划和预测模块直接读取的先验。今天这类地图主要靠人工离线标注，成本高、也很难随城市扩张而扩展。近两年出现的学习类方法换了一条路，让模型在鸟瞰图（BEV, Bird's-Eye-View）上给每个像素打类别标签，直接从车载传感器在线预测地图。

问题是，规划器想要的并不是一张像素图。一格一格的栅格地图没有「实例」概念，分不清哪几段属于同一条车道；难以保证几何上的空间一致性；更关键的是，它必须再经过一套人工设计的后处理，才能被转换成下游模块真正消费的矢量折线。这一步「先栅格、再矢量化」的绕行，正是精度和可扩展性的瓶颈。

这篇发表于 ICML 2023 的工作提出 VectorMapNet，把地图构建重新表述为「检测 + 生成」问题：模型直接从摄像头和激光雷达数据出发，输出一组稀疏的矢量折线（polyline），完全跳过栅格化和后处理。它是第一个端到端的矢量化高精地图学习框架。




图 1 VectorMapNet 总览。左侧是车载摄像头与激光雷达输入，中间统一编码为 BEV 特征，随后用「元素查询（element query）」检测每个地图元素的位置，再由它们生成一组稀疏折线，直接得到右侧的矢量化地图。折线是有方向的，因此还能推断出可行驶区域与可行走区域。

论文： <https://arxiv.org/abs/2206.08920> | 代码：https://github.com/Mrmoore98/VectorMapNet_code | 项目主页：<https://tsinghua-mars-lab.github.io/vectormapnet/>

为什么要跳过「栅格」这一步

先看在线地图学习为什么有吸引力。相比离线人工地图，从车辆自身的摄像头和激光雷达实时构图，既省去了标注负担，也绕开了离线高精地图在使用时几十厘米级的定位误差。但作者的观点更进一步：一个真正端到端的系统，应该直接输出下游任务使用的表示，而不是先产出中间产物再转换。

此前的最好方法 HDMapNet 仍然预测栅格化的语义图、实例图和方向图，再用一套手工设计的算法把像素拼接成矢量。这个额外步骤既限制了精度，也限制了可扩展性。VectorMapNet 的动机就是把这段绕行整段拿掉：用折线作为统一的地图基元。一条折线可以表示点、线、曲线和多边形，覆盖边界、分隔线、人行横道等形态各异的元素；它顶点的先后顺序天然编码了方向信息，这正是下游规划所需要的。

三段式结构：从传感器到折线

VectorMapNet 由三个可以一起训练的阶段串联而成。理解它的最好方式，是顺着下面这张架构图从左看到右。




图 2 VectorMapNet 的网络结构。(a) BEV 特征提取器：多相机图像经 CNN 和逆透视变换 (IPM) 投影到鸟瞰空间，激光雷达点经 PointPillars 体素化，两者拼接融合；(b) 地图元素检测器：DETR 式的 Transformer 解码器用可学习的元素查询定位并分类每个地图元素，输出一组关键点；(c) 折线生成器：一个自回归 Transformer 逐个坐标地解码出每个元素的有序折线顶点，直到输出终止符 EOS。

第一阶段是 BEV 特征提取器，负责把不同模态统一到同一个俯视坐标系。摄像头分支用 ResNet 提特征，再经逆透视变换投影到鸟瞰平面；激光雷达分支用 PointPillars 处理点云；两路特征直接拼接融合。第二阶段是一个 DETR 风格的地图元素检测器，用一组可学习的元素查询配合可变形注意力，定位并分类每个大小、形状各异的地图元素，并用少量关键点来表示它的粗略位置。

第三阶段是折线生成器，这是把「检测结果」变成「干净矢量」的关键。它是一个自回归 Transformer，接过每个被检测到的元素，一个坐标接一个坐标地生成折线顶点。顶点坐标先被量

化成离散的 token，再用一个类别分布来建模（沿用了 PolyGen 的做法），因此生成折线的过程更像是在「写序列」而不是回归数值。整个模型用一个二部图匹配的检测损失加上一个负对数似然的生成损失来端到端训练。

两个不起眼但关键的设计选择

论文用消融实验说明了两个容易被忽略、却明显影响结果的设计。第一个是「用什么关键点来表示一个地图元素」。检测器不需要一次性吐出完整折线，只需给出几个关键点勾勒出元素的粗略位置和范围，剩下的交给生成器。作者比较了三种方案，见下图。




图 3 三种关键点表示：Bounding Box ($k=2$ ，用左下、右上两个角点)、SME ($k=3$ ，起点—中点—终点) 和 Extreme Points ($k=4$ ，上下左右四个极值点)。 k 表示每种表示所用的关键点数量；虚线箭头表示关键点的排列顺序。实验显示，最简单的两点式包围框反而效果最好。

结果有些反直觉：最简单的两点式包围框（Bounding Box, $k=2$ ）表现最好，在 Fréchet 距离下比另外两种高出 2.0 mAP，在 Chamfer 距离下高出 7.3 mAP，因此被设为默认方案。第二个设计是训练策略。自回归生成如果只用教师强制（teacher forcing）训练，推理时会因为「暴露偏差」而误差累积。作者改为两阶段训练：先用教师强制训练，再在模型自己预测的关键点上做微调。这一步为纯摄像头方案带来 +6.9 mAP、为融合方案带来 +8.5 mAP 的提升。

实验结果：全面超过栅格化基线

实验在 nuScenes 和 Argoverse2 两个公开数据集上进行，评测三类地图元素：人行横道、车道分隔线和道路边界。沿用 HDMapNet 的协议，用预测折线与真值折线的匹配来计算平均精度（AP）；除了常用的 Chamfer 距离，论文还引入了考虑顶点顺序的 Fréchet 距离 AP，阈值取 0.5、1.0 和 1.5 米。

在 nuScenes 上，VectorMapNet 全面超过 HDMapNet：纯摄像头 +17.9 mAP、纯激光雷达 +9.9 mAP、传感器融合 +14.2 mAP。融合本身相对纯摄像头再加 +4.3 mAP、相对纯激光雷达加 +11.2 mAP。配合两阶段微调，融合模型达到 53.7 mAP，而 HDMapNet 在相同融合设置下是 31.0 mAP。在 Argoverse2 上领先幅度为 +14.6 mAP，且由于该数据集带有高度标注，模型还能做三维评测。

表 1 nuScenes 上的 Chamfer 距离 AP（%）。VectorMapNet 在人行横道、分隔线、边界三类元素上全面领先，融合加微调达到 53.7 mAP。

方法	人行横道	分隔线	边界	mAP
HDMapNet (Camera)	14.4	21.7	33.0	23.0
HDMapNet (LiDAR)	10.4	24.1	37.9	24.1

HMapNet (Fusion)	16.3	29.6	46.7	31.0
VectorMapNet (Camera)	36.1	47.3	39.3	40.9
VectorMapNet (LiDAR)	25.7	37.6	38.6	34.0
VectorMapNet (Fusion)	37.6	50.5	47.5	45.2
VectorMapNet (Fusion) + fine-tune	48.2	60.1	53.0	53.7

数字之外，定性对比更能看出矢量表示的好处。下图用同样的摄像头输入，把真值、HMapNet 和 VectorMapNet 放在一起。




图 4 nuScenes 上的定性对比（均以摄像头图像为输入）。红、蓝椭圆标出的区域显示，VectorMapNet 能保留清晰的直角转角，折线表示也避免了 HMapNet 那种含糊的自相交、断裂结果；可行驶区域可由互不相连的边界推断得到。

可以看到，HMapNet 的栅格后处理结果容易出现断裂、自相交和边角模糊；VectorMapNet 输出的折线更干净、拐角更利落，几何结构也更接近真值。论文还观察到一个有意思的现象：模型偶尔能检测出真值标注里漏掉的地图元素，例如未被标注的人行横道。

对下游任务有用，也有清晰的边界

地图预测得准，最终要看它是否真的帮到下游。作者把 VectorMapNet 预测出的地图喂给一个运动预测（motion forecasting）基线：仅用历史轨迹时 minADE 为 0.909，换成预测地图后降到 0.826，已经很接近使用人工标注真值地图的 0.779，在 MR（miss rate）指标上更是仅差约 0.2%。这说明端到端预测出的矢量地图，质量已经足以支撑真实的下游任务。

作者也没有回避局限。模型目前不建模时序信息，逐帧独立预测；当摄像头被临近车辆遮挡、或处于恶劣天气时，纯摄像头方案会漏检或误检，需要靠激光雷达的深度线索来补偿。折线

作为基元的灵活性则是额外的收获：不改动任何结构，同一个模型就能扩展到中心线（centerline）预测。

小结

VectorMapNet 传达的核心信息是：高精地图的构建并不需要「先栅格、再连线」的绕行。把它表述为「检测 + 自回归折线生成」，一个端到端网络就能直接从车载摄像头和激光雷达输出干净、带方向的矢量地图，并以两位数的 mAP 优势超过最好的栅格化流水线。对做在线建图、BEV 感知和自动驾驶系统的团队来说，这提供了一条更简洁、也更贴近下游需求的技术路线。