

ICLR 2022 | 匹配不到，就“脑补”：让网络学会想象看不见的对应点

École des Ponts 与波尔多大学提出 NeurHal，把遮挡与视野之外的对应点从“噪声”变成可预测的“信号”

在两张有重叠的图片之间找到对应点，是从视觉定位到三维重建的基础一步。但无论是传统方法还是深度局部特征匹配，都有一个隐含前提：一个关键点只有在两张图里都看得见，才谈得上“匹配”。一旦它被前景挡住，或者干脆落在第二张图的画面之外，这些方法就无话可说，只能把这些区域当作噪声丢掉。

问题在于，现代视觉定位恰恰依赖这些关键点匹配，而当两张图片的重叠很少时，绝大多数点都处于被遮挡或视野之外的状态，匹配随之崩溃。人类却不会就此放弃：面对一个看不见的点，我们会根据场景的几何结构去推断它“应该”落在哪里。经典视觉里当然也有几何推理，但通常只用在事后，用对极几何这类模型去剔除错误匹配，从没有人真正去主动预测那些不可见位置上的对应点。

这篇发表于 ICLR 2022 的论文，正是冲着这个空白去的。作者提出“视觉对应幻想”（visual correspondence hallucination）这一新任务，以及一个名为 NeurHal 的网络：给定一对有重叠的源图与目标图，以及源图中的一批关键点，NeurHal 为每个关键点输出它的对应点在目标图上位置的概率分布——无论这个位置是可见、被遮挡，还是落在视野之外。

○ = Identified + = Inpainted × = Outpainted




图1 视觉对应幻想的三种情形。上排是源图及其上标出的少量关键点，下排是目标图上 NeurHal 预测的概率分布。红圈表示可以直接识别的可见对应点，红十字为需要“内补”的被遮挡点，红叉为需要“外补”、落在目标图边界之外的点。三组示例都来自训练时未见过的场景。

论文：<https://arxiv.org/abs/2106.09711>（arXiv:2106.09711，ICLR 2022）。作者：Hugo Germain、Vincent Lepetit、Guillaume Bourmaud。

当匹配“看不见”时

要理解这项工作，先把对应点的定位拆成三个子任务。作者把它们统一命名为：识别（identifying，对应点在目标图里可见）、内补（inpainting，对应点被前景遮挡）、外补（outpainting，对应点落在目标图视野之外）。传统匹配方法天生只能处理第一种，因为它们只在目标图的像素范围内寻找最相似的描述子：被遮挡的点没有可匹配的外观，视野之外的点根本不在搜索范围里。

NeurHal 的目标，是用同一个网络把这三种情形一并解决。它在室内场景 ScanNet 上训练、并在 NYU Depth 上测试；在室外场景 MegaDepth 上训练、在 ETH-3D 上测试。关键在于，所有评测都使用训练时从未见过的场景，因此结果衡量的是真正的泛化能力，而不是对训练场景的记忆。

NeurHal 是怎么“脑补”的

NeurHal 的结构可以顺着图 2 从左到右看：从两张输入图，到一组每个关键点各自的对应图。




图 2 NeurHal 总览。左侧为源图与目标图经孪生骨干得到的描述子图（目标图用可学习向量 λ 向外扩充），中间的交叉注意力骨干让二者互相“交流”，右侧每个关键点特征经 1×1 卷积与二维 softmax，得到一张对应图。

具体来说，一个孪生（siamese）卷积骨干网络先把源图和目标图各自编码成稠密的描述子图。为了让“视野之外”也有对应的描述子，目标图的描述子图会用一个可学习的向量 λ 向外扩充（padding），相当于为画面边界之外的位置预置了初始描述子。接着，一个带位置编码的交叉注意力（cross-attention）骨干让源图与目标图的描述子互相“交流”——这正是网络能为被遮挡和

视野之外的点给出集中概率分布的关键。最后，每个关键点的特征以 1×1 卷积的方式扫过目标特征，再经过二维 softmax，得到一张对应图。

训练只需最小化一组神经重投影误差（Neural Reprojection Error，NRE）之和，也就是真实重投影位置的负对数似然，用 SGD 优化并配合早停。整个过程既不假设任何点可见，也不需要标注哪些点是可见、被遮挡还是视野之外——网络自始至终只输出对应图。为了突出几何而非纹理细节，对应图刻意保持低分辨率：在有效 stride 为 8、输出比例 $\gamma=50\%$ 时，一张 640×480 的目标图对应一张 160×120 的对应图。

它真的能“想象”出对应点吗

论文的第一个核心问题是：在没见过的场景里，NeurHal 能不能真正幻想出看不见的对应点？下面这张能力对比表先给出一个定性的回答——原文用精度曲线做了量化，这里只关心“能不能做到”。

表 1 NeurHal 与主流局部特征匹配方法在三类对应任务上的能力对比。

对应任务	主流匹配方法（LoFTR、DRC-Net、S2DNet）	NeurHal
识别（可见点）	可以	可以
内补（被遮挡）	很弱	可以
外补（视野之外）	无法	可以

结论很直接：在识别可见点上，大家都能做；但在内补上，LoFTR、DRC-Net、S2DNet 等方法表现很弱；而在外补上它们几乎完全失效——因为这些方法只会在目标图边界以内搜索，根本不会把对应点放到画面之外。NeurHal 则在三种情形下都能给出集中在真实位置附近的预测。图 5 用几组训练时未见过的图片，把这种能力直观地展示了出来。




图 5 定性的内补/外补结果。上排为外补示例，下排为内补示例。每组从左到右依次是：带关键点（红点）的源图、目标图，以及 NeurHal 预测的（负对数）对应图；蓝色虚线框标出目标图的真实边界，红圈为真实对应点。可以看到，即便正确答案落在边界之外，概率质量也能集中到框外正确的一侧。

幻想对应点，让相机定位更稳

这种“脑补”能力有什么实际用处？作者把它接到了绝对相机位姿估计上——这是视觉定位里的关键一环。在 ScanNet 留出场景的 2500 对源图/目标图上，他们统计了位姿被正确估计的比例——判定标准是旋转误差 $< 20^\circ$ 、平移误差 $< 1.5\text{ m}$ ——并观察这个比例如何随两张图的视觉重叠度而变化。




图 7 绝对相机位姿实验 (ScanNet)。横轴为图像对的最大视觉重叠度，纵轴为位姿被正确估计的比例。绿色曲线是 NeurHal，明显高于所有对比的局部特征匹配方法，尤其是在重叠很少、大多数对应点都不可见的困难区间。

差距最大的地方，恰恰是两张图几乎不重叠、绝大多数对应点都落在视野之外的時候——而 NeurHal 是唯一能“外补”这些点的方法。也就是说，能不能想象出画面之外的对应点，直接决定了低重叠图像对上的定位成败。

到底是哪一项在起作用

那么，三个任务里究竟是谁带来了这份稳健？作者在 ScanNet 上做了一次消融，逐一考察识别、内补、外补各自的贡献。




图 6 消融实验 (ScanNet)。深色曲线为同时学习识别、内补、外补三个任务的完整 NeurHal；一旦去掉外补任务（浅色曲线），在低重叠区间的位姿精度明显下降。相比之下，内补任务带来的额外提升要小得多。

结论是：同时训练三个任务效果最好，而真正拉开差距的是外补任务——在低重叠、对应点大多落在视野之外的情形下，它几乎决定了成败；内补任务对相机位姿估计的额外帮助则相当有限。这也和直觉吻合：越是难的低重叠场景，越需要把对应点“想”到画面之外去。

小结与边界

这篇工作给出的信息简单却有力：一个网络可以学会幻想关键点的对应——无论可见、被遮挡，还是完全落在视野之外——而这种幻想能力，让绝对相机位姿估计在低重叠图像对上明显更稳健。换句话说，NeurHal 把“不可见区域”从需要丢弃的噪声，重新定义成可以通过学习几何推理去预测的信号。

当然也要看到它的边界。NeurHal 输出的是刻意保持低分辨率的概率分布，强调的是几何上的合理位置而非像素级精度；外补点的定位仍带有可观的不确定性，往往只是把概率质量压到正确的方位区域。但作为把“脑补对应点”正式变成一个可学习任务的第一步，它已经清楚地证明：让网络去想象看不见的东西，是有价值的。