

NeurIPS 2022 | 让 VQA 模型学会“讲道理”，却发现我们还没法给它打分

University of Illinois 与 Amazon Alexa AI 在 SOTA 视觉问答框架上加装可读解释生成模块，准确率几乎不变，却揭示 BLEU、ROUGE 根本分不清解释的好坏。

给一个现代视觉问答（Visual Question Answering, VQA）模型看一张图，问它“马是走在小路上吗？”，它会很有把握地回答“no”。但你要是追问一句“为什么”，它就哑口无言了。过去几年，得益于大规模预训练视觉语言模型，这个领域把答案准确率一路推高，却几乎没人去关心答案背后的推理过程。预测可能是对的，可你拿不到任何解释它是怎么得出来的证据，而一旦你想调试它、信任它，或者把它放进产品里，这就成了大问题。

来自 University of Illinois at Urbana-Champaign 和 Amazon Alexa AI 的这篇《Towards Reasoning-Aware Explainable VQA》做了两件事。第一，在一个强大的 VQA 主干上加装一个轻量的解释生成模块，让模型在给出答案的同时输出一句人类可读的解释，而且几乎不损失准确率。第二，也是更耐人寻味的一点：作者用一项大规模人类评测去追问一个几乎被整个领域跳过的问题：当模型能自我解释之后，我们又该怎么判断这份解释到底好不好？结论并不让人舒服：大家惯用的字符串匹配指标 BLEU 和 ROUGE，在这件事上并不可靠。

作者把 VQA 模型分成三档。第一档只给答案；第二档额外配一句对图片的泛泛描述（caption），它恰好在图里，却并不真正支撑答案；第三档，也是稀缺又理想的一档，能给出一份逻辑自洽、真正导向答案的解释。今天几乎所有 SOTA 系统都停在第一、二档。这篇论文想做的，就是用很低的成本够到第三档，并且诚实地衡量它到底做到没有。




图 1 整体架构。Faster-RCNN 图像编码器与基于 GRU 的问题编码器共同送入 Coarse-to-Fine Reasoning (CFR) 主干，其联合嵌入驱动两个分支：一个 MLP 预测答案 (A)，一个新增的解释生成器输出文本解释 (E)。整套系统端到端训练。

论文链接：<https://arxiv.org/abs/2211.05190>

主干不变，改变一切的只是那一个模块

系统搭建在 SOTA 的 Coarse-to-Fine Reasoning (CFR) 框架之上。预训练的 Faster-RCNN 从图像中抽取感兴趣区域 (ROI) 特征，以及图像谓词 (object、attribute 标签，例如“brown, horse”)，并用 GloVe 做嵌入；问题一侧用 GloVe 嵌入过一个 GRU 编码，问题谓词则通过过滤停用词得到。这些信号依次流经三个阶段：information filtering 去除噪声区域，multimodal learning 用双线性注意力在粗、细两种粒度上融合图像与问题，semantic reasoning 再把两级信息合成为一个联合嵌入。

论文的关键改动就落在这个联合嵌入上。在标准 VQA 模型里，它只喂给一个预测答案的 MLP；这里它还额外喂给第二个分支：解释生成器，自回归地解码出一句自然语言解释。作者尝试了两种解码器：一个两层 LSTM 和一个八头 Transformer decoder，都用真值解释以 teacher forcing 训练。整个模型以组合损失端到端优化， $L = \alpha \cdot L_{\text{ans}} + (1-\alpha) \cdot L_{\text{expl}}$ ，其中平衡因子 α 在“答题”和“解释”之间做权衡。它的巧妙之处在于，解释分支是一个轻量的外挂：它复用主干本就在做的推理，而不需要额外的模型或外部知识库。

两个数据集都不完美，而作者直言不讳

很少有数据集在答案之外还标了解释，于是作者选了现有规模最大的两个。GQA-REX 为 GQA-balanced 中约 98% 的样本提供了解释，约 1.04M 个问答对、覆盖 82K 张图像，但它的解释沿用了此前工作的场景图 (scene graph) 推理格式，并不完全是人类可读的，有时还带语法瑕疵。VQA-E 为 VQA 2.0 中约 40% 的问答对提供解释，但由于这些解释是靠给问答对匹配图像 caption 生成的，读起来更像描述而非真正的推理。论文坦承两者都不理想，这一点很重要，因为真值本身的薄弱，正是后面评测故事变复杂的原因之一。




图 2 (a) GQA-REX 与 (b) VQA-E 的解释样例。GQA-REX 的解释引用场景图里的物体 ID (如“(obj:329774) is parrot”)，只有部分可读；VQA-E 的解释则像一句恰好包含答案的图像描述。

好消息：解释几乎是白送的

第一个头条结果是一个“没有变化”的结果，而这恰恰是最好的结果：加上解释分支并不损失准确率。在 GQA-REX 上模型拿到 77.49% 的 VQA score，在 VQA-E 上拿到 71.48%，两者都基本追平了完全不带解释监督训练的基线。扫过平衡因子 α ，数字几乎不动；把 LSTM 换成 Transformer decoder，数字也几乎不动。无论解释分支占用了多少容量，主干答题的水平照旧。

表 1 加装解释分支后，答案准确率 (VQA score, %) 得以保持。“基线”是同一主干在无解释监督下训练的结果。

数据集	基线 (无解释)	+ LSTM (最优 α)	+ Transformer ($\alpha=0.5$)
-----	----------	-----------------------	--------------------------------

GQA-REX	77.49	77.49	77.06
VQA-E	71.48	71.55	71.46

这样一来模型会“说话”了。可这些解释到底好不好？用传统 NLP 指标看，还算体面，但谈不上出彩。在 VQA-E 上，CFRF+LSTM 全面优于此前基线：BLEU-1 从 0.268 提到 0.33，ROUGE-L 从 0.249 提到 0.325。作者没有借机吹嘘，只把这些绝对分数评价为“仅仅令人满意”。而这份克制，正是全文真正论点的铺垫，因为下一个问题是：这些指标到底还有没有意义？

表 2 VQA-E 验证集上的解释质量。CFRF+LSTM 在每项指标上都优于基线，但绝对值仍然不高。

Model	BLEU-1	ROUGE-1	ROUGE-2	ROUGE-L
Baseline [16]	0.268	—	—	0.249
CFRF+LSTM	0.33	0.364	0.117	0.325

坏消息：这些指标在说谎

BLEU 和 ROUGE 生来是为字符串重叠打分的，统计候选句与参考句共享了多少 n-gram。用来衡量翻译质量还算合理，但它完全说不清一份解释是否真的支撑了答案。论文用三个被指标彻底搞反的例子把这一点讲透了，值得对着图细看。



图 3 字符串匹配指标为何失效。(a) 中模型答对了，人类标注者也认为生成解释与真值解释都有效，但因为措辞不同，BLEU-1 只有 0.27；(c) 中生成解释在事实上是错的（把红衣黑裤说成“blue shirt and white shorts”），却因为句式与参考句重合，拿到了高达 0.84 的 BLEU-1。重叠高但推理错，重叠低但推理对。

例 (a) 是一份被指标冤枉的有效解释：模型说“a woman is walking in the rain with an umbrella”，是对问题的一个获人类认可的回答，但因为真值解释换了种说法，BLEU-1 只有 0.27。例 (c) 则是镜像，也更具杀伤力：生成解释把颜色说得完全不对，却因为呼应了参考句的句式结构，赢得了 0.84 的 BLEU-1。一个奖励错误解释、惩罚正确解释的指标，衡量的根本不是我们在意的东西。这正是论文的核心论断，也是作者转向人类评测的原因。

把人类拉进评测环路

为了直接衡量解释质量，作者在 Amazon Mechanical Turk (AMT) 上做了一项研究。每个任务给出一张图、一个问题、一个答案和一份解释，只问一件事：这份解释真的能导向这个答案吗？标注者从“Yes”“No but contains the answer”“No”“Not determined”里四选一，而关键在于，他们并不知道这份解释是模型生成的还是真值，从而消除了一个明显的偏差来源。



Question: **How many chefs are in the picture?**

Is the explanation sufficient to lead the answer to the question?

Explanation: **two people in a kitchen with two ovens**

Answer: **2**

☐ Yes ☐ No but contains the answer ☐ No ☐ Not determined

Is the explanation sufficient to lead the answer to the question?

Explanation: **two male chefs cooking in a kitchen while another staff member uses a mobile phone.**

Answer: **3, 2**

☐ Yes ☐ No but contains the answer ☐ No ☐ Not determined

图 4 人类评测中的一个 HIT (human-intelligence task) 示例。对同一个图像问题对，标注者在不知道哪个是模型生成、哪个是真值的情况下，分别判断两份解释能否导向答案。

这项研究规模不小：从 VQA-E 验证集中取 4735 个不重复的图像问题对，每个由 3 名标注者评判，共收到来自 111 名受试者的 14205 份回复。剔除三人意见完全相左的样本后，对生成解释的裁决是：65.16% 确实能导向预测答案，相比之下真值解释这一比例为 93.12%。差距是真实存在的，但同样真实的是，模型自发给出的解释里大约有三分之二能通过人类的“直觉检验”。

再按答案本身是否正确来拆分，画面就更清晰了。约 56.39% 的情况下，模型答案和解释双双正确；把若干接近的情形算进来，模型在大约 60.5% 的时候能同时给出正确答案和有效解释。真正该担心的情形，也就是“听着挺像样的解释配了个错答案”，反而相对少见，只占约 8.77%，在整体里属于少数。

表 3 人类对模型预测解释的判断，按预测答案是否正确拆分 (VQA-E)。多数有效解释都伴随正确答案；模型很少为错误答案配出看似有效的解释。

预测答案	有效解释	无效解释
正确	56.39%	23.77%
错误	8.77%	11.05%

该带走什么

这里有两条结论，而更持久的是第二条。从工程角度看，论文证明了解释生成几乎可以免费地加到一个强 VQA 主干上：一个轻量的解码器分支，端到端训练，就能在答案旁附上一句人类可读的理由，而准确率没有可测量的损失。仅这一点，对任何想构建可解释视觉语言系统的人都是有用的结果。

但从方法论角度，论文抛出的判断更锋利：可解释 VQA 的瓶颈不在生成器，而在评测。字符串匹配指标会奖励错误解释、惩罚有效解释，所以 BLEU 和 ROUGE 不足以用来给解释质量排序，那项人类评测之所以存在，正是因为没有任何自动指标能替代它。诚实的边界也在这里：数据集本身并不完美，而人类评测虽大，却昂贵到难以反复重做。作者并没有给出那个替代指标，他们做的是把“领域需要一个新指标”这件事论证清楚。如果你在做面向推理的视觉语言模型，这份对“建立真正以人为本的评测”的呼吁，才是最值得带走的部分。