

NeurIPS 2023 | 对抗鲁棒的天花板到底在哪里：多分类版本的最优 0-1 损失

Princeton、University of Chicago、Penn State 用冲突超图给出任意离散数据集下、面对测试时攻击者的最优可达损失，并揭示当前鲁棒模型离这条上限还有多远

过去几年，对抗样本的研究几乎变成了一场攻防军备竞赛：有人提出更强的防御，很快就有人设计出更强的攻击把它打穿，然后再换一轮更强的防御。问题是，这样的循环里我们始终缺一个参照系：一个分类器到底能有多鲁棒？如果连理论上的天花板都不知道，就没法判断当前的鲁棒模型究竟是已经接近极限，还是还有很大的提升空间。

对二分类问题，已有工作给出了这个参照系：在给定数据分布和攻击者能力（test-time attacker，测试时攻击者）的前提下，任何分类器能达到的最优 0-1 损失是可以刻画的。但现实里的分类任务大多是多分类，而从二分类到多分类并不是简单的推广：当类别数达到三个或更多时，样本之间会出现二分类分析捕捉不到的高阶相互作用，这些作用会改变「最优鲁棒」长什么样。

这篇发表于 NeurIPS 2023 的论文正是补上了这一块：它给出了任意离散数据集、面对 L2 约束下测试时攻击者时，多分类问题最优 0-1 损失的信息论下界，并把它做成一个可以实际计算的诊断工具。核心做法是把数据和攻击者的约束编码成一张「冲突超图」（conflict hypergraph），再解一个线性规划，其最优值就是任何分类器所能达到的最低损失。

论文与代码

论文：Characterizing the Optimal 0-1 Loss for Multi-class Classification with a Test-time Attacker (NeurIPS 2023) , <https://arxiv.org/abs/2302.10722>

代码：https://github.com/inspire-group/multiclass_robust_lb

为什么要算「最优损失」这个天花板

衡量一个鲁棒模型好不好，最有力的方式不是和别的防御互相比，而是和「理论上最好的分类器」比。如果最优分类器在某个攻击强度下也只能做到 0.4 的损失，那你的模型做到 0.45 其实已经很接近极限了；但如果最优损失是 0，而你的模型停在 0.6，那说明瓶颈不在数据本身，而在训练方法，还有大量的鲁棒性没被利用起来。

这个下界有两个关键性质：它是和「具体的数据集与威胁模型」绑定的，而不是一个笼统的最坏情况；它衡量的是任意分类器（而非某一类特定模型）能达到的极限。正因为如此，它能把「你的方法不够好」和「这个问题本来就难」这两件事分开，而这恰恰是攻防军备竞赛里最难判断、也最有价值的一点。

核心工具：冲突超图与线性规划

论文把最优鲁棒损失的计算，转化成了一个图结构上的优化问题。先看直觉：把每个数据点看成图上的一个顶点；当来自不同类别的一组点，它们在攻击者眼里的「邻域」相互重叠（也就是攻击者可以把其中任意一个点推向同一个难以区分的输入），这组点就构成一条超边（hyperedge）。二分类里只需要考虑两两之间的冲突（普通的边），而多分类需要考虑三个、四个乃至更多点同时冲突的情形，这正是高阶相互作用的来源。

下面这张图用最小的例子说明了高阶冲突为什么重要。三个点分别来自三个不同类别，它们两两的邻域都有重叠。区别在于：三个邻域是否存在一个公共交点。




图 1 三个来自不同类别的样本构成的两种冲突结构。左侧 ($\mathcal{V}$) 三个圆两两相交但没有公共交点，因此 $\{u, v, w\}$ 不是一条超边，只有两两之间的边生效；右侧 ($\mathcal{V}'$) 三个圆存在公共交点， $\{u', v', w'\}$ 的所有子集都是超图中的超边。这条三阶超边只有在三个样本的类别概率都接近均衡（都不超过 $1/2$ ）时，才会真正改变最优损失，这也解释了为什么高阶结构在很多情况下可以被忽略。

有了这张超图，最优 0-1 损失就可以写成一个线性规划：在超图关联矩阵给出的约束下，最大化被正确分类样本的概率质量。它的对偶问题是用超边对顶点做一个分数覆盖（fractional cover），而这个覆盖直接对应最优攻击者的策略。换句话说，同一个线性规划的原问题给出「最好的分类器能做到多好」，对偶给出「最强的攻击者应该怎么打」。

问题在于，精确计算需要枚举所有阶数的超边，规模会爆炸。为此论文给出了三种更省算力的界，把真实最优损失夹在一个可计算的区间里：把超图截断到最大阶数 m ，得到一族下界 $L^*(m)$ （阶数越高越紧）；把二分类的一对一（1-vs-1）最优损失用最大权耦合聚合起来，得到一个便宜但更松的下界 $L^*_{co}(2)$ ；再用独立集数的广义 Caro-Wei 近似给出一个上界 LCW。下界和上界一起把最优损失锁定在一个窄区间内。

现实差距有多大：三分类上的实验

论文在 MNIST 和 CIFAR-10 两个标准视觉数据集上计算了这些界，攻击者为 L_2 约束、强度 ϵ 逐步扫描。三分类设定下每类取 1000 个样本（MNIST 用数字 1、4、7，CIFAR-10 用 plane、bird、ship 三类）。作为参照的防御模型采用 TRADES 对抗训练（adversarial

training, AT), MNIST 上是一个三层 CNN, CIFAR-10 上是 WRN-28-10, 并用 AutoAttack 中的强攻击 APGD-CE 评测。




图 2 三分类问题上的 0-1 损失随攻击强度 ϵ 的变化 (左: MNIST 1/4/7, 右: CIFAR-10 plane/bird/ship)。 $L^*(2)$ 、 $L^*(3)$ 是截断到二阶、三阶超边得到的最优损失 (下界), AT 是对抗训练模型在 APGD 强攻击下的实际损失。可以看到对抗训练曲线 (绿色) 始终远高于最优损失曲线: 在 CIFAR-10 上, 当最优损失还接近 0 时, TRADES 已经卡在约 0.6 的损失上下不去。

这张图给出了论文最直接的结论: 对抗训练模型与理论最优之间存在一个很大的、此前从未被量化的差距, 而且这个差距比二分类里观察到的要大得多。在三分类 CIFAR-10 上, 当攻击强度对应的最优可达损失几乎为 0 时, TRADES 对抗训练却怎么也做不到比 0.6 更低。这说明当前鲁棒训练方法留下的性能空间非常大: 瓶颈不在数据, 而在方法。

扩展到十分类, 以及一个反直觉的观察

作者进一步在完整的十分类设定下计算了这些界。这里的关键问题是: 截断到低阶的下界会不会太松, 导致上面的「差距」只是界不准的假象? 下图回答了这个问题。




图 3 完整十分类问题上的最优损失的上下界 (左: MNIST, 右: CIFAR-10)。 $L^*(2)$ 、 $L^*(3)$ 、 $L^*(4)$ 是阶数递增的截断下界, $L^*_{co}(2)$ 是聚合二分类界得到的更松下界, L_{cW} 是 Caro-Wei 上界; 灰色区域是真实最优损失 $L^*(10)$ 预计落入的范围。在实际使用的攻击强度下, 下界与上界把最优损失夹得很紧, 说明前面看到的「对抗训练差距」并不是界不准造成的假象。

在实际关心的攻击强度区间里, 截断下界和 Caro-Wei 上界几乎贴合, 把真实最优损失锁定在一个很窄的灰色区间内。这意味着, 前面在三分类上看到的巨大差距, 在十分类下依然成立, 并且不是因为界算得太松。

更反直觉的是一个关于「高阶超边到底有多重要」的观察。理论上，多分类需要考虑三阶、四阶乃至更高阶的冲突，但实验发现：在小攻击强度下，只用二阶边算出的下界 $L^*(2)$ ，和额外加入三阶、四阶超边的 $L^*(3)$ 、 $L^*(4)$ 几乎完全重合，直到损失超过约 0.4 才开始分开。以 CIFAR-10、 $\epsilon=3$ 为例，图里其实存在约 3M 条三阶超边和约 10M 条四阶超边（三百万、一千万量级），但它们对计算出的下界没有任何影响。换句话说，在实践关心的低强度区间，只用边的下界既便宜又准确。

把差距摆到台面上

如果换成当前最好的可认证鲁棒（certifiably robust）模型，结论也不会变好。下表把这些模型的实际 0-1 损失和对应设定下的最优损失下界放在一起，差距一目了然。

表 1 当前最好的可认证鲁棒模型的实际 0-1 损失 vs. 最优损失下界（越低越好）。即便是专门为鲁棒性设计、带有认证保证的模型，也远离理论上限，在所有列出的设定里，最优下界都是 0。

设定	攻击强度 ϵ	最佳鲁棒模型 0-1 损失	最优损失下界
MNIST（可认证）	1.52	0.27	0
MNIST（可认证）	2.0	0.44	0
CIFAR-10（可认证）	1.0	0.6	0
CIFAR-10（可认证）	2.0	0.8	0

总结与边界

这篇论文把二分类里的冲突图框架推广到了多分类，用一张冲突超图上的线性规划刻画了面对测试时攻击者时的最优 0-1 损失，并配上一族高效的上下界，在实践关心的低强度区间把这个最优值夹得很紧。基于这套工具，它第一次量化了多分类下对抗训练模型与理论最优之间的差距，而这个差距远比二分类里的严重。

对实践者来说，最有价值的是它提供了一个快速的诊断工具：给定你的数据集和威胁模型，你可以先算出最优损失的区间，看看当前模型离天花板还有多远，从而判断该继续打磨训练方法，还是这个问题本身就难。需要留意的边界是：这些结果针对的是离散数据分布、L2 约束的测试时攻击者，具体数值也与数据集、类别选择和样本量有关；下界给出的是「存在这样一个分类器」的信息论保证，并不直接告诉你如何训练出它。但它至少把方向指清楚了：与其在攻防军备竞赛里无休止地迭代，不如先看看还有多少鲁棒性真正留在桌上。