

ICML 2024 | 单条示范不该照抄,而该被“追踪”

南京大学与南栖仙策提出 Deep Demonstration Tracing(DDT):让单样本模仿在环境突变时依然稳健

单样本模仿学习(One-shot Imitation Learning, OSIL)要求智能体只看一条示范,就把任务完成。在部署环境与采集示范时几乎一致的情况下,这类方法表现相当好。问题在于,真实世界很少一成不变:路线示范给出之后,可能突然有辆卡车停在路中间;抓取动作演示完,物体也可能从夹爪里滑落。正是在这些时刻,示范不再是一份可以逐步照抄的脚本,顶多只能算一份粗略的向导。

大多数 OSIL 方法把示范编码成一个上下文向量,然后克隆示范中的动作。在静态环境里这已经够用。可一旦出现未曾预料的变化,把智能体推入示范从未覆盖的状态,盲目照抄就无从应对,已有方法的性能也会急剧下滑。这篇发表于 ICML 2024 的工作,正是把这一失效模式当作研究对象。

作者给出的答案是 Deep Demonstration Tracing(DDT,深度示范追踪):与其照抄示范,不如学会“追踪”示范——先判断当前时刻哪些示范状态是相关的,再读出专家在那些状态下的行为,最后在绕行之后重新回到示范的路径上。DDT 把一个专门设计的示范 Transformer 与元强化学习(meta-RL)训练方案结合起来,在以往单样本模仿方法失效的地方依然站得住脚。




图 1 展示 Meta-World 中的一个抓取-放置任务,物体在执行中途滑落。面对同一条示范(a),传统 OSIL 策略(b)掉落物体后直接失败,而 DDT 策略(c)重新抓取物体并最终成功——这正是“照抄动作”与“追踪意图”的差别。

论文 :<https://arxiv.org/abs/2408.05285> | 代码 :<https://github.com/xionghuichen/Deep-Demonstration-Tracing> | 项目主页:<https://osil-ddt.github.io>

当“照抄”不再奏效

从形式上看,一个任务就是一个马尔可夫决策过程(MDP),而 OSIL 只提供一条专家轨迹作为“该做什么”的唯一描述。以往工作大多研究采集与部署几乎一致的设定,此时只要在每个示范状态复现示范动作,策略就能应付。本文则刻意拉大采集与部署之间的差距——在运行时加入障碍、扰动等未曾预料的变化——并指出真正有意思、也长期被忽视的难点恰恰在这里。

于是,要求就不再只是复现示范动作,而是要在偏离示范的状态下也能做出合理行为,并找到回到示范的路。这正是现有方法没有内建的自适应能力。

来自人类模仿的蓝本

方法的设计起点,是人类如何模仿一条路线。沿着示范路线走向目的地时,你遇到一辆停在原本没有障碍处的卡车。你不会僵住,也不会重头再来,而是绕过障碍,再在合适的地方重新汇入原路线。作者把这一过程提炼成一个三阶段决策流程:识别(identify)当前情境下哪些示范状态相关,分析(analyze)专家在这些状态下如何行动,再追踪(trace)回到示范之上。




图 2 未预料变化下单样本模仿的人类蓝本。专家轨迹(虚线)从起点 S 通向目标 P;一辆采集示范时并不存在的卡车挡住了状态 B。合格的模仿者会离开示范路径、绕行(绿色),再重新汇入示范——先识别、再分析、最后追踪回去。

这套蓝本不只是叙事上的点缀,它会直接变成网络的结构:三个阶段各自对应示范 Transformer 中一项具体运算。正是这种对应关系,把关于人类行为的直觉转化成模型可以学习的归纳偏置。

示范 Transformer

核心模块把智能体当前状态作为查询(query),把示范的状态-动作对作为键(key)与值(value)。注意力加权模块为“当前哪些示范状态重要”打分,对应识别阶段;随后的逐点相乘(point-wise

multiplication)把这些权重与编码后的专家行为结合,读出专家在那些状态下做了什么,对应分析阶段;结果再与当前状态重新融合,经一个 MLP 输出动作,对应追踪阶段。专家状态编码器与已访状态编码器共享权重,使示范状态与当前状态在同一表示空间中比较。




图 3 示范 Transformer。自下而上,人类的三个阶段被落实为网络运算:注意力加权(阶段一,识别该跟随哪些状态)、逐点相乘(阶段二,分析专家如何行动),以及与当前状态重新融合后经 MLP 输出动作(阶段三,追踪回去并行动)。专家状态编码器与已访状态编码器共享权重。

把示范编码器与基于上下文的策略整合进同一个架构,正是 DDT 倾向“追踪”的归纳偏置来源。也正是这种偏置,让它能够泛化到训练中从未见过的示范与扰动,而不是死记一套从上下文到动作的固定映射。

以元强化学习训练,而非行为克隆

第二个要素在于训练方式。行为克隆(behavior cloning)只能教会智能体在示范访问过的状态该做什么,而当整个问题恰恰是“在偏离示范的状态下也要表现良好”时,这正好用错了工具。DDT 转而把单样本模仿建模成基于上下文的元强化学习:示范作为上下文,智能体通过与环境交互,学会在示范从未到达的状态下也能行动。

奖励采用一种平稳的 OSIL 奖励,它把“鼓励智能体跟随示范”的项,与一个大权重的任务奖励结合起来,后者确保重心始终落在真正完成任务上。这个稠密信号让训练早期就能高效学习,整个目

标用 Soft Actor-Critic(SAC)优化。论文还给出一个理论条件——大致是环境可从偏离处“恢复”回示范——在该条件下,单条轨迹就足以成功模仿。

VPAM:为“未预料变化”而生的基准

为了检验运行时变化下的模仿能力,作者构建了 VPAM(Valet Parking Assist in Maze,迷宫代客泊车),灵感来自现实中的代客泊车。一个质点智能体要在从未从全局见过的迷宫里,从起点走到目标,只能依靠由 8 条射线、5 步范围计算出的局部视野。关键在于,矩形障碍会随机出现在路线上,而它们往往在示范中并不存在,因此智能体无法简单照抄示范动作。八个任务变体分别切换:单张地图还是多张、是否出现障碍、以及是否提供坐标。




图 4 一张 VPAM 迷宫。智能体在示范点(灰色)引导下,从起点(蓝色)走向目标(绿色),而未预料的障碍(棕色)挡住了示范路线。智能体只能感知很小的局部视野(阴影区),DDT 的模仿轨迹(红色)绕过每个障碍后重新汇入示范。

除 VPAM 外,DDT 还在多个机器人基准上评测:带扰动的 Meta-World、Gymnasium 的 Reacher 与 Pusher,以及一个涉及抓取、堆叠与杂乱环境的 MuJoCo 操作任务,另有部分可观测的 VPAM 变体。

它到底有多稳?

在 VPAM 上,DDT 在每个设定下都领先;更说明问题的是,随着条件变难,它的下滑幅度小得多。从训练分布,到无障碍测试地图,再到未预料障碍,DDT 的成功率仅从 0.86 降到 0.84 再到 0.73,跌幅 15%。而基线在同一跨度上分别下滑 20%、33% 与 52%,也就是说 DDT 至少多保留了 5% 的性能。




图 5 VPAM 三种设定下的成功率。DDT(红)在每个设定下都领先 DCRL、CbMRL 以及行为克隆式的 Trans4OSIL,且在未预料障碍下差距进一步拉大——DDT 达到 0.73,而最强基线仅 0.57。黑色误差条为三个随机种子下各任务间的标准误。

表 1 VPAM 成功率(越高越好),以及从训练集到未预料障碍设定的下滑幅度。

方法	训练	无障碍	未预料障碍	下滑幅度
DDT(本文)	0.86	0.84	0.73	-15%
DCRL	0.71	0.62	0.57	-20%
CbMRL	0.62	0.47	0.36	-33%
Trans4OSIL	0.33	0.28	0.16	-52%

机器人实验把这个故事讲得更鲜明。在带扰动的 Meta-World 上,DDT 在未见过的示范上有 61% 的成功率,而最强基线最多也只有约 12%。带来这种对变化的稳健性的,是元强化学习机制,而不仅仅是 Transformer。

它真的在“追踪”吗？

一个以“追踪”命名的方法,理应证明它确实在追踪。作者把 DDT 在迷宫中的一次运行,与示范 Transformer 在智能体前进时对专家轨迹给出的注意力分数一并可视化。如果 DDT 确实在跟随示范,那么注意力应当大致随智能体自身的推进,沿着专家路径逐步移动。




图 7 左:DDT 生成的一条轨迹,绕过障碍后重新回到示范路线。右:注意力分数图,纵轴为智能体步数,横轴为专家步数。明亮的条带沿对角线延伸——智能体每前进一步,注意力就跟踪到示范的对应部分,这正是“追踪”的可视化。

那条对角线正是机制如预期般工作的证据:注意力随智能体同步跟随示范,恰在需要绕行时短暂偏离,绕行之后又重新锁定。这是一个令人安心的验证,说明架构确实在做它被设计去鼓励的那件事。

消融与规模化

两项消融确认了两个要素缺一不可。把示范 Transformer 换成标准 Transformer,渐近性能明显下降——可见起作用的是这套量身定制的架构,而非泛泛的注意力机制。去掉 OSIL 奖励、只用稀疏的结束奖励学习,则会显著拖慢学习,因为 OSIL 奖励提供的稠密信号,正是让智能体在训练早期就能紧跟示范的关键。




图 8 左:DDT 及其消融版本的学习曲线(成功率对环境步数);替换示范 Transformer 或去掉 OSIL 奖励都会带来损害。右:随数据量与模型规模扩大时的渐近成功率(横轴为对数)——性能呈对数线性上升,仅扩大模型参数就带来约 2x(两倍)的提升。

规模化曲线是一个更安静却引人兴趣的结果:DDT 随数据量与模型规模都呈对数线性提升,参数增大时成功率大致翻倍。正是这种干净的规模化行为,让作者提出 DDT 或可作为更大、更通用决策智能体的骨干网络。

小结

核心思想简单而经得起推敲:拿到一条示范的智能体,应当学会追踪它,而非照抄它——判断此刻哪些示范状态相关,读出专家做了什么,并在绕行之后重新回到路径上。DDT 用一个由元强化学习训练的示范 Transformer 把这一思想落地,回报是当环境在运行时发生变化时依然稳健的单样本模仿,而这恰是以往方法失效的区域。

也应看清它诚实的边界:单条示范的保证依赖一个可恢复性条件,而最亮眼的结果建立在一个专门构建的迷宫基准以及一组机器人任务之上。但在这一范围内,DDT 干净地表明了:当世界拒绝静止时,合适的归纳偏置加上强化学习,胜过行为克隆——而它的规模化表现,也让人对后续充满期待。