

ICLR 2022 | 把一整支策略群装进一个网络： NeuPL 让种群学习不再从零重来

UCL 与 DeepMind 提出 Neural Population Learning，用一个条件网络统一自博弈、虚拟博弈与 PSRO，并给出收敛保证

在 StarCraft、扑克这类策略博弈里，只训练一个「最强策略」是没有意义的：石头总会输给布，任何单一策略都能被针对。要在这类博弈里稳住阵脚，模型需要的是一整支互相制衡的策略群（population）。问题在于，主流做法是把这支群「一个一个」养大——每次固定住已有的策略，再从头训练一个新策略去打败它们的混合，如此循环。

这套流程在石头剪刀布这样的标准式（normal-form）小游戏里很干净，因为最优反应（best response）可以精确求解。但真实博弈是时序的、部分可观测的，最优反应只能用昂贵的深度强化学习去近似。于是两个麻烦同时出现：算力有限时，你分不清一个策略是真的收敛了，还是卡在局部平台，只能凭手工设定的时间表提前截断训练，把一批「训练不足」的弱策略塞进群里；更糟的是，每个新策略都要从零重新学会走路、看图、操控这些基本功，对手越强，这件事越算不动。

NeuPL（Neural Population Learning）给出的思路很直接：这些策略之间的重叠其实极大——它们共享感知、记忆和运动技能，分开训练本身就是浪费。如果一个网络能同时装下整支策略群，并根据「该打谁」来切换自己的行为，那么对弱对手学到的早期技能，就能直接为发现针对强对手的克制策略打好底子。这篇发表于 ICLR 2022、来自伦敦大学学院（UCL）与 DeepMind 的工作，把这个想法做成了一个带收敛保证的统一框架。




图 1 常见的种群学习算法都可以写成同一种「交互图」（下方有向图）或等价的元博弈混合策略矩阵 Σ （上方矩阵）。图中从策略 i 指向 j 、权重为 σ_{ij} 的有向边，表示策略 i 以概率 σ_{ij} 去对抗 j 。自博弈、策略循环、虚拟博弈、PSRO-Nash 只是同一框架下 Σ 的不同取值。

论文链接：<https://arxiv.org/abs/2202.07415> 项目主页：<https://neupl.github.io/demo/>

老框架卡在哪里

为什么非要一支策略群？根源在博弈论：像石头剪刀布这样纯循环（cyclic）的博弈里，「变强」是相对的——你对某个对手变强，就意味着对另一个对手变弱，单点策略无处安放。经典的 PSRO（Policy Space Response Oracles）正是用「群」来处理这种循环：反复训练新策略去最优反应已有策略的混合。但它把策略一个一个训练，并丢弃了它们之间本可共享的知识。像 StarCraft 联赛那样的成功案例，动用了接近一千个智能体、代价惊人，这恰恰说明：我们需要一个在样本和技能上都高效得多的替代方案。

NeuPL 把两个原本手工设定的旋钮——种群规模、每轮训练预算——交还给算法本身。它不再靠人为的截断时间表决定「练到什么程度算一个新策略」，而是让元博弈求解器（meta-graph solver）在训练中决定有效的种群规模，同时让所有策略共享底层技能。

方法：一个网络，一张交互图

具体来说，NeuPL 只训练一个「对手条件化」的网络 $\Pi_\theta(\cdot|o, \sigma_i)$ 。每个策略序号 i 都配一个元策略向量 σ_i ，它是一个概率分布，规定这个策略应该以多大比例去对抗其他哪些策略。网络要最大化的是一个双重期望下的折扣回报：先对采样到的对手 σ_j 取期望，再对由双方策略共同决定的博弈动态取期望，即 $J(\sigma_i) = E_{\sigma_j \sim P(\sigma_i)} E_{a \sim \Pi_\theta(\cdot|o, \sigma_i), a' \sim \Pi_\theta(\cdot|o', \sigma_j)} [\sum_t \gamma^t r_t]$ 。

为了用强化学习优化它，NeuPL 联合训练一个对手条件化的动作价值函数 Q_θ ；此外还额外学一个收益估计器（payoff estimator） ϕ_ω ，直接从价值函数预测任意一对策略交手的期望结果，这样整张收益矩阵就能廉价地估出来，而不必把每一组对局都重放一遍。分配对手的这张交互图 Σ ，既可以是一个固定矩阵（复现虚拟博弈 fictitious play），也可以是自适应的——由元图求解器根据学到的收益 U 重新计算 $\Sigma \leftarrow F(U)$ （复现 PSRO-Nash）。关键在于：决定「哪些目标此刻生效」的是这张图，而不是手工时间表，所以真正互不相同的策略数量会随博弈需要自行增长。当两行 $\sigma_i = \sigma_j$ 完全相同，对应的策略就会坍缩成同一个，于是「有效种群规模」自然浮现出来。

论文进一步证明：对于「接地的」下三角交互图与合适的元图求解器，NeuPL 会收敛到 N 步最优反应；当 N 足够大时，收敛到标准式的纳什均衡。换句话说，它在获得共享与迁移带来的效率的同时，并没有丢掉博弈论上的收敛保证。

在石头剪刀布里看清它怎么工作

要理解 NeuPL 的动态，最直观的办法是把它放回石头剪刀布，因为整支策略群可以直接画在策略单纯形（simplex）上。下图用一个实现 PSRO-Nash 的自适应交互图来训练，每 10 次迭代算一个 epoch。看图时请把三行分开读：最上面一行是策略在 R/P/S 三角形里的位置，中间是网络学到的策略间收益矩阵，最下面是作为收益矩阵响应而生成的交互图（邻接矩阵）。




图3 采用实现 PSRO-Nash 的自适应交互图后，NeuPL 在石头剪刀布中的演化。（上）随时间被神经种群探索到的策略空间；（中）种群策略之间学到的收益估计；（下）作为对收益矩阵的响应而生成的交互图邻接矩阵。可见新策略被逐步推向三角形边角，收益矩阵和交互图随之扩展。

随着训练推进，新策略被一个个推向单纯形的边角，收益矩阵里出现越来越清晰的循环结构，交互图也随之扩展——这正是「让求解器决定该练谁」在最简单博弈里的可视化。同一套机制放大到更难的域，才是这篇论文真正要证明的事。

放大到时空、部分可观测的博弈

running-with-scissors 把石头剪刀布抬进了一个时空、部分可观测的设定：玩家在格子世界里移动，采集石头、布、剪刀三种资源，而且只能通过一个 4×4 的第一人称狭窄视野观察世界，必须从中推断对手隐藏的库存。这里没有精确最优反应可解，正是 PSRO 手工截断最脆弱的地方。




图4 在 running-with-scissors 中，一支 NeuPL 种群逐步发展出越来越复杂、越来越多样的策略集合。交互图每 1,000 次梯度更新（一个 epoch）刷新一次。（上）随训练推进，神经种群策略之间学到的收益估计 U ；（下）作为对收益矩阵响应而生成的交互图 $\Sigma \leftarrow \text{FPSRO-N}(U)$ 。

收益矩阵 U 从一片空白逐渐长出结构，交互图 Σ 也随之扩展，说明种群确实在持续发现能互相克制的新策略——而这一切都发生在同一个网络内部，早期学到的感知与操控技能被后来的策略反复复用。

核心结果：更省，也更稳

最能说明问题的对照，是把 NeuPL 种群直接拿去打代表同样策略集合的 PSRO 基线。下图的关键在于两条轴要一起看：黑色实线群是相对种群表现（Relative Population Performance，越高表示越能压制对手），紫色虚线是有效种群规模（右轴）。




图 7 一支 NeuPL 种群与 PSRO 基线得到的策略种群之间的相对种群表现。每个 PSRO 变体重复 3 次试验，以阴影表示。紫色虚线为有效种群规模：相对表现的上升与有效种群规模从 5 增长到 8 同步发生。

结论有两层。其一，一支最大规模为 8 的 NeuPL 种群，能够压制由同样 8 个策略构成的 PSRO 种群——即便这些 PSRO 基线每轮迭代拿到了 2 倍的梯度更新。其二，也是更重要的一点：相对表现的提升，与有效种群规模从 5 增长到 8 是同步发生的。这说明性能的改善来自真正发现了新策略，而不是在旧策略上过拟合。无论是持续训练还是从零重训的 PSRO 变体，都同样容易被压制，暗示它们没有建立起可复用的表征。

为什么会更省：迁移的作用

NeuPL 最反直觉的性质，是随着种群变大，发现新策略反而变得更容易，而不是更难。一个专门的消融实验把「迁移」单独拎出来验证：让一个新智能体分别以两种方式初始化——完全随机，或者从一个训练到第 1,000 epoch 的 NeuPL 网络迁移其编码器（encoder）与记忆（memory）组件——再要求它去打败强度递增的固定纳什混合策略。




图 6 从不同 epoch 的 NeuPL 智能体向新智能体迁移，再让其学习克制固定纳什混合（左侧为网络结构，仅迁移绿色的 Encoder 与 Memory）。红色为随机初始化从头训练，绿色为从第 1,000 epoch 迁移。面对 $n=2$ 的易剥削混合，随机初始化也能追上；但面对 $n=4$ 、 $n=7$ 的强混合，随机初始化即便长时间训练也几乎学不动，迁移则能顺利找到克制策略。每个实验重复 5 次。

面对一个只有 2 个策略、容易被剥削的混合，即便是随机初始化的智能体最终也能找到克制手段，只是更慢。但一旦对手是覆盖 4 个乃至 7 个策略的强混合，随机初始化的智能体即使长时间训练也几乎学不动，而迁移了编码器与记忆的智能体却能顺利发现克制策略。这正是 NeuPL 的核心卖点在实验上的落点：种群越大，共享的技能底座越厚，发现新策略反而越轻松。

一路放大到 MuJoCo Football

最后，为了证明框架能扛住真正的规模，论文把 NeuPL 用在了 2v2 的 MuJoCo Football 上——一个「技能博弈」（Game-of-Skills），既要求连续的运动控制，又要求团队协作，还藏着隐性的策略循环。




图 8 NeuPL 以 FPSRO-N 在 2v2 MuJoCo Football 中的表现。左侧为不同训练 epoch 下学到的收益矩阵与交互图；右侧红/蓝/白轨迹分别对应红方、蓝方球员与球，展示了不同策略之间出现的克制关系。

在这个连续控制与团队协作交织的域里，收益矩阵同样长出了清晰的循环结构，右侧轨迹图也显示出策略之间真实的克制关系——同一套「一个网络装下整支种群」的配方，从石头剪刀布一路撑到了足球。

关键数字一览

表 1 NeuPL 的核心量化结论。

指标	结果
NeuPL 种群规模	8，可压制 8 策略的 PSRO 种群
PSRO 基线的额外预算	2× 梯度更新（仍被压制）
有效种群规模增长	5 → 8（与相对表现同步上升）
有效种群规模饱和值	约 12（跨不同最大规模上限）
迁移实验重复次数	5 次
纳什混合强度	$n \in \{2, 4, 7\}$ 个策略
评测域	石头剪刀布 / running-with-scissors / 2v2 MuJoCo Football

小结与边界

NeuPL 的一句话总结是：把整支策略群装进一个对手条件化的网络，让交互图决定谁和谁对练，技能便在策略之间免费流动。这把种群学习从「一轮轮从零重来」的浪费流程，变成了一次「充满迁移」的联合训练，既降低了成本，又保留了收敛保证，还带来一个最反直觉的好处——随着神经种群扩张，发现新策略变得更容易，而不是更难。

需要保持清醒的边界也很明确：论文的收敛保证针对的是接地的下三角交互图与合适的求解器，把最大种群上限提升到 8 以上，对可剥削性的改善也只是边际的；MuJoCo Football 上的结果更多是定性的可行性展示，而非大规模基准上的系统性胜负。即便如此，「用一个条件模型承载整支种群」这条主线，为把博弈论式的种群学习真正推向复杂真实博弈，给出了一个清晰而经济的方向。