

TimeSiam：让时间序列模型向自己的「过去」学习

清华大学团队发表于 ICML 2024 的自监督预训练框架，将预训练重构为「用过去还原现在」，在 13 个基准上刷新纪录。

自监督预训练（self-supervised pre-training）改变了图像和文本模型的构建方式：先在海量无标注数据上学习通用表示，再在真正关心的任务上微调。时间序列看起来是下一个理想场景，工业传感器、可穿戴设备以及更广义的物联网（IoT）每天都在产生海量且不断增长的测量数据，而其中几乎没有标注。于是一个很自然的想法出现了：把在视觉和语言上奏效的配方，直接搬到时间序列上。

问题在于，这些配方并不太合身。当你在序列上随机遮盖（mask）零散的点时，可能会破坏信号赖以成立的平滑时间结构，有时甚至让重构任务难到模型学不到什么东西。对比学习（contrastive learning）则是另一种失败模式：以整条序列为单位计算相似度，往往忽略序列内部细粒度的相关性，而且它依赖的数据增强对时间信号来说极难设计。两类方法都悄悄忽略了让时间序列之所以成为时间序列的那件事：过去的观测与当下的观测之间是相关的。

来自清华大学、发表于 ICML 2024 的 TimeSiam，正是把这种相关性当作核心对象。它不再孤立地遮盖一个窗口，而是从同一条序列中采样一个「过去」子序列和一个「当前」子序列，训练孪生网络（Siamese network）用过去还原被遮盖的现在。这一个设计选择，迫使模型把序列中相隔较远时刻之间的关系内化下来，而它在跨任务、跨领域的迁移上表现得出奇地好。




图 1 时间序列自监督预训练的三种配方。(a) 掩码建模：孤立地重构被遮盖的序列；(b) 对比学习：拉开不同序列，同时拉近同一序列的两种增强；(c) TimeSiam：用随机采样的过去窗口去重构被遮盖的当前窗口，把「跨时间相关性」作为学习信号。

论文地址：<https://arxiv.org/abs/2402.02475>

代码地址：<https://github.com/thuml/TimeSiam>

为什么「借来的配方」不够用

具体看看问题出在哪里。掩码建模最初是为词元和图像块设计的，遮盖掉一个离散单元后，周围上下文仍能推断出它。可时间序列是连续且局部平滑的，遮盖零散的点，要么留下一个很容易插值的简单问题，要么在高遮盖比例下破坏了太多结构，让任务不再教给模型任何有用的东西。对比方法绕开了重构，却依赖既保持语义又改变表象的增强，而对时间信号来说，哪些变换能做到这一点其实并不清楚。以整条序列计算相似度，还会把一个窗口压成单一表示，丢掉了下游预测和分类都要依赖的窗口内部动态。

追求更好配方的动机并不只是学术上的。物联网传感器和可穿戴设备产生的无标注时间序列体量持续膨胀，一种显式建模时间相关性的预训练方法，或许能在无需人工标注的情况下，把这些数据真正用于预测和分类。TimeSiam 提出的问题很简单：与其孤立地看待每个窗口，为什么不围绕「相隔一段时间的观测之间的关系」来构建预训练任务？

核心思路：用过去还原现在

TimeSiam 的预训练任务建立在作者称为「孪生子序列」（Siamese subseries）的一对窗口之上。从一条长序列中，它随机采样两个窗口：一个过去子序列和一个当前子序列，并用遮盖这类简单增强轻微地扰动当前窗口。两个共享权重的编码器分别处理过去与当前窗口，一个带交叉注意力（cross-attention）的解码器再用过去窗口作为键和值、用被扰动的现在作为查询，去重构被遮盖的当前序列。训练目标就是真实当前窗口与重构结果之间的平方误差。因为填补被遮盖现在的唯一途径，就是利用它与过去的相关性，编码器被推着去学习那种被掩码和对比目标都留在桌面上的时间结构。




图 2 TimeSiam 框架总览。(a) 预训练阶段：从同一序列取出一个过去窗口和一个被遮盖的当前窗口，由共享权重的孪生编码器编码，交叉注意力解码器用过去重构当前；编码前会加入一个按两窗口相对距离索引的可学习血缘嵌入（lineage embedding）。(b) 微调阶段：对固定长度输入将多个血缘取平均，对更长输入则逐段拼接以扩展输入长度。

血缘嵌入：一个模型，覆盖多种时间间隔

过去窗口和当前窗口在时间上可能相隔很近，也可能相隔很远，而两者之间的相关性会随这个间隔而变化。若强迫同一个编码器把「回看一步」和「回看上千步」的窗口一视同仁，就会模糊掉有用的信息。TimeSiam 用可学习的血缘嵌入（lineage embedding）来处理这一点：一小组按过去与当前窗口相对距离索引的向量，在编码前加到输入表示上。这样一个模型就能同时表示多种时间间隔，最终表示是这些血缘的集成。微调时，输入长度固定就对血缘嵌入取平均，要适配更长输入就逐段拼接，这让 TimeSiam 能够干净地扩展到比预训练时更长的输入。

效果如何？覆盖 13 个基准的实验

评测覆盖面很广，横跨 13 个基准和两大主流任务。预测涵盖四个 ETT 子集，以及 Weather、Electricity、Traffic 和 Exchange；分类涵盖 EEG 数据集 AD、TDBrain 和 ECG 数据集 PTB。在这些既有基准之外，作者还构建了两个大规模、多领域的预训练语料 TSLD-500M 和 TSLD-1G，其中更大的一个汇集了来自多样、互不重叠领域的 13.9M 条样本，用来压力测试跨领域迁移。

关键数字一致而有力。在域内预测上，相对随机初始化，TimeSiam 用 PatchTST 骨干把平均均方误差（MSE）降低了 5.7%，用 iTransformer 骨干降低了 2.5%，而这些骨干本身从零训练时就已经很能预测。在域内分类上，它把平均准确率提升了 11.5%。在两种设定下，它都胜过 8 个强自监督基线，包括 SimMTM 这类基于重构的方法，以及 TS2Vec、CoST 这类对比方法。下面的散点图让这一规律一目了然：TimeSiam（红色星标）在域内和跨领域两幅图中都独处左上角，也就是同时取得最低的预测误差和最高的分类准确率。




图 3 预测误差（MSE，越低越好）对分类准确率（越高越好）的对比，涵盖域内设定（左）与用 TSLD-1G 预训练的跨领域设定（右）。红色星标的 TimeSiam 在两幅图中都独占左上角，同时在两个坐标轴上领先。

表 1 TimeSiam 相对随机初始化的域内提升（跨基准平均）。

设定	指标	TimeSiam 相对随机初始化
域内预测（PatchTST）	平均 MSE	降低 5.7%
域内预测（iTransformer）	平均 MSE	降低 2.5%
域内分类	平均准确率	提升 11.5%

最引人注目的是跨领域的结果。在大规模、多样的 TSLD-1G 上预训练、再到一个完全不同的目标数据集上微调，有时甚至能超过域内预训练；而在跨领域迁移带来的分布偏移下，TimeSiam 仍是最好的方法。这对实践者是个有用的信号：预训练数据的规模与多样性确有回报，一个在广泛数据上预训练一次的模型，可以在众多下游来源上复用。

适配更长的输入

任何预测模型都会遇到一个现实顾虑：如果在微调时喂给它比训练时更长的历史，会发生什么？更长的输入携带更多信息，但也带来更多噪声，标准模型反而可能随输入变长而变差。由于 TimeSiam 能跨段拼接血缘嵌入，它是原生地适配更长输入，而非退化。下面四个数据集的曲线记录了平均误差随输入长度增长的变化，规律很清楚：从零训练的基线趋平甚至上翘，而 TimeSiam 持续改善。




图 4 在 iTransformer 骨干上微调到扩展输入长度 (96、192、288、384、576)，报告在预测步长 96、192、336、720 上平均的 MSE。随着输入变长，随机初始化训练可能退化，而 TimeSiam 持续降低误差。

消融实验证实了什么

在 Traffic 基准上的消融实验，锁定了哪些设计选择真正重要。用过去窗口重构当前窗口，明显优于单纯的自重构，这验证的是孪生这一核心思想，而不只是遮盖本身。遮盖比例存在一个甜点区，大约在 25% 附近：只遮盖 15% 会让预训练任务太容易，教不了什么；遮盖 75% 又太难，无法引导有用的学习。而血缘嵌入相对随机初始化能带来稳定收益，适当增加数量还会继续改善结果，这证实显式建模若干种时间间隔，值得那一点点额外开销。




图 6 血缘嵌入数量在 ECL 和 Traffic 上的影响，在 input-96 的域内设定下分别使用 1、2、3 个血缘 token。血缘 token 越多，曲线在各预测步长上越低于随机初始化基线，说明建模多种时间间隔确有帮助。

小结

TimeSiam 的贡献更多是一次重新表述，而非全新架构。它把时间序列预训练表述为孪生子序列之间「用过去还原现在」的重构，并给单个模型配上可学习的血缘嵌入以覆盖不同时间间隔，从而精准捕捉到掩码与对比目标所遗漏的相关性。这一框架与骨干无关，能干净地嵌入 PatchTST、iTransformer 和 TCN，其收益还会随更大、更多样的预训练数据而增长。需要诚实指出的边界是：跨领域预训练并不总能胜过域内预训练，因为预训练与微调领域之间的差距依然重要。但作为一种把无标注时间序列转化为强可迁移表示的简单而通用的方法，TimeSiam 为预测与分类都立下了清晰的新标杆。对实践者来说，这套配方很容易上手：在你手头已有的任意无标注序列上预训练一次，把编码器接到标准的预测器或分类器上，再照常微调即可。更广的启示是，预训练任务的设计有时比单纯堆数据规模更重要，而对时间序列而言，最值得学习的任务，正是理解过去如何塑造现在。