

ICLR 2025 | 生成模型为什么会“背下”训练数据？答案藏在几何里

Layer 6 AI 提出流形记忆假说（MMH）：用局部内在维度统一定义、检测并缓解记忆现象，一路验证到 Stable Diffusion

当你在文生图模型里输入「梵高的星空」，得到的究竟是模型「学会」了梵高的风格，还是它原样「背出」了某张训练图？随着扩散模型（diffusion model）越来越强，这个问题不再是学术趣味：模型一旦记住并复现训练数据，就可能泄露隐私、复制受版权保护的作品，把模型的开发者推到法律风险面前。

麻烦在于，整个领域一直缺一把统一的尺子来回答「这张图到底被记住了多少」。过去的定义大多依赖像素空间里到某张最近训练图的距离，这既抓不住更隐蔽的「重构式记忆」（构图、风格被照搬，但不是整张图逐像素复制），也没法在 LAION-2B、Stable Diffusion 这种规模上算出来。

来自 Layer 6 AI、发表于 ICLR 2025 的这篇工作提出了一个干净利落的答案：记忆本质上是一个几何问题。作者提出流形记忆假说（Manifold Memorization Hypothesis, MMH），用一个可测量的几何量——局部内在维度（Local Intrinsic Dimension, LID）——来刻画「一个样本被记住的程度」，并据此把两类成因截然不同的记忆现象干净地分开，最终给出了能一路用到 Stable Diffusion 的检测与缓解工具。




图 1 用局部内在维度（LID）理解记忆的直观示意。浅蓝色是真实数据流形，叉号是训练样本，红色是模型学到的流形。(a) 和 (d) 在数据点周围塌成 0 维的点质量，即发生记忆；(a) 是过拟合驱动（模型维度低于真实维度

$LID_{\theta}(x) < LID^*(x)$ ），(d) 是数据驱动（真实维度本就很低）。(b)、(e) 记住的是 1 维子流形。只有学到 2 维流形的 (c) 才真正泛化、两类记忆都避开。(f) 是拟合很差的模型，此时 LID 与记忆没有有意义的关系。

论 文 : <https://arxiv.org/abs/2411.00113> | 代
码 : https://github.com/layer6ai-labs/dgm_geometry

为什么要换成「几何」这把尺子

流形假说（manifold hypothesis）认为，真实数据其实分布在高维空间里一个低维的流形上。作者的主张是：这套几何恰恰是理解记忆最合适的语言。纯概率的定义需要拿到完整训练集、再抽取海量样本才能估计密度，在 LAION 规模上根本无从算起；而几何视角把记忆和一个已有成熟估计器的量——局部内在维度——挂上了钩，即便是 Stable Diffusion 这样的大模型也能算。

$LID(x)$ 可以直白地理解为样本 x 在其所处流形上的「自由度」个数。如果把维度想成约束：在 d 维空间里每加一条有效约束就减一个自由度，于是 ℓ 条约束对应 $LID(x) = d - \ell$ 。一张被逐像素完美复现的训练图，几乎没有任何自由度，就坐在一个 0 维的「点质量」上——这正是记忆最极端的形态。

同一个「记忆」，其实有两种成因

MMH 的核心动作，是把模型学到的流形 M_{θ} 上的 $LID_{\theta}(x)$ ，和真实流形 M^* 上的 $LID^*(x)$ 放在一起比较。两者的关系恰好切出两类成因完全不同的记忆——这也是本文最有洞见的一刀。

第一类是过拟合驱动记忆（OD-Mem）：模型的局部维度比真实的还低（ $LID_{\theta}(x) < LID^*(x)$ ），也就是模型把本该有多种可能的区域压成了一个点，这是一次实打实的泛化失败。第二类是数据驱动记忆（DD-Mem）：模型其实没学错（ $LID_{\theta}(x) = LID^*(x)$ ），只是这个点的真实维度本来就很低——想想「《神奈川冲浪里》」这种极其具体的提示词，对应的合理输出本就寥寥无几。关键在于，DD-Mem 无法通过比较训练集和测试集的似然来发现，因为它并不是过拟合。

要验证这套框架，第一步是找一个能算出「真实维度」的玩具场景。作者在二维的 von Mises 混合分布上训练扩散模型：真实流形是已知的，因此 LID^* 可以被精确算出，再拿它与模型估计出的 LID_{θ} 相互对照。




图 4 在二维 von Mises 混合分布上训练扩散模型。上图是真实流形与对应分布（一个圆环加一个中心点质量）。下图是模型生成的样本，颜色表示各自估计的 LID_θ ——落在圆环（1 维）上的样本 LID 高，塌向中心点（0 维）的样本 LID 低，与真实几何一致。

从 CIFAR10 看：两类记忆长什么样

把尺度往上抬一档，作者在 CIFAR10 上分别训练了 StyleGAN2-ADA 和 iDDPM 扩散模型。这里能同时看到「精确记忆」（生成图与某张训练图逐像素几乎一致）和「重构式记忆」（构图、主体被照搬，但细节不同）——后者正是像素距离容易漏掉的那一类。而低 LID_θ 的样本，无论属于哪种记忆，都被这把尺子稳稳标了出来。




图5 在 CIFAR10 上可视化 OD-Mem 与 DD-Mem (StyleGAN2-ADA 与 iDDPM)。上排：精确记忆（左）、重构造式记忆（中）的生成样本与其匹配到的 CIFAR10 训练图，以及低 LID θ 但并非记忆的样本（右）。下排是各记忆度量的密度直方图——记忆样本的 LID θ 明显偏低，与非记忆样本清晰分开。

放大到 Stable Diffusion：不用提示词也能查记忆

真正的考验在 Stable Diffusion v1.5。由于真实的 LID* 在这个规模上已无法估计，作者改用三个可扩展的「模型侧」代理量：无条件的 LID θ （用 FLIPD 算法估计）、带提示词条件的 LID $\theta(\cdot|c)$ ，以及此前工作用过的分类器无关引导（CFG）向量范数。他们还证明了一个直觉上很对的不等式：加条件只会让局部维度变小或不变 ($LID^*(x_0|c) \leq LID^*(x_0)$)——这解释了为什么越具体的提示词越容易触发记忆。

在 86 张被标注为「逐字复现」的 LAION 记忆图，与数千张非记忆图（2000 张 LAION-Aesthetics、2000 张 COCO、251 张 Tuxemon）的对照下，三个代理量都指向同一结论：记忆图的 LID θ 一致偏低、CFG 向量范数一致偏高。更重要的是一个新能力——无条件 LID θ 不需要图片的提示词就能把记忆的训练图挑出来，而依赖 CFG 向量范数的旧方法必须先拿到那条提示词才行。




图6 Stable Diffusion 上各记忆度量（LID θ 、条件 LID θ 、CFG 向量范数）在不同数据集上的密度直方图。绿色的 LAION-Memorized（记忆图）分布明显与 COCO、LAION-Aesthetics、Tuxemon 等非记忆数据分离，说明这些几何量能吧记忆图区分出来。

三个代理量各有取舍，下表把它们放在一起看最清楚：

表 1 三种在 **Stable Diffusion** 规模上可用的记忆检测代理量。

代理量	几何含义	记忆图上的表现	需要提示词吗
无条件 LID θ (FLIPD)	模型无条件流形的局部维度	偏低	不需要

条件 LID0($\cdot c$)	给定提示词后的局部维度	偏低	需要
CFG 向量范数	分类器无关引导向量的大小	偏高	需要

既能检测，也能缓解：把记忆归因到具体的词

如果记忆是几何造成的，那缓解记忆的思路就自然浮现：把生成推向局部维度更高的区域。作者把一个可微的记忆度量反向传播，归因到提示词中的每个 token，找出真正「拉低维度」的那几个词，再用 GPT-4 把这些词改写掉。相比随机挑词改写，基于归因的选择在同等记忆下降幅度下能保留更高的图像质量。

作者扫描了改写 token 的数量 $k \in \{1,2,3,4,6,8\}$ ，画出记忆（用 SSCD 相似度衡量，越低越好）与保真度（用 CLIP score 衡量，越高越好）之间的权衡曲线：改的词越多，记忆越少，但保真度也会下降。基于 CFG 分数范数与 FLIPD 的两个新归因度量，效果与 Wen 等人（2023）原本基于 CFG 向量范数的度量相当，而所有基于归因的做法都优于随机改词。




图 7 用 token 归因来诊断并缓解记忆。左：缓解方法的分析——各归因度量 (A^{FLIPD} 、 A^{CFG} 、 $A^{s_{\theta}CFG}$) 都在同等 CLIP score 下取得比 Random 更低的 SSCD 相似度。右：对一个记忆提示词的归因对比，以及原图、生成图与两种改写后的缓解结果，改写后不再逐字复现《神奈川冲浪里》。

一句话记忆点：记忆是几何

这篇论文最值得带走的一句话是：生成模型的记忆本质上是几何的。当模型在某点周围的局部内在维度太小，这个点就被记住了——无论成因是过拟合还是数据本身太简单。既然 LID 在大规模下可估计，我们就能既检测记忆（甚至不需要提示词），又通过把生成引向更高维度的区域来缓解它。

对要把生成模型真正上线的人来说，这套框架的实用价值有两层。其一，无条件 LID0 不依赖提示词，模型方可以直接审计自己的训练集、把被记住的图片筛出来，这件事在过去只要拿不到那条提示词就无从下手。其二，既然标记记忆的那套几何同时指出了走出记忆的方向，token 归因加改写就成了一个轻量的采样期护栏，在基本不损失画质的前提下把记忆压下去。

当然，框架也有它诚实的边界：真实流形维度 LID^* 在大模型上无法直接估计，实际检测依赖的是模型侧的代理量；缓解会带来保真度的折损，需要按 token 数量做权衡；大规模验证依托于已被标注为「逐字记忆」的 86 张 LAION 图，覆盖面仍有限。但 MMH 的价值在于，它把一个长期含糊、争论不休的现象，变成了一个可测量的几何量——这往往是把问题真正推进下去的第一步。

把视角拉远，这篇论文更持久的贡献，或许正是这次「换框架」本身。当一个众说纷纭、难以界定的现象被重述成一个几何量，整个社区就有了共同的词汇和一个可度量的目标。后续工作可以在同一套语言下讨论更好的 LID 估计器、更紧的条件界，或是新的缓解策略，而不必再为「记忆到底指什么」各说各话。