

ICML 2024 | 大视觉模型不必又大又贵：两个经典技巧就够了

悉尼大学、北京理工大学与华为诺亚方舟实验室提出 DeLVM，用数据增强与知识蒸馏，让紧凑的自回归视觉模型在有限数据上学好多任务

语言模型的成功很大程度上建立在一个统一接口上：把一切都变成 token，然后做“下一个 token 预测”（next-token prediction）。最近的大视觉模型（Large Vision Model, LVM）把这套自回归思路搬进了视觉领域——把图像和它的标注拼成一句“视觉句子”（visual sentence），让模型像写句子一样逐个 token 地生成分割图、姿态骨架或去雨结果。这条路很有吸引力：一个模型、一套接口、多种任务。

问题在于代价。目前领先的自回归 LVM 动辄 3B 以上参数，训练要吃掉约 400B 个视觉 token（来自 1.64B 张图像）。这样的规模既昂贵，也很难放到端侧部署。更棘手的是，视觉世界是长尾（long-tailed）的：分割任务数据充足，而关键点检测、去雨这类任务数据稀少。把它们简单混在一起训练，数据多的任务会淹没数据少的任务，模型干脆学不会那些稀有任务。

这篇发表于 ICML 2024 的工作 DeLVM（Data-efficient Large Vision Models）提出了一个直接的问题：我们真的需要这么大、这么多数据吗？作者给出的答案是不需要，而用的两件工具都相当朴素——数据增强（data augmentation）与知识蒸馏（knowledge distillation）。它们在视觉里是老办法，却几乎没人在自回归 LVM 上认真试过。本文正是补上了这一块。




图 1 DeLVM 框架总览。(a) 训练阶段：VQGAN 编码器把图像离散化成 token 序列，因果 Transformer 做下一个 token 预测；(b) 推理阶段：若干“输入-输出”图像对拼成任务提示（task prompt），模型据此续写测试图像的输出，再由 VQGAN 解码器还原成图像；(c) 数据增强把长尾任务补齐到相近数据量；(d) 知识蒸馏用 LLaMA-1B 教师指导紧凑的 LLaMA-300M 学生，推理更省、更快。

论文：<https://arxiv.org/abs/2402.04841> · 代码：<https://github.com/ggjy/DeLVM>

为什么语言模型的训练配方搬不过来

语言模型通常在海量语料上只训练一个 epoch，就能避免过拟合。视觉很少有这种奢侈：许多任务的数据集本来就很小，重复训练几十轮才是常态，语言模型的“一遍过”配方无法直接迁移。与此同时，社区的主流做法仍是把模型和数据集越堆越大。DeLVM 反其道而行：与其收集更多真实数据，不如把手头有限的数据用好——这正是数据增强和知识蒸馏的用武之地。

在方法上，DeLVM 沿用了自回归 LVM 的接口。一张图像先经过一个现成的 VQGAN 编码器，被离散化成 256 个 token；多张图像的 token 顺序拼接，就构成一句视觉句子。因果（causal）Transformer 以交叉熵损失做下一个 token 预测来训练，本质上和训练一个语言模型没有区别。推理时，把几组“图像-标注”对当作任务提示，接上一张待处理的测试图像，模型自回归地生成接下来的 256 个 token，再由 VQGAN 解码器还原成结果图。任务是什么，完全由提示里的示例来定义。

第一招：数据增强，等价于“凭空”补数据

第一个观察很直接：对数据稀少的任务，简单的随机裁剪和翻转带来的收益，几乎等同于真的去收集更多数据。作者用固定 12K 训练步、在 SA-1B 子集和增强后的 COCO-Pose 上训练 LLaMA-300M，对比“加真实数据”与“加增强数据”两条曲线。




图 2 数据增强与引入新数据的效果相当。上排为数据充足的图像分割任务（SA-1B）：随着训练 token 增多，验证损失与困惑度持续下降；下排为数据稀缺的姿态估计任务（COCO-Pose，原始约 0.03B token）：仅靠增强扩充数据，就能复现出与真实新数据几乎一致的下降趋势。

两排曲线几乎重合：对数据充足的分割任务，加真实数据会稳定降低验证损失和困惑度；对数据稀缺的姿态估计任务，只用增强把数据量补上去，也能得到几乎一样的曲线。换句话说，增

强在这里扮演了“廉价的新数据”。这一点很关键，因为它把长尾问题从“去哪里找更多数据”变成了“把已有数据均衡地补齐”。

补齐单个任务之后，真正的考验是把多个任务混在一起训练。作者比较了三种处理数据不均衡的方案：直接用原始不均衡数据训练；对稀有任务做重采样（re-sampling），也就是把少数任务的样本重复多次以凑够数量；以及用数据增强把每个任务都扩充到相近的数据量。三者的差别，可以直接从模型在同一组测试样本上的输出看出来——下图把分割、姿态、去雨三类任务的推理结果并排摆在一起。




图 3 不同均衡策略下的推理结果。菱形为测试输入。在不均衡数据上训练的模型（圆形）明显偏科，只有分割任务做得好；重采样（三角形）反而整体变差；用增强均衡数据（心形）在分割、姿态、去雨三类任务上都给出更干净、更合理的输出。

结论清晰：直接混合会让模型偏科，只擅长数据最多的分割；简单重采样不但没解决问题，反而在稀有任务上崩掉；而用增强把三类任务补到相近的数据量，才在三个任务上同时拿到最好的整体表现。

第二招：知识蒸馏，把大模型的能力搬进小模型

第二个技巧是知识蒸馏——据作者所述，这是首次在自回归 LVM 上引入蒸馏。做法本身很标准：用一个较大的 LLaMA-1B 作教师，指导紧凑的 LLaMA-300M 学生，让学生在训练时不仅拟合真实标注，还要对齐教师的输出分布。真正的疑问在于设定：语言蒸馏里教师给的是词表上的软概率，而这里模型是在“逐 token 生成图像”，教师和学生吐出的是一长串离散视觉 token。在这种生成式设定下，蒸馏还能把教师的能力传给学生吗？下图用单任务训练的结果给出了直观回答。




图 4 单任务训练下的推理结果对比。菱形为测试输入，圆形为 LLaMA-1B 教师，三角形为从零训练的 LLaMA-300M，心形为经蒸馏的 LLaMA-300M。教师结果最好；而带蒸馏的学生（心形）无论在分割还是姿态估计上，都明显比从零训练的同规模模型（三角形）更接近教师。

答案是管用。在单任务和多任务两种设定下，蒸馏都让紧凑学生在分割、姿态估计、去雨三个任务上稳定变好。从可视化看，带蒸馏的 LLaMA-300M 生成的分割图和姿态骨架都更接近 LLaMA-1B 教师，而从零训练的同规模模型则明显更粗糙。在 Pascal-5i 前景分割这个下游基准上，蒸馏加微调的 LLaMA-300M 也明显超过从零训练的版本。

一个容易被忽略的细节：多任务必须打乱训练

论文里还有一个很有教育意义的消融，关于任务数据的排列顺序。如果不把不同任务的数据打乱、而是一个任务接一个任务地顺序训练（先在 SA-1B 上学分割，再到 COCO-Pose 学姿态，最后用 Rain13K 学去雨），模型会发生灾难性遗忘（catastrophic forgetting）：它只在最近训练过的那个任务上表现正常，对更早学过的任务几乎完全失能。作者在表格中报告，早期任务的困惑度会从正常的一百多一路飙升到上千。下图把三个训练阶段的推理结果摆在一起，遗忘的过程一目了然。




图 6 顺序（不打乱）训练不同阶段的推理结果。三行分别对应分割、姿态、去雨三种数据源的测试样本。无论提示指向哪个任务，模型的能力都只集中在它最近训练过的那个任务上——这正是灾难性遗忘的表现，说明多任务 LVM 训练必须打乱数据。

这提醒我们：把多个任务塞进一个自回归 LVM，数据的组织方式和数据本身一样重要。此外，作者还观察到提示的背景色会直接影响生成结果——用黑色背景的提示，能让后续“灰度阈值”这一简单后处理稳定地抽取前景分割掩码。这些看似琐碎的工程细节，恰恰是让紧凑模型真正跑通多任务的关键。

两招叠加：连 80M 的模型都能打

把增强和蒸馏叠在一起，作者进一步做了一个更极端的实验：一个仅 80M 参数的 LLaMA-80M，在这套配方下，据论文报告在 ImageNet 分类上达到了 83.04% 的 top-1 准确率。对一个以“生成”为训练目标的紧凑自回归模型来说，这个数字相当出人意料，也暗示了生成与理解或许可以在同一个模型里一起学。下表汇总了两个代表性结果。

表 1 DeLVM 的两个代表性结果（数据来自论文）。

设置	指标	结果
LLaMA-300M（蒸馏+微调）	Pascal-5i 前景分割 mIoU (split)	18.58 / 21.32 / 19.90 / 21.08

	0/1/2/3)	
LLaMA-80M (增强+蒸馏)	ImageNet top-1 准确率	83.04%
SA-1B 数据 1% → 10%	验证损失 / 困惑度的下降幅度	0.19 / 22.4

意义与边界

DeLVM 传递的信息很清爽：要造一个能干活的自回归视觉模型，未必需要 3B 参数和几百 B 的 token。两个经典技巧——用数据增强来均衡长尾任务，用知识蒸馏来压缩大教师——就能让紧凑模型在有限数据上，于分割、姿态估计、去雨等任务上给出不错的表现。一个 80M 的版本甚至能在 ImageNet 上摸到 83.04%，指向了一条更省、更易部署的通用视觉模型路线。

当然，边界也要说清楚。文中的评测集中在分割、姿态估计、去雨等少数几类任务上，任务面还不算宽；模型仍依赖一个现成的 VQGAN 分词器，其重建上限会限制细粒度输出的质量；83.04% 这一亮眼数字来自特定设置，能否推广到更广的理解类任务仍需更多验证。但作为一份“少花钱、把老办法用对”的研究，DeLVM 给出的方向足够实用：在把模型继续做大之前，先想想手里的数据有没有用满。