

ICLR 2022 | 别再问节点属于哪一类：换个更便宜的问题，图主动学习又准又省

北京大学与 Apple 提出 IGP：用二元查询和软标签，重新定义图神经网络的主动学习

图神经网络（Graph Neural Network, GNN）在节点分类等任务上表现很强，但代价是需要大量带标签的节点，而人工标注既慢又贵。主动学习（active learning）本是缓解这一问题的常规做法：不盲目标注，而是每一轮只挑出最值得标注的节点交给专家。可无论选点策略多聪明，过去几乎所有图主动学习方法都建立在同一个隐含假设上——专家总能一口报出某个节点确切属于哪一类。

问题在于，当类别数很大或领域比较陌生时，这个假设并不成立。以 OGB 里的 ogbn-papers100M 为例，它有 172 个类别；要专家从上百个候选类里精确指出一个节点的确切类别，远超一般标注者的能力，标注预算就在这种高难度的问题上被大量浪费。

这篇 ICLR 2022 的工作换了个思路：与其问「它到底属于哪一类」，不如只问一个便宜得多的二元问题——「它属于（模型猜的）第一类吗？是或否」。这个被放松（relaxed）后的查询给出的不是精确类别，而是一个软标签（soft label）；配套的一个新选点准则，则专门去挑那些「信息增益能沿着图传得最远」的节点。结果是：在同样的标注成本下，精度更高。




图 1 两种标注策略的对比。上方是本文的放松查询：面对模型预测（0.5/0.3/0.2），只问「是否属于第一类」，专家回答「是/否」即可，答案被转成归一化的软标签（如「是」→1/0/0，「否」→0/0.6/0.4）。下方是以往方法：必须让专家直接说出确切类别（ground truth label）。左边的二元问题显然比右边的多分类问题更容易回答。

论文：Information Gain Propagation: A New Way to Graph Active Learning with Soft Labels (ICLR 2022, arXiv:2203.01093, <https://arxiv.org/abs/2203.01093>)。作者来自北京大学与 Apple。

问题：贵的不只是标注，还有「问错了问题」

把标注成本拆开看，会发现两个一直被忽略的浪费点。第一是查询本身的成本：让专家在 c 个类别里指认确切类别，难度和花费大约是回答一个二元问题的 $c-1$ 倍；类别越多，这个差距越大。以往方法却默认「一次精确标注」是最小的成本单位，于是预算天然被高估。

第二是选点准则的视野。以往准则大多沿用为硬标签（hard label）设计的思路，只衡量单个节点自身的不确定性（uncertainty），却忽略了 GNN 的一个本质特性：标注一个节点，监督信号会顺着图结构传播到它的 k 跳邻居。也就是说，一个节点的价值不该只看它自己，而要看它能把信息「照亮」多大一片邻域。

方法：让信息增益沿着图传播

IGP（Information Gain Propagation）把上面两点合到一个闭环里。整个流程在三步之间循环：先用当前已标注节点的软标签训练 GNN（Model Training）；再按新准则挑出这一轮最该标注的节点（Node Selection）；最后对选中的节点发起放松查询，把「是/否」答案转成归一化软标签并更新数据（Node Labeling），如此往复。




图 3 IGP 框架总览。左：用软标签在已标注节点集 V_l 上训练 GNN；中：选点时同时考虑「影响力大小（Influence Magnitude）」与「信息增益（Information Gain）」，二者相乘得到「传播后的信息增益（Propagated Information Gain）」；右：对选中节点 V_b 发起放松查询，得到归一化软标签，再回到左侧更新模型。

选点准则是 IGP 的核心，也是它和以往方法拉开差距的地方。对每个候选节点，IGP 不只问「标它能减少它自己多少不确定性」，而是问「标它之后，它的整个感受野（receptive field）里所有被影响到的节点，加起来能减少多少不确定性」。具体做法分两块：用特征梯度 / 随机游走在 k 层 GNN 上估计一个节点对邻居的影响力大小，再用这个影响力去加权每个被影响节点的信息增益（即熵的下降）。二者的乘积在感受野上求和，就是这个节点的「信息增益传播」值。

于是选点变成一个带预算约束的最大化问题：在标注预算 B 之内，选出使全图传播信息增益之和最大的节点子集。换句话说，IGP 挑的不是「自己最迷糊」的节点，而是「一标下去、能顺着图照亮最多邻居」的节点。

结果：五个数据集、四种骨干网络上的稳定领先

作者在五个标准图基准上评测：三个引文网络 Cora、Citeseer、PubMed，一个大规模社交网络 Reddit，以及 OGB 的 ogbn-arxiv。关键的一点是，预算不再按「标了多少个节点」计，而是按真实的标注成本（金钱）来算——毕竟一个精确多分类查询要比一个二元查询贵 $c-1$ 倍。在每类 20 个标注的同等预算、GCN 骨干下，IGP 在全部五个数据集上都取得最高精度。

表 1 同等标注预算（每类 20 个标注，GCN 骨干）下的测试精度（%）。IGP 相比最强基线 GRAIN，在三个引文网络上提升 1.6–2.2%，在 Reddit 上 +0.9%，在 ogbn-arxiv 上 +0.6%。

方法	Cora	Citeseer	PubMed	Reddit	ogbn-arxiv
Random	78.8	70.8	78.9	91.1	68.2
ALG	83.6	73.6	80.9	92.4	70.1
GRAIN	84.2	74.2	81.8	92.5	70.3
IGP	86.4	75.8	83.6	93.4	70.9

更值得注意的是精度随预算增长的曲线。当标注预算逐步增大时，IGP 的精度爬升得最快，并在每一个预算点上都保持领先——这说明它的优势不是靠某个特定预算「刚好卡对」，而是在整条曲线上都成立。




图 4 测试精度随标注预算变化的曲线（引文网络，GCN）。最上方的粉色曲线为 IGP：从最小预算起就领先，且随预算增大，与其他主动学习基线的差距进一步拉开。

这种领先在不同 GNN 骨干上同样稳健。在 PubMed 上，横跨 SGC、APPNP、GCN、MVGRl 四种骨干，IGP 比 ALG 和 GRAIN 都高出 1.8% 以上，说明「放松查询 + 传播感知选点」的收益并不依赖某一种特定网络结构。

为什么有效：选点更分散，拆掉哪块都会掉分

IGP 为什么更强？一个直观的解释来自它选出的节点在图上的分布。把 Cora 上被选中的节点用 t-SNE 投到二维平面，可以看到它们相当均匀地散布在整个嵌入空间里，而不是扎堆在少数几个区域。传播感知的准则天然偏好那些影响力能覆盖不同邻域节点，因此选出的标注集更有代表性、冗余更少。




图 5 IGP 在 Cora 上所选节点的 t-SNE 分布。彩色点为被选中标注的节点，灰色点为全体节点；被选中的节点铺满整个嵌入空间，覆盖各个区域，体现出选点的多样性与代表性。

消融实验进一步印证了每个部件的作用：逐一去掉一个组件都会掉分。去掉传播感知的选点 (informative selection) 损失最大，PubMed 上最多掉 3.2%、Cora 上掉 2.5%，是最关键的一环；去掉软标签训练 (informative training) 最多掉 2.9%，去掉影响力大小 (information quantity) 最多掉 2.1%，去掉归一化软标签 (normalized label) 最多掉 2.4%。这也说明：真正把 IGP 和别人拉开的，是「传播感知的选点」，而不仅仅是换用软标签。

小结：换个问法，也换个选法

IGP 的配方其实很简洁：把昂贵的「精确多分类」标注，换成一个便宜的二元 yes/no 问题得到软标签；再把选点准则从「谁最不确定」换成「谁的信息增益能沿图传得最远」。两者叠加，让图主动学习在同等标注成本下既更准、又更省，而且这套思路可以接在任意 GNN 骨干之上。

当然也要看清它的边界：软标签由「模型预测 + 专家的一次二元确认」构造，其质量依赖模型当前的预测分布；成本上的优势建立在「二元查询确实比多分类便宜 $c-1$ 倍」这一假设之上，实际收益会随任务和标注方式而变化。但作为一个可插拔的通用范式，「放松查询 + 传播感知选点」给图主动学习指出了值得继续走下去的方向。