

复现挑战 | Graph Edit Networks 大部分成立，但有一个扩展性结论站不住

卢布尔雅那大学的复现研究：重写模型、逐一核对四个实验主张，并追问那几个合成 benchmark 到底测出了什么

在图神经网络（Graph Neural Network, GNN）里，一个不太起眼但很实际的任务是「图的时间序列预测」：给定一个随时间演化的图序列，预测下一时刻的图长什么样。它不是给节点或边打个分那么简单，而是要说清楚从当前图到下一张图，具体发生了哪些结构变化。

标准 GNN 在这里有点力不从心。它们输出的是节点或边的概率分数，而不是「插入一个节点、删掉一条边、给某个顶点改标签」这种能真正把一张图变成下一张图的结构化操作。Graph Edit Network（GEN，图编辑网络）就是为填这个缺口而提出的：它作为 GNN 的输出层，直接预测一段可读的「编辑脚本」。

本文要讲的不是 GEN 原始论文，而是一篇独立复现研究。作者重新实现了 GEN，逐一核对了原文的四个实验主张，并把原论文语焉不详的几个合成数据生成器彻底写清楚。结论是有褒有贬：四个主张里三个站得住，但「反向传播随图规模线性扩展」这一条被推翻了；更尖锐的是，他们发现有几个 benchmark 其实是在奖励模型「记住见过的变换」，而不是真正的泛化能力。




图 1 Edit Cycles 数据生成器产生的三条循环时间序列。每一步的图变换都被写成一段编辑操作 δ （如 ins 插入节点、eins 插入边、del 删除节点），红色箭头即一次「图编辑」。这正是 GEN 要学着预测的目标：不是一张静态图，而是把当前图变成下一张图的那串操作。

论文：<https://doi.org/10.5281/zenodo.6574701>（ReScience C 2022，ML Reproducibility Challenge 2021）

代码：https://github.com/MarusaOrazem/reproducibility_challenge

问题：预测「图怎么变」，而不是「图是什么」

很多真实系统本身就是一张会变的图：分子在反应中断键成键、社交网络里关系此消彼长、逻辑表达式在化简中不断改写。想预测它们的下一步，模型需要输出的是一组结构编辑，而不是一张概率热力图。把「下一张图」硬塞进节点/边打分的框架里，往往既不直观也不好解释。

GEN 的思路是把预测目标换成「编辑脚本」本身。它假设图的演化是马尔可夫式的：下一张图只由当前图决定。于是模型只需为当前图预测一串有限的编辑操作，依次执行后就得到下一张图。

方法：GEN 如何把预测变成一串「图编辑」

GEN 接在一个标准 GNN 主干之后，输出的不再是分数，而是一段编辑脚本。脚本由一套很小的操作词汇构成：插入 / 删除 / 替换一个节点，插入 / 删除一条边。把这串操作按顺序作用到当前图上，就得到下一张图，这正对应它所依赖的马尔可夫假设。

训练信号来自相邻时刻两张图之间的「参考映射」。这些映射通过图编辑距离（Graph Edit Distance, GED）的近似算法得到，因为精确计算 GED 是 NP-hard 的；再把映射转成每个节点的教学信号。复现中训练了两种损失变体（改写的 hinge loss 与 cross-entropy loss），并为大规模引文图额外加了「边过滤」机制，限制每个节点能提出多少条边编辑。对照的 baseline 是一个改造过的变分图自编码器（Variational Graph Autoencoder, VGAE）。




图 2 一次树结构的演化，采样自 Boolean Formulae 生成器：最左侧是逻辑公式 $(x \vee (y \wedge \neg y)) \vee x$ 对应的语法树，之后每一步都是对上一张图的一次逻辑化简。每个 δ 方框列出该步要执行的编辑操作（del 删除、repl 替换）。GEN 要学的就是在给定当前树时预测出这样一段脚本。

复现做了什么：重写代码、写清数据、换一套评测协议

这篇复现的价值不只是「跑一遍看数字对不对」。作者用 Python 重新实现了 GEN，核对代码与原文方法是否一致（过程中还帮原作者修好了一段代码），并把原文只是一笔带过的五个合成数据生成器（DGP）逐一写清楚。这五个 DGP 分两类：动态图系统 Edit Cycles、Degree Rules、Game of Life，以及树结构动态系统 Boolean Formulae、Peano Addition。扩展性实验则用了 arXiv HEP-Th 引文网络（约 27,700 篇论文），从中用滚动时间窗切出 1554 个子图，节点数 $N_G \in [100, 2786]$ 。

他们还指出原实验一个隐患：训练和测试可能落在同一批图上，模型有机会在评测时「重逢」训练时见过的变换。为此作者提出一套更严格的风险估计协议，专门留出 100 张图作为独立测试集，并在这套协议下重跑实验。

结果：四个主张，三个成立，一个被推翻

原论文有四个核心主张：(i) GEN 在三个动态图 DGP 上都胜过 VGAE；(ii) 在树结构 DGP 上达到近乎完美的准确率；(iii) 前向传播随图规模呈亚二次（sub-quadratic）扩展；(iv) 反向传播随图规模线性扩展。复现证实了前三个，但推翻了第四个。

关键证据是运行时间随图规模的对数-对数拟合斜率（斜率小于 2 即亚二次，等于 1 即线性）。前向传播的斜率确实明显小于 2，亚二次成立；但反向传播在两种边过滤方案下的斜率都明显大于 1，也就是超线性（super-linear）。它仍然是亚二次的，但绝不是原文所说的线性。




图 3 运行时间与图规模的关系（横轴节点数 100 → 3k，纵轴运行时间，均为对数刻度）。四个子图分别是 Flexible / Constant 两种边过滤下的前向（forward）与反向（backward）传播。黑线是拟合趋势：前向平缓、亚二次；反向明显更陡，尤其是右下角 Constant.backward，斜率远大于 1，直接否定了「反向传播线性扩展」的说法。

表 1 运行时间对数-对数拟合斜率（5 次重复的均值 ± 标准差）。斜率 <2 为亚二次，=1 为线性。行是两种边过滤方案（Flexible / Constant），列是前向（Forward）与反向（Backward）传播。前向亚二次成立；反向全部大于 1，即超线性，推翻原文的线性主张。

Filtering	Forward	Backward
Flexible	1.38 ± 0.02	1.30 ± 0.01
Constant	1.31 ± 0.02	1.69 ± 0.10

复现的保真度：数字基本对得上

在准确性这一面，复现结果整体令人放心：绝大多数指标都落在原文报告值的一个标准差之内。偏差最大的一处，是 VGAE 在 Edit Cycles 任务上的删除精度与插入召回有所上升，但这并

没有翻盘 GEN 的整体胜出。树结构任务上，Boolean Formulae 准确率为 0.98 ± 0.02 ，Peano Addition 更是达到完美的 1.0，两项都与原文报告高度一致。




图 4 诊断用 δ 箱线图：纵轴是「复现值 - 原文报告值」，红色虚线为 0（完全一致）。这是在 Game of Life DGP、hinge-loss 版 GEN、并采用更严格的风险估计协议和更大测试集下得到的。绝大多数箱体都紧贴 0 附近、偏差在 0.05 以内，说明复现与原文高度吻合。

作者还做了两项稳健性检查。其一，把原实验里随手写的随机图初始化换成成熟的 Erdős-Rényi 模型和 Configuration 模型，所有指标变化都在 0.05 以内。其二，引入前面说的 100 张图独立测试集后，分数只轻微下移，偏移量 $\delta \in [-0.1, 0.05]$ 。结论都指向：原文结果并不依赖某个实验捷径。

更尖锐的追问：这些 benchmark 真的够难吗

真正有意思的是最后一项诊断。作者去采样这些树结构生成器，看它们到底产出什么样的序列，结果发现一个问题：这些生成器绝大多数时候产出的是根本无法再化简的树。在超过 300,000 次采样中，能采到「可化简树」的概率，Boolean Formulae 只有 0.13 ± 0.003 ，Peano Addition 也只有 0.26 ± 0.002 。




图 5 从树结构 DGP 采样得到的时间序列长度分布（boolean 与 peano，行对应最大操作数 3–5）。可以看到分布严重堆在极短序列一侧：大量样本几乎没有可执行的化简步骤。这意味着「近乎完美准确率」的任务，本身可能就没那么有挑战性。

这一发现给「树任务上近乎完美」的漂亮数字打了个问号：如果大部分测试样本本就无需化简，那高准确率更多反映的是任务偏易，而非模型有多强的表达能力。换句话说，模型可能是在重复它已经学会的变换，而不是在泛化。

小结：优雅可复现，但别高估它的扩展性与难度

综合来看，这篇复现给出的评价是有分寸的。GEN 本身是个优雅、可解释、也确实能复现的架构，原文四个主张里三个经受住了独立检验。但复现纠正了其中一个扩展性结论：反向传播是超线性而非线性；同时提醒大家，几个合成 benchmark 让模型「赢在重逢已学过的变换」，而不是真正泛化。

值得一提的是，这份研究里对五个数据生成器的详尽记录，本身可能和它对主张的裁决一样有价值，任何想复用这些 benchmark 的人都能直接受益。作者最后呼吁：对 GEN 这类有潜力的架构，评测应当更严格、更贴近实际用途。