

ICLR 2023 | 图神经网络不只是脆弱，它们还「过度稳健」

慕尼黑工业大学重新审视图机器学习的对抗稳健性：当我们说的「小扰动」其实早已改变了节点的真实标签

关于图神经网络（Graph Neural Network，GNN）有一个流行的说法：它们脆弱得可怕。只需改动几条边，一个看起来很准的模型就会突然改口。过去十年，对抗稳健性（adversarial robustness）研究几乎都把这种脆弱当成全部问题：攻击者做一个微小的、不改变含义的改动，能够守住原有预测的模型才是稳健、可信的那个。这篇来自慕尼黑工业大学、发表在 ICLR 2023 的论文指出，这套叙事悄悄假设了一件我们在图上从未真正验证过的事情：那个「小改动」是否真的保留了节点的含义。

这个假设其实很关键。一个对抗样本之所以「对抗」，前提是它没有改变输入的真实标签；否则，模型改变预测只是对一个真正不同的输入做出的正确反应。对图像来说，人可以扫一眼扰动后的图片，确认它还是一只猫。但图没有这种视觉检查手段，于是社区退而求其次，用一个代理指标：数一数插入或删除了多少条边，只要这个数目不超过 10 预算，就把这次扰动叫作「小」。论文的核心观察是：在真实图上，大多数节点的邻居本就很少，即使是很小的边预算，也足以把一个节点彻底重连；而一旦重连了一个低度数节点，它的真实类别可能早就变了。

这样看，一个死守旧预测的模型，其实谈不上任何好的意义上的稳健。它只是对一个真值已经移动的输入固执地判错。作者给这种失效模式起了个名字：过度稳健（over-robustness），并给出了度量它的工具。他们的核心结论令人不安：所测试的每一个 GNN 都存在显著的过度稳健，而我们平时津津乐道的稳健性，有相当大一部分落在节点语义早已翻转的那一侧。




图 1 在合成的 CSBM 图上，虚线「语义边界」表示：对于给定度数的节点，平均需要多少次边改动才会真正翻转它的真实类别（即最可能的类别）。而每个 GNN（彩色曲线）都要等到远高于这条线时才改变自己的预测——两者之间那片阴影区，就是模型在语义已经改变之后仍然保持的稳健性。

论文：<https://arxiv.org/abs/2305.00851>

为什么「数改了几条边」还不够

图之所以棘手，是因为你没法像看扰动后的图像那样去检查一个扰动后的节点。已有工作试图把「数边」变得更讲究一些，加入一些代理约束——尽量保持度数分布不变、保持同质性（homophily）等等——好让扰动看起来「不易察觉」。但这些启发式都回避了真正定义对抗样本的那个问题：这次改动之后，节点的真实标签还在吗？

这个缺口之所以重要，源于真实图的一个朴素事实：它们由大量低度数节点主导。如果一个节点只有三个邻居，而你的预算允许改动三条边，你就能把它从原来的整个邻域里剥离，再接进一个全新的邻域。此时度数分布看上去毫无异常，节点的真实类别却可能已经改变。因此论文主张，我们需要一个「标签感知」的、对语义保持的扰动的定义——直接追踪真值，而不是指望一个预算去保护它。

一个知道真值的参考分类器

追踪真值的难点在于：在真实数据上，扰动之后我们并没有真值——没人给你刚刚改动过的图重新标注。论文的关键一步，是把可控实验放在上下文随机块模型（Contextual Stochastic Block Model, CSBM）上——这是一类数据生成过程完全已知的合成图。在 CSBM 上，可以推导出贝叶斯最优分类器 g ，它按定义输出给定（可能被扰动的）图下最可能的真实类别。于是 g 就成了「语义到底是什么」的可信参考。

有了参考，过度稳健就有了清晰的定义。取一个模型 f 和一个节点 v ：在干净图上， f 与参考 g 的判断一致；现在在允许的预算内施加一次扰动，如果这次扰动翻转了 g （真实类别确实变了），而 f 仍然保持它原来的预测，那么 f 在 v 处就是过度稳健的——它守着一个如今已经错了的答案。图 2 把这件事画了出来：模型 f 所防守的决策区域（阴影部分）越过了 g 划定的真实边界，而每个节点周围的扰动集合 B 正好跨过了那条真实边界。

这里值得停一下，体会「过度稳健」为什么是个坏消息。常规评估会为一个从不改变预测的模型鼓掌，把它当成最稳健、最可信的那个；但如果它所面对的输入其实早已属于另一个类别，这种「岿然不动」就变成了系统性的判错——而且是被指标伪装成优点的判错。参考分类器 g 的价值，恰恰在于把两种情况区分开：真正应当保持不变的稳健，和早已越过真实边界、本不该再保持的「稳健」。




图 2 (a) 参考分类器 g 画出真实决策边界（实线），模型 f 防守一个更宽的区域（虚线），两者之间的阴影带正是 f 在语义已改变之后仍保持稳健的地方。(b) 每个节点带着一个有限扰动集合 B ；这些「球」跨过 g 边界的地方，就意味着一次「小」改动其实已经改变了节点的真实类别。

要把它变成一个数值，作者为同一个模型比较了两种稳健性。 $R(f)$ 是常规的、经过度数校正的稳健性：相对于节点原始标签， f 在改变预测之前能承受多少扰动。 $R(f, g)$ 是语义感知稳健性：同样的量，但相对于参考 g 来测，因此只统计到语义真正改变为止的那部分稳健性。过度稳健就是常规稳健性中「语义感知版本不予支持」的那部分： $R_{\text{over}} = 1 - R(f, g) / R(f)$ 。取值 0.2 意味着模型所测稳健性中有五分之一属于语义已变之后的稳健。

实验设置

可控实验使用 $n = 1000$ 个节点的 CSBM，其参数被调成模仿 CORA——匹配它的类内与类间期望边数 ($p = 0.63\%$, $q = 0.15\%$, 平均度数 $d = 21$)。一个旋钮，即信号强度 K ，控制节点特征有多大区分度： $K = 0.1$ 时特征几乎是噪声、信号主要由图结构承载； $K = 5$ 时仅凭特征就足够、结构变得多余。对每个 K ，作者采样 10 张训练图，并在每张图上以归纳 (inductive) 方式新增 1000 个测试节点后取平均。合成实验的结论随后在真实图 Cora-ML，以及带社区结构的上下文 Barabási-Albert 模型 (CBA) 上得到印证。

「稳健性」里有多少其实是过度稳健？

第一个结果，是关于威胁模型 (threat model) 本身的，甚至还没轮到怪罪任何模型。在一个常见的按节点预算（度数加二次改动）下，当 $K = 1.0$ 时，99.4% 的目标节点都存在至少一张真实标签已经改变的扰动图。换句话说，标准扰动集合里充斥着根本不保持语义的图——而我们恰恰是在这些输入上给模型的稳健性打分。

第二个结果，是关于模型的。所测试的每一种架构——GCN、SGC、APPNP、GAT、GATv2、GraphSAGE——都存在显著的过度稳健。为了给出一个上界，作者还测了一个 MLP：它完全忽略图结构，因而对边改动天然最稳健；在 $K = 0.1$ 、弱 l_2 攻击下，它表现出 43% 的过度稳健。而每个 GNN 都紧贴着这个上界聚集。图 3 展示了完整的扫描：过度稳健 R_{over} 在低 K 时很高——此时信号靠结构承载，边改动造成的语义破坏最大——并随着 K 增大、特征本身足以决定标签而趋近于零。




图 3 过度稳健 R_{over} 随信号强度 K 变化（横轴从 0.1 到 5.0）。实线为原始模型，虚线为叠加标签传播（+LP）后的模型。(a) 采用按节点度数的预算；(b) 不设预算限制地施加攻击。加入标签传播（虚线）把每条曲线都往下拉，而单独的 LP（浅棕色）位于所有方法的最低处。

一个几乎零成本的修法：标签传播

如果过度稳健来自模型在邻域已变之后仍死守预测，那么一个补救办法，就是在推理时喂给模型它平时忽略的信息：它在训练时早已见过的标签。作者把每个 GNN 的软预测与标签传播（label propagation / label spreading）结合起来，让已知的训练标签沿图扩散开去。图 3 中的虚线就是结果——每个模型的过度稳健都大幅下降，而单独使用标签传播，取得了本研究中所有方法里最低的过度稳健。

关键细节是：这几乎是免费的。加入标签传播不会降低测试准确率，而且在图结构仍然携带有用信号时，往往还会提升真正的对抗稳健性。具体来说，GCN 叠加标签传播后，在 $K = 0.5$ 时过度稳健降到 $R_{\text{over}} = 20.9\%$ 。这一效果在更强的定向攻击下依然存在，只是无法完全消除：在 Netack 下， $K = 0.5$ 的 GCN 仍有 11.4% 的过度稳健，即便是对结构视而不见的 MLP，在 $K = 2$ 时也还残留 19.2%。下面的表格汇总了这些关键数字。

表 1 关键过度稳健数字。过度稳健是指模型所测稳健性中，延续到语义改变之后的那一部分比例。

设置	数值
存在改变语义的扰动的节点比例 ($K = 1.0$ ，度数加二 预算)	99.4%
最大稳健分类器的过度稳健 ($K = 0.1$ ， l_2 -weak)	43%
GCN + 标签传播的过度稳健 ($K = 0.5$)	20.9%
Netack 下 GCN 的过度稳健 ($K = 0.5$)	11.4%
Netack 下 MLP 的过度稳健 ($K = 2$)	19.2%

合成结论在真实图上成立吗？

CSBM 让作者能算出真值参考，但一个始终存在的担忧是：合成的结论会不会只停留在合成世界里。图 4 在真实图 Cora-ML 上回应了这一点：它画出把一个训练好的 GCN 的预测翻转所需的结构扰动次数，并按节点度数分组。低度数节点只需寥寥几次改动就会翻转——正是「小预算即可重连整个邻域」的那种情形，也正是主导真实图的那类节点。论文在 CSBM 上分离出的机制，在没人刻意生成的数据上同样清晰可见。




图 4 在真实图 Cora-ML 上，按节点度数统计翻转 GCN 预测所需的结构扰动次数。低度数节点——在真实图中占绝大多数——只需很少的改动就会翻转，正是「小」预算已足以改变节点真实类别的区间。

为什么这重新定义了图上的稳健性

结论并不是说 GNN 其实没问题，而是说我们的尺子一直在重复计数。我们所测稳健性里有很大一部分是过度稳健——模型在节点真实含义已经改变之后拒绝更新——而常规评估把这种固执当成了好行为。一旦改为相对语义而非原始标签来度量，图景就清晰了：那些看似在攻击一个防守严密模型的改动，对许多低度数节点来说，其实是模型没能跟上的、合理的类别变化。

有两点尤其值得记住。其一，通过标签传播把训练图的标签结构折回推理，是一个廉价而有效的办法，能在不牺牲准确率和真实对抗稳健性的前提下削减过度稳健。其二，作者证明：在语义感知的定义下，以归纳方式给一个新加入的节点分类，根本不存在稳健性与准确率的权衡——我们以为根本性的那种张力，部分只是「相对一个早已移动的标签去度量稳健性」造成的假象。

当然，这一切都依赖于一个可信的真值参考：CSBM 按构造提供了它，真实图却没有，如何把语义感知的评估推广到完全真实的场景，是论文留在桌上的开放问题。对实践者而言，启示也很直接：把小的边预算当成一个需要验证的语义假设，而不是理所当然的保证，并把标签传播当成一个几乎免费、却能削减过度稳健的补充。