

NeurIPS 2023 | 金融大模型的第一套开源三件套：模型、数据与基准

PIXIU 提出 FinMA、FIT 与 FLARE，用领域指令微调让开源小模型在金融 NLP 上超过更大的通用模型

金融文本高度专业，术语密集、语境敏感，一直被认为需要专门的模型来处理。过去几年，NLP 技术在金融场景里快速落地，但真正可用的开源金融大模型几乎不存在。现有的金融预训练模型，如 finBERT、FLANG，参数量普遍低于 1B，泛化能力有限；唯一的大规模金融模型 BloombergGPT（50B）则完全闭源，既不公开权重，也不公开训练数据，而且不具备指令遵循能力。

更关键的是，社区缺的不止是模型。要在金融场景里训练并公平评测一个大模型，还需要另外两样东西：一套金融指令微调数据，用来赋予模型零样本能力；以及一个覆盖真实任务的评测基准，用来横向比较不同模型。这两样此前都没有开源版本，研究者因此被挡在了金融 AI 的开放进展之外。

来自武汉大学、中山大学、西南交通大学、佛罗里达大学与 ChanceFocus 等机构的 PIXIU（发表于 NeurIPS 2023）一次性补齐了这三块拼图：指令微调数据集 FIT、指令遵循的金融大模型 FinMA，以及评测基准 FLARE。下面这张总览图展示了它们如何协同工作。




图 1 FinMA 的多任务、多模态指令微调总览。左侧是为命名实体识别（NER）、情感分析（FPB）、股票走势预测（BigData22）等任务撰写的指令化输入，右侧是 FinMA 对每个任务给出的结构化输出。一个统一模型即可覆盖文本、表格与时间序列等多种模态的金融任务。

论文地址：<https://arxiv.org/abs/2306.05443>；代码与数据：<https://github.com/chancefocus/PIXIU>。模型、指令数据、基准数据集与实现全部开源。

问题：金融 AI 为什么迟迟没有开放基座

指令微调（instruction tuning）已被证明是提升模型零样本能力的关键一步，但金融领域此前没有可用的指令数据，这一步也就无从谈起。与此同时，已有的金融评测基准，如 FLUE、BBT-CFLEB，只覆盖金融 NLP 任务，忽略了股票走势预测这类真正贴近交易场景的预测任务，而后者往往需要同时利用文本与时间序列。

换句话说，社区面对的是一个三重缺口：没有开放的模型，没有开放的指令数据，也没有覆盖预测任务的统一基准。任何一块缺失，都会让金融大模型的研究难以复现、难以比较。PIXIU 的目标就是用开放资源、多任务覆盖、多模态数据把这三块缺口一并补上。

方法：FIT、FinMA 与 FLARE 三件套

第一步是构建数据。PIXIU 收集了五类金融任务的开源数据，涵盖情感分析、新闻标题分类、命名实体识别、问答与股票走势预测，再由领域专家为每类任务撰写多样的任务指令，与数据样本拼装成 FIT 指令数据集。FIT 共含 136,609 条（约 136K）指令样本，横跨 5 类任务、9 个数据集，并且是多模态的，同时包含财报中的文本与表格、以及历史股价这样的时间序列。

第二步是训练模型。作者在开源的 LLaMA 上做多任务指令微调，分别得到 7B 与 30B 两个规模的 FinMA，并额外训练了同时覆盖 NLP 与预测任务的 FinMA-7B-full。第三步是统一评测：FLARE 基准把四类金融 NLP 任务（六个数据集）与一类金融预测任务（三个数据集）放在一起，让 FinMA 与其他大模型在同一把尺子下比较。

结果：开源小模型如何赢过 GPT-4

在 FLARE 上，经过指令微调的 FinMA 在多数金融 NLP 任务上显著超过其他大模型。以情感分析数据集 FPB 为例，FinMA-30B 的 F1 比 GPT-4 高 10%，比 BloombergGPT 高 37%；在新闻标题分类与命名实体识别上，FinMA 同样领先或与 GPT-4、ChatGPT 持平。这说明，把大模型通过指令微调对齐到金融领域，比单纯堆参数更有效。

表 1 FLARE 基准上的部分代表性结果（数值越高越好；“-”表示原文未报告）。FinMA 在情感、标题分类与实体识别上领先，但在需要数值推理的问答任务 ConvFinQA 上落后。

任务（指标）	BloombergGPT	GPT-4	FinMA-7B	FinMA-30B
FPB (F1)	0.51	0.78	0.86	0.88
FiQA-SA (F1)	0.75	-	0.84	0.87
Headline (Avg F1)	0.82	0.77	0.98	0.97
NER (Entity F1)	0.61	0.77	0.75	0.62
ConvFinQA (EM Acc)	0.43	0.60	0.25	0.40

结果也有诚实的另一面。在 FinQA、ConvFinQA 这类需要复杂数值推理的问答任务上，FinMA 明显落后于 GPT 系列。作者指出，这源于底座 LLaMA 在预训练时几乎没有数学数

据，数值推理本就偏弱，指令微调难以凭空补上。这提醒我们，领域对齐能解决「语言理解」，却不能替代基础模型欠缺的推理能力。

规模不是答案：来自消融的观察

把 FinMA 从 7B 放大到 30B，在多数 NLP 任务和股票预测上并没有带来稳定的提升。这说明，对金融指令微调而言，数据的质量与多样性比单纯的参数量更重要。只有在 ConvFinQA 这种强数值推理的问答上，更大的规模才明显有帮助，这与 LLaMA 数学能力随规模增强的趋势一致，但仍不及 GPT-4。

另一个有意思的观察来自 FinMA-7B-full：它同时在 NLP 与预测任务上做了指令微调，结果在 ACL18 股票预测数据集上取得了所有模型中的最好成绩。这暗示，针对预测任务的专门指令微调，可能是让大模型真正走进金融预测的一条可行路径，尽管对所有模型来说，股票走势预测目前都还很难。

结语：一个开放的起点，也标出了边界

PIXIU 的价值在于，它第一次把金融 AI 的三件套完整地开放出来：一个指令遵循的金融大模型 FinMA、一套大规模多任务指令数据 FIT，以及一个覆盖语言与预测的整体基准 FLARE。它用实验证明，经过认真的领域指令微调，一个相对小的开源模型可以在金融语言任务上胜过体量大得多的通用系统。

与此同时，论文也没有回避边界：数值推理型的问答，以及跨所有模型仍然困难的股票走势预测，被清楚地标记为这个领域尚未解决的开放问题。对想要在金融场景里研究或落地大模型的人来说，PIXIU 提供的，是一个可复现、可比较、可继续往前走的开放基座。