

ICLR 2024 | 让混合模型学会「做减法」：平方一下，就能既紧凑又合法

爱丁堡大学、Aalto 大学等提出 NPC²：用平方把「减法混合模型」变成可精确归一化的概率电路，并证明它比只做加法的模型指数级更紧凑

混合模型 (mixture model) 是概率建模里最朴素也最常用的一招：把若干个简单分布（比如几个高斯）按非负权重加权求和，凑出一个复杂分布。这套「加法」思路简单、稳妥，但有个绕不开的代价——如果目标分布本身带有「洞」或者尖锐的结构，纯加法的混合模型就得堆上大量组件，才能把这些洞一点点「填」出来，非常浪费。

一个很自然的想法是：能不能让某些组件去「减」掉一部分概率质量，而不是只会「加」？如果允许做减法，模型往往能用少得多的组件刻画同样复杂的形状。问题在于，一旦允许权重为负，函数就可能取到负值，不再是一个合法的概率分布，学习也随之变得棘手。这正是这篇 ICLR 2024 论文要解决的核心难题。

作者给出的答案干净得出人意料：把整个混合模型平方一下。平方天然保证输出非负，于是权重可以随便取负值；同时，平方后的模型仍然能被精确归一化。作者把这一构造统一地表达在「张量化概率电路」 (tensorized probabilistic circuit) 的语言里，得到所谓的平方非单调概率电路 NPC² (squared non-monotonic probabilistic circuit)，并证明它可以比任何只做加法的单调电路指数级地更紧凑。




图1 把一个 $K=3$ 组件的浅层混合模型 $c(\mathbf{X})$ 平方后得到 $c^2(\mathbf{X})$ 。左边是普通的加法混合：三个组件各配一个权重 w_1, w_2, w_3 。右边是平方之后的等价电路：展开平方会得到所有组件两两相乘的项 ($c_1^2, c_2^2, c_3^2, c_1c_2, c_1c_3, c_2c_3$)，权重变成 $w_i \cdot w_j$ 。组件数从 3 涨到 6，但这些权重全都由原来的 3 个参数共享得到。

论文：<https://arxiv.org/abs/2310.00724>；代码：<https://github.com/april-tools/squared-npcs>

为什么加法混合模型「不划算」

传统混合模型要求各组件的权重非负、且归一化，本质上是把简单分布做「凸组合」。凸组合的每一项都只能往上加概率质量，永远不会互相抵消。这意味着如果你想在密度里挖出一个「洞」——某块区域概率应该很低甚至接近零——加法模型只能靠在洞的周围密集地堆组件、再靠尾部相互压低来近似，效率很差。

让组件相互抵消（做减法）能从根上缓解这个问题：一个能「减」的混合模型，可以用远少于加法模型的组件去刻画带洞、带尖锐结构的分布。但天下没有免费的午餐——负权重会让整体函数在某些点变成负数，而负的「概率密度」是没有意义的。此前能量模型（energy-based model）用指数化来保证非负，代价却是丢掉了可精确归一化这一关键性质；与此同时，信号处理、核方法、量子力学等多个彼此独立的领域，其实各自都重新发明过某种「平方保非负」的技巧，却始终缺一个统一、且可精确归一化的框架把它们串起来。

核心技巧：把混合模型平方

先看最简单的浅层情形。取一个权重不受约束（可正可负）的 K 组件混合 $c(X) = \sum_i w_i c_i(X)$ ，然后对它整体平方： $c^2(X) = (\sum_i w_i c_i(X))^2 = \sum_i \sum_j w_i w_j c_i(X) c_j(X)$ ，其中 $w_i \in \mathbb{R}$ 。平方之后无论权重正负，输出恒为非负，合法性天然成立。

展开这个平方， K 个组件的混合就变成了所有组件两两相乘的「专家乘积」（product of experts）形式，如图 1 右侧所示。关键在于归一化仍然是可算的：配分函数 $Z = \int c^2(x) dx = \sum_i \sum_j w_i w_j \int c_i(x) c_j(x) dx$ ，只要每一对组件乘积的积分有闭式解（很多常见分布族都满足）， Z 就能精确算出。于是对数似然可以写成 $\sum_x \log(c^2(x)/Z) = -|D| \log Z + 2 \sum_x \log|c(x)|$ ，直接用梯度上升做最大似然训练即可。

从浅到深：逐层平方一个张量化电路

浅层平方只是热身。真正的表达力来自深度模型。作者把上面的构造推广到深层、结构可分解（structured-decomposable）的张量化概率电路上：这类电路由输入层、乘积层（Hadamard 积）和求和层（一个参数矩阵）逐层堆叠而成。要平方整个电路，只需要做「逐层平方」——从底向上，对每一层递归地做一次平方即可，最终得到的 NPC^2 仍是一个合法的深层电路，既可精确边缘化，也可精确推断。




图 2 对张量化结构可分解电路的平方，可以归约为对每一层分别平方。(a) 是变量 X_1, X_2, X_3 的区域图 (region graph)；(b) 是据此定义的原始电路，彩色方块分别是输入层、乘积层 ($\otimes$) 和求和层 (矩阵 W)；(c) 是逐层递归平方后的结果。平方层的单元数是原来的平方量级，但每一层仍然只输出一个向量，因此模型整体依然高效。

这里有个容易担心的效率问题：平方之后单元数变成了平方量级，会不会训练不动？答案是不会。虽然平方层内部含有二次方数量的单元，但每一层对外仍然输出一个向量，而不是一个矩阵；配分函数 Z 每个 batch 只需算一次。因此 NPC² 可以像普通神经网络一样用基于梯度的最大似然稳定训练。

看得见的证据：二维密度上的「挖洞」能力

理论说得再好，也要看它在数据上是否真的管用。作者先在二维合成密度上做了最直观的对比——因为二维分布可以直接画出来、用肉眼判断谁拟合得更好。这里有三类模型：普通单调电路 MPC (只做加法)、平方后的单调电路 MPC² (做了平方但权重仍非负)、以及平方后的非单调电路 NPC² (既平方、又允许负权重)。




图 3 在二维连续 (上) 与离散 (下) 数据上，MPC、MPC² 与 NPC² 拟合出的密度。左侧的圆环形分布带有明显的「洞」；连续情形输入层用样条 (splines)，离散情形用类别分布、嵌入 (embeddings, 供 NPC² 用) 或二项分布 (Binomial)。可以看到 NPC² 把同心圆环之间的空隙刻画得最干净，尤其配上参数高效的输入层时优势更明显。

对比很说明问题：单纯做平方 (MPC²) 相比纯加法 (MPC) 已经有所改善，但真正把圆环之间的「洞」干净地挖出来的，是允许负权重的 NPC²。也就是说，带来额外表达力的并不是「平方」这一步本身，而是「负参数」——平方只是让负参数得以合法存在的手段。这一点在离散数据 (下排) 上同样成立。

在标准基准上，同样大小、更高似然

接下来是更严格的定量评测。作者在五个常用的 UCI 多变量密度估计数据集（Power、Gas、Hepmass、MiniBooNE、BDSDS300）上，把 NPC² 与一系列强基线对比，包括归一化流（RealNVP、MADE、MAF、NSF）、全协方差高斯、单调概率电路（EiNet-LRS）以及张量列密度估计器（TTDE）。




图 4 左：在五个 UCI 数据集上，把 NPC² (±²) 与单调电路 MPC (+) 在相同模型规模下逐点对比的散点图，点越暗表示每层单元数 K 越大，蓝色为高斯输入层、红色为样条输入层。位于对角线上方的点，代表在同等规模下 NPC² 取得了更高的对数似然。右：本文模型与不可精确推断（上）和可精确推断（下）两类基线的最佳平均测试对数似然对比表。

散点图里绝大多数点都落在对角线上方，说明在相同参数预算下，NPC² 的对数似然普遍高于单调电路。右侧的表格进一步给出具体数字：在可精确推断的模型里，NPC² 在多个数据集上取得了最好的平均测试对数似然。下面这张精简表列出了几个可精确推断模型的结果，便于快速对照。

表 1 五个 UCI 数据集上，可精确推断模型的最佳平均测试对数似然（越高越好；BDSDS300 上 EiNet-LRS 无结果，以 — 表示）。NPC² (BT) 在 Power、Gas、Hepmass 上取得同类最优。

模型	Power	Gas	Hepmass	MiniBooNE	BDSDS300
Gaussian	-7.74	-3.58	-27.93	-37.24	96.67
EiNet-LRS	0.36	4.79	-22.46	-34.21	—
TTDE	0.46	8.93	-21.34	-28.77	143.30
MPC (BT)	0.57	5.56	-22.45	-32.11	123.30
NPC² (BT)	0.62	10.98	-20.41	-26.92	128.38

需要如实说明边界：优势并非在所有数据集上都同样明显。例如在图像质地类的 BDSDS300 上，TTDE 反而以 143.30 领先；在某些输入本身已很有表达力的离散任务上，NPC² 的领先幅度也会收窄。作者的消融进一步显示：二叉树（binary tree）区域图通常优于线性树（linear tree），连续数据上样条输入层帮助最大，离散数据上嵌入/二项分布比类别分布更重要。

蒸馏 GPT2：逼近一个「不可精确推断」的模型

最后一个实验更有意思：能不能用可精确推断的电路去逼近一个本身不可精确推断的大模型？作者从 GPT2 采样句子，用这些数据训练 NPC² 与单调电路，看谁能更好地近似 GPT2 的分布。作为参照，GPT2 在同一批训练数据上的对数似然大约是 -52。




图5 在由 GPT2 采样得到的数据上，NPC² ($\pm^2$ ，橙色) 与单调电路 (+，蓝色) 的对数似然随每层单元数 K 的变化。曲线为中位数，阴影覆盖 90% 的实验结果。随着 K 增大，NPC² 持续上升并向 GPT2 的参照似然 -52 靠拢，而单调电路很快趋于平台。多数 K 值下，二者在测试数据上的差距是显著的。

结论很清晰：随着模型变大，NPC² 的扩展性明显更好，对数似然稳步逼近 GPT2 自身的水平，而单调电路则较早地停止提升。这意味着在同等规模下，平方非单调电路能更忠实地近似这个本身难以精确推断的语言模型。

小结：让「减法」成为概率建模的一等公民

这篇工作的要点可以用一句话概括：平方，把「减法混合模型」变成了合法、可精确推断的概率模型，而要达到同样的表达力，它所需的组件数比纯加法模型指数级地更少。一个 K 组件的混合平方后，用同一批 K 个参数就编码出约 $(K+1 \text{ 选 } 2)$ 个两两组件——这正是紧凑性的来源，而作者证明了这种相对单调电路的紧凑性差距是指数级的。

更值得一提的是，这套以「平方」为核心、以电路性质为纲的框架，把此前分散在多个领域的负参数模型——密度平方根模型、正半定核模型、以及量子物理里的 Born machine——统一到了同一视角之下。对实践者而言，它把「做减法」从一个零散的技巧，变成了构建紧凑而富有表达力的可精确推断概率模型时可以放心使用的一等工具。