

ICML 2024 | 不再手搓分子网络：一套通用 Transformer 同时学好不变与等变表示

北京大学、微软研究院 AI4Science 提出 GeoMFormer，用两条标准 Transformer 流加 cross-attention，统一几何分子表示学习

用深度学习给分子建模，绕不开一条物理铁律：模型的输出必须和坐标系「转得一样、动得一样」。把整个分子在空间里旋转或平移，它的能量（一个标量）不能变，这叫「不变性（invariance）」；而每个原子受的力、原子的位置（都是三维向量）则必须跟着一起旋转，这叫「等变性（equivariance）」。同一个模型往往既要预测能量，又要预测力和结构，也就是要同时把不变和等变两种表示都学好。

过去几年，为了满足这两条约束，研究者「手搓」了大量专用的几何网络：一些用昂贵的高阶张量运算，一些堆叠受约束很强的等变模块。它们能保证物理正确，但代价是难扩展、表达能力受限，而且大多只擅长其中一类任务。一个自然的问题是：能不能不再一个个手工设计专用模块，而是用最标准、最成熟的 Transformer 组件，搭出一个既通用又灵活、还能同时学好不变与等变表示的框架？

ICML 2024 的这篇工作给出的答案是 GeoMFormer。它的核心思路简单到有点「反直觉」：为每个原子同时维护两套表示，一套不变、一套等变，让它们分别流过两条并行的标准 Transformer 流，再用精心设计的 cross-attention（交叉注意力）模块在两条流之间架桥，让不变与等变信息互相「查阅」对方的上下文。作者进一步证明，许多此前提出的几何网络，其实都是 GeoMFormer 的特例。




图 1 GeoMFormer 的整体架构。左侧为一个 GeoMFormer Block：不变流（紫）与等变流（蓝）并行，各自依次经过自注意力、连向另一条流的交叉注意力（cross-attention）和前馈网络；右侧展开四个注意力模块的计算。

注意等变注意力的分数在三维 Query/Key 上求和得到，从而在结构上保证等变性。

两条物理约束，为什么这么难同时满足

先把问题讲清楚。分子性质预测里，标量量（如能量、HOMO-LUMO gap）要求不变性：无论 you 从哪个角度看这个分子，读数都一样。向量量（如每个原子受的力、弛豫后的原子坐标）则要求等变性：把分子转 30 度，预测出来的力也要跟着转 30 度。普通的神经网络并不天然满足这些约束，硬训是训不出物理正确的结果的。

以往解决办法的通病，是把约束「焊死」在特制模块里。等变操作本身可选项就不多——为了满足等变约束，很多算子被排除在外，于是架构越堆越复杂，只为保证那条物理性质。结果就是：模型专用、难以复用，扩展到大体系时算力吃紧，而且往往是「要么擅长不变、要么擅长等变」，很难两头都强。GeoMFormer 想换一条路：与其发明新算子，不如把 Transformer 这套已经被反复验证的标准组件重新组织一下。

方法：两条标准 Transformer 流，用 cross-attention 架桥

GeoMFormer 为每个原子保留两种 token：一个不变特征向量 Z^I ，一个等变的三维特征 Z^E 。它们分别进入两条并行的 Transformer 流。每条流内部，先由自注意力在原子之间交换信息；关键之处在于等变流——标准注意力被改写成「在三维 Query 和 Key 上逐通道做点积再求和」来计算注意力分数，作者证明这样得到的输出可证明地保持等变性。不变流则沿用普通的标量注意力。

真正把两条流连起来的，是 cross-attention 模块。不变流会去「查询」等变流（Inv-Cross-Attn），等变流也会反过来查询不变流（Equ-Cross-Attn），两者在 Query/Key/Value 的构造方式上各有讲究，但都保证融合后仍满足各自的几何约束。直觉上，这一步让标量信息和向量信息互相补充：能量的预测可以参考几何结构的线索，力和位置的预测也能借用不变特征里的化学语义。每个 block 最后各接一个前馈网络（Inv-FFN / Equ-FFN），再配合标准的 Layer Normalization 和结构编码，堆叠若干层即成。

因为整套设计只用到标准 Transformer 组件的重新排列，作者得以在论文中证明：只要限制或裁掉其中某些模块，Graphormer-3D、Equiformer、TorchMD-Net 等一批已有的几何网络就会「掉出来」成为 GeoMFormer 的特例。换句话说，这不只是又一个新模型，而是一个能把许多现有方法收编进来的统一框架。

证据：一套架构，横扫不变与等变任务

作者在一组刻意「两头都考」的基准上评测 GeoMFormer，既有不变任务，也有等变任务：OC20（Open Catalyst 2020，超过 46 万个吸附质-催化剂复合物）上同时做 IS2RE（初始结构预测弛豫能量，不变）和 IS2RS（初始结构预测弛豫结构，等变）；PCQM4Mv2（约 337 万分

子) 和 Molecule3D (约 234 万分子) 上预测 HOMO-LUMO gap ; 再加上一个五体 N-body 模拟任务考察等变的位置预测。结果是同一套架构在这些任务上普遍达到或逼近 SOTA。

表 1 GeoMFormer 与各任务先前最佳基线的对比 (同时覆盖不变与等变任务)。箭头表示指标方向, ↓ 越低越好, ↑ 越高越好。

任务 / 指标	GeoMFormer	先前最佳基线
OC20 IS2RE 能量 MAE (eV) ↓	0.4141	0.4410 (Equiformer)
OC20 IS2RS ADwT (%) ↑	10.67	8.36 (GemNet-OC)
PCQM4Mv2 Valid MAE ↓	0.0734	O(n²) 模型中最优, 相对降 6.7%
Molecule3D 随机划分 MAE ↓	0.0252	0.0301 (SphereNet)
Molecule3D scaffold 划分 MAE ↓	0.1045	0.1182 (SphereNet)
N-body 模拟 MSE ↓	0.0047	0.0071 (EGNN)

几个数字值得单独拎出来: 在 PCQM4Mv2 上, GeoMFormer 拿到 0.0734 的验证 MAE, 是所有 O(n²) (二次复杂度) 模型里最低的, 相对之前最好的二次模型下降约 6.7%, 同时保持了可扩展到大体系的效率; 在 Molecule3D 上, 随机与 scaffold 两种划分分别相对下降 16.3% 与 11.6%; 而在 N-body 模拟上, MSE 从 0.0071 降到 0.0047, 相对下降幅度达到 33.8%。同一个模型, 既能在能量这类不变任务上压过专用的不变模型, 也能在结构、位置这类等变任务上表现最好。

消融: cross-attention 才是整套设计的核心

一个自然的追问是: 这些提升到底来自哪里? 作者对四个注意力模块逐一做了消融, 最有说服力的发现集中在连接两条流的 cross-attention 上——把它们去掉, 性能会明显下滑。以 N-body 模拟为例, 单独移除任一 cross-attention 模块都会带来可观的性能损失, 两个一起移除时下滑最严重。

表 2 N-body 模拟上对 cross-attention 模块的消融 (其余超参保持一致)。数值为相对完整模型的性能下降, 负号越大表示越依赖该模块。

配置	性能下降
完整模型 (四个注意力模块齐全)	基准
移除 Inv-Cross-Attn	-8.5%
移除 Equ-Cross-Attn	-14.9%
同时移除两个 cross-attention	-21.3%

在更难的 MD17 力场预测任务上, cross-attention 带来的相对提升更大——去掉这座「桥」, 误差会成倍上升。自注意力、前馈网络、Layer Normalization 这些模块也各有贡献, 但把不变流和等变流真正打通的, 正是 cross-attention。这也印证了论文的核心主张: 让两种几何表示互相「看见」对方, 是这套框架有效的关键。

小结：不必再手搓，标准组件也能通吃几何建模

GeoMFormer 想传达的信息很清楚：在物理约束下给分子建模，未必需要一堆一次性的、启发式的专用模块。用两条并行的标准 Transformer 流分别承载不变与等变表示，再用简单的 cross-attention 把它们连起来，一个模型就能同时学好两类表示，并在一大批任务上超过专用架构。由于许多现有方法都是它的特例，GeoMFormer 更像是给几何分子表示学习提供了一条干净、通用、可扩展的设计原则。

当然，边界也要说清楚：这套框架的注意力是 $O(n^2)$ 复杂度，论文强调的是「在二次复杂度模型中最优」，超大体系上的线性化仍是后续问题；本文的实证覆盖了能量、力、结构、粒子位置等多类任务，但主要面向分子与粒子系统，迁移到其他几何领域仍需验证。即便如此，「两条流 + cross-attention」这一简洁范式，已经为后续工作提供了一个很值得沿用的起点。