

FLAb | 深度学习真的能“读懂”抗体好坏吗？

约翰霍普金斯大学构建迄今最大的治疗性抗体基准，把六个蛋白质模型与物理方法 Rosetta 放上同一张考卷

治疗性抗体的研发既贵又慢：一个候选分子往往要在实验室里反复表达、纯化、测稳定性、测结合，才知道它到底行不行。于是很自然地，人们希望用深度学习来提速——先让蛋白质语言模型给成千上万个候选抗体打个分，把最有希望的挑出来再做湿实验。但这条路只有在一个前提成立时才走得通：模型真的能分辨“好抗体”和“差抗体”。

问题在于，这个前提一直没有被认真检验过。抗体设计方法今天常用“原生序列恢复率”这类弱代理指标来评判，可它和真正的治疗潜力关系并不大；而主流的蛋白质适应度基准（CAFA、TAPE、FLIP）要么完全不含抗体数据，要么只放了很小一部分。结果就是：没有人能系统地回答，这些模型到底懂不懂抗体的“适应度”（fitness，即一条序列作为治疗药物的综合优劣）。

针对这一空白，本文提出了 FLAb（Fitness Landscape for Antibodies，抗体适应度图谱）——迄今最大的治疗性抗体设计基准。它汇集了真实的实验测量数据，把六个被广泛使用的蛋白质模型和物理方法 Rosetta 一起考核。先看一组直观的例子：模型有时排序相当准，有时却几乎失灵。




图1 准与不准的两个极端。(a) 在一个热稳定性数据集上，语言模型给熔点更高、更稳定的抗体变体分配了更低的困惑度（perplexity，越低代表模型越“自信”），排序基本正确（ $r = -0.84$ ）；(b) 在免疫原性数据集上，对同样产生 0% 抗药抗体反应（% ADA）的多个药物，模型却同时给出高、低两种置信度，几乎没有分辨力（ $r = 0.48$ ）。

论文与代码：bioRxiv 预印本 <https://www.biorxiv.org/content/10.1101/2024.01.13.575504v1>；开源数据与代码 <https://github.com/Graylab/FLAb>。作者为约翰霍普金斯大学的 Michael Chungyoun、Jeffrey Ruffolo 与 Jeffrey Gray (NeurIPS 2023)。

为什么抗体需要一个“专属”基准

一个能上临床的治疗性抗体，必须同时满足许多相互牵制的要求：要能高效表达、结构足够稳定、不引发人体免疫反应、牢牢结合靶点、不容易聚集、也不能“乱粘”别的东西。这些属性常常此消彼长——改善其中一个，可能拖累另一个。如果模型能可靠地在所有这些维度上给候选分子打分，就有望替代大量昂贵而缓慢的湿实验筛选。

但正因为抗体的评价维度如此特殊，通用蛋白质基准并不适用。随着专门面向抗体的深度学习方法不断涌现，这个领域更需要一个统一、以抗体为中心的基准，先在它上面达成共识，再谈是否可以信任某个模型的预测。FLAb 正是为此而建。

FLAb 是什么：一张更大的“考卷”

FLAb 从 8 项独立研究中，整理出 17 个来自不同抗体家族的突变体图谱（mutational landscape），累计 13,384 条实验适应度测量。它覆盖了定义治疗性抗体的六大可开发性属性（developability properties）：表达量、热稳定性、免疫原性、聚集性、多反应性与结合亲和力。更重要的是，每个属性都对应一个真实的实验单位，而不是抽象打分——这也是 FLaB 能真正检验模型是否“泛化”到抗体各个侧面的关键。

表 1 FLaB 覆盖的六大可开发性属性及其实验单位。按论文的划分，热稳定性、聚集性、多反应性属于“内在”（intrinsic）属性，主要由抗体自身决定；结合亲和力、表达量、免疫原性属于“外在”（extrinsic）属性，还取决于靶点生物学与作用机制。这一区分在后文的结果中非常关键。

属性	实验单位	类型
热稳定性	熔点 Tm (°C)	内在
聚集性	波长位移	内在
多反应性	保留时间 (min)	内在
结合亲和力	解离常数 KD (nM)	外在
表达量	滴度 (µg/mL)	外在
免疫原性	抗药抗体比例 (% ADA)	外在

怎么给抗体打分，又怎么判分

评测方法其实很简单。把每条抗体的可变区序列（或其结构）喂给模型，让模型输出一个在重链和轻链所有残基上平均的“困惑度”（perplexity）。困惑度衡量模型对这条序列有多“惊讶”，所以一个表现良好的模型，应该对高适应度的抗体更自信，也就是给出更低的困惑度。随后，作者把这些分数与真实实验适应度做相关性分析，同时报告三种系数：皮尔逊 r（线性）、斯皮尔曼 ρ（单调）和 Kendall τ（序关系）。

关键的一点是：所有模型都按发布时的原样使用，不做任何微调（fine-tuning）。受测的六个深度学习模型横跨三类架构——仅解码器（ProGen2 系列、IgLM、ProtGPT2）、仅编码器（AntiBERTy）、以及逆折叠（inverse-folding，ESM-IF、ProteinMPNN）——并统一与物理方法 Rosetta 的能量打分对照。

困惑度的定义为 $PPL(s) = \exp(-1/N \sum \log p(x_i | x_{<i}))$ ，即序列平均负对数似然的指数。数值越低，代表模型认为这条序列越“自然”、越有把握。

总览：一张有点“刺眼”的热力图

把“每个模型 × 每个数据集”的结果压进一张图，最直观。下图中每一格的颜色代表该配对的相关强度：蓝色越深，模型的排序越正确、越有用；红色越深，排序越相反、越有害；白色则意味着几乎没有相关性。




图2 所有“模型 × 数据集”配对的表现总览（皮尔逊相关系数 PCC）。为便于比较，聚集、表达、热稳定性三项的相关系数符号已被翻转，使“有用的相关”统一显示为正（蓝色）。可以看到大片的白色与红色——在相当多的数据集上，模型的表现并不优于随机猜测，甚至方向相反。

结论是一记现实的提醒：没有任何一个模型能在全部六个属性上都表现良好；即便是同一个属性，模型的表现也会随数据集大幅波动。若论“夺冠”次数，ProGen2-Small 最多，在 7 个数据集上排名第一；ProGen2-Medium、ProGen2-OAS、ESM-IF 与 Rosetta 能量紧随其后，各在 6 个数据集上居首。换句话说，冠军相当分散，谁也没有全面领先。

拆开来：什么才真正决定表现

一个值得注意的整体趋势是：基于序列的模型，平均而言在全部六个属性上都优于基于结构的模型，其中热稳定性上的差距最大。这暗示，在当前设定下，原始序列信号仍然承载了大部分的预测能力。




图3 序列模型与结构模型的对比（六个属性上的绝对皮尔逊相关系数）。序列模型汇总了 AntiBERTy、IgLM、ProtGPT2、ProGen2 的平均表现，结构模型汇总了 ProteinMPNN、ESM-IF、Rosetta。序列模型在每个属性上都不落下风，热稳定性（Therm.）上的优势尤其明显。

那么，同一个属性为什么有时准、有时不准？一个关键因素是“家族”。当被比较的抗体来自同一个家族（intra-family，往往只差个别点突变）时，模型的排序相当可靠；可一旦要跨家族（inter-family）比较来源不同的抗体，能力就几乎消失。




图4 家族内与家族间的对比。左侧“家族内热稳定性”的相关系数普遍很高，中间“家族间热稳定性”则几乎贴着零线，右侧“家族间聚集性”同样很低。模型更擅长在同一家族内部区分变体，而非跨家族判断优劣。

这一差距在数字上非常悬殊：家族内热稳定性的平均绝对相关系数约为 0.77，而家族间只有约 0.12。类似地，“内在”属性（热稳定性、聚集性、多反应性）平均绝对相关系数超过 0.6，而“外在”属性明显更差——结合亲和力低于 0.4，表达量低于 0.42，免疫原性低于 0.5。也就是说，模型更能读懂由抗体自身决定的性质，对依赖靶点生物学的性质则力不从心。

作者还拆解了另外两个常被关注的因素。其一是架构与训练数据：仅编码器的 AntiBERTy 与仅解码器的 IgLM，都在同样的 558M 条 OAS 抗体序列上训练，二者表现几乎一致，说明架构差异影响有限。其二是参数规模：把 ProGen2 从 151M 一路放大到 6.4B 参数，也只在多反应性和热稳定性两项上带来了明显提升。相比之下，参数量的影响比架构或训练数据更值得关注，但也远非灵丹妙药。

最后一个发现颇具警示意味：语言模型可能被“进化信号”带偏。对临床已获批的 golimumab 抗体，多个语言模型把野生型（wildtype）判为比实际更稳定的突变体还要“优”，而基于物理的 Rosetta 却能正确地把更耐热的突变体排在前面。




图5 进化偏置的一个例子（golimumab 突变体）。左图 ProGen2-XL 给野生型（橙色，熔点较低）分配了最低困惑度，即最高置信度，排序被进化似然带偏；右图物理方法 Rosetta 则正确地给更耐热的变体更高的稳定性评分。这提醒我们：进化上的“常见”并不等于物理上的“更好”。

这项工作告诉我们什么

FLAb 给出的答案坦诚而有用：就目前而言，没有任何一个深度学习模型能在抗体的全部可开发属性上都可靠预测适应度。因此，现在还不能放心地让这些模型独立地去筛选治疗性抗体候选。好消息是，内在生物物理属性已经被捕捉得相当不错，这恰好指明了最难啃的骨头在哪里。

作者认为，最有希望的前进方向，是给这些模型补上它们现在缺的信息：结构、抗原上下文，以及基于物理的先验；同时持续扩充像 FLAb 这样开放的抗体适应度数据集。全部 13,384 条数据都已开源，正是为了让社区能不断把这张“考卷”做得更大、更全。对于任何想用模型加速抗体设计的人，FLAb 至少划清了一条底线：先在真实实验数据上验证，再谈信任。