

ICML 2024 | 让神经网络「知道自己不知道」： 把不确定性看成一次数据压缩

CMU、普林斯顿与索尼 CSL 提出 Distance Aware Bottleneck (DAB)，单模型、单次前向即可给出可靠的不确定性

把一个深度模型真正部署到线上时，最让人不安的往往不是它在测试集上的准确率，而是它遇到「没见过的输入」时的表现：一张与训练分布完全不同的图片、一段异常的传感器读数，模型照样会自信满满地给出一个答案，而且概率还很高。问题在于，标准的深度网络几乎没有「距离感」，它不知道当前输入离自己见过的训练数据有多远。

在概率模型里，这种「距离感」本来是天然存在的。高斯过程 (Gaussian Process, GP) 在远离训练点的地方会自动给出更大的方差，也就是更高的不确定性。但要在大规模深度学习里既可靠又高效地复现这种性质，一直是个没有被很好解决的问题：集成 (ensemble) 和贝叶斯方法确实具备距离感知，却需要多次前向传播，部署成本高昂。

这篇发表于 ICML 2024 的工作给出了一个新的切入角度：把不确定性量化重新表述成一个率失真 (rate-distortion) 压缩问题。作者用一个很小的「码本」 (codebook) 来概括整个训练集，一个新样本离这个码本越远，它的不确定性就越高，而这个距离只需要一次前向传播就能算出来。他们把由此得到的方法称为 Distance Aware Bottleneck (DAB，距离感知瓶颈)。




图 1 一个带噪声回归任务上的 DAB。蓝色是预测均值，灰色是真值曲线，粉色带宽是 DAB 给出的不确定性。可以看到：在训练点（深蓝散点）密集的区域，不确定性带很窄；一旦离开数据、走向曲线两端，带宽迅速变宽。

这正是一个「距离感知」模型该有的行为。

论文：<https://arxiv.org/abs/2406.10775>

代码：https://github.com/ifiaposto/Distance_Aware_Bottleneck

问题：为什么深度网络不「距离感知」

一个可信的模型，应该在「远离自己见过的数据」时表现得更谨慎。高斯过程之所以能做到这一点，是因为它的不确定性直接建立在输入到训练点的欧氏距离之上。而普通深度网络的特征空间没有这种约束，甚至会出现「特征坍缩」（feature collapse）：语义上差别很大的输入被映射到几乎相同的特征，模型自然就分不清「熟悉」和「陌生」。

目前主流的单次前向确定性方法（Deterministic Uncertainty Methods, DUMs）大多依赖架构层面的技巧来对抗特征坍缩，比如谱归一化（spectral normalization）。这些约束一方面可能悄悄损害校准（calibration），另一方面也很难干净地接到一个已经训练好的大模型上。作者想问的是：能不能不靠这些架构约束，让一个单一的确定性模型天然具备距离感知？

方法：把训练集压缩进一个「码本」

DAB 的出发点是信息瓶颈（Information Bottleneck）框架，但把其中的「率」（rate）项换成了率失真理论里一个「有限基数」（finite cardinality）版本的可达率。直观地说，模型不再试图压缩每一个样本的编码本身，而是去学习一小组有代表性的「码」（code）：每个码都是特征空间里的一个分布（质心），它们共同构成一个码本，用来量化、概括所有训练点的编码。




图 2 训练集可以看作高维空间 $\mathbb{R}^d$ 中的一堆点。DAB 做的事情，就是把这一大堆点「压缩」成少量有代表性的分布式码（在论文的 CIFAR-10 实验里只用了 10 个），再用新样本到这些码的距离来度量不确定性。

关键在于「距离」怎么定义。DAB 不用欧氏距离，而是用分布之间的统计距离（这里取 Kullback-Leibler 散度）。一个测试样本的不确定性，就是它的编码分布到整个码本的期望统计距

离： $\text{uncertainty}(x) = E[D(p(z | x), q(z))]$ ，其中 $p(z | x)$ 是编码器给出的分布， $q(z)$ 是码本里的码。样本离码本越远，这个期望距离越大，不确定性越高。整个计算只需一次前向传播。

这套构造和高斯过程有一个很干净的对应关系：码本扮演了 GP 里「诱导点」（inducing points）的角色，统计距离则取代了欧氏距离。换句话说，DAB 相当于把 GP 那种基于距离的不确定性，用一种适配深度网络、且可微可训练的方式重新实现了一遍。训练时，作者在两组更新之间交替进行：用梯度下降更新编码器和解码器，用解析解更新软分配和质心，这一步和经典的 Blahut-Arimoto 算法同源。

实验：单次前向，打平甚至超过集成

作者以 CIFAR-10 作为分布内数据，用 SVHN 作为「远 OOD」（far out-of-distribution）、CIFAR-100 作为更难的「近 OOD」来考察分布外检测能力。值得强调的是，DAB 只用了一个很窄的 8 维隐变量瓶颈和 10 个分布式码。即便如此，在 CIFAR-10 到 SVHN 上 DAB 拿到了 AUROC 0.986、AUPRC 0.994，在更难的 CIFAR-10 到 CIFAR-100 上拿到 AUROC 0.922、AUPRC 0.915，两项任务上都优于包括 5 模型深度集成在内的所有基线。而它做到这一点，只需一次前向传播、约 36.5M 参数（集成约 182M），分类准确率 95.9%，与各基线基本持平。

另一个更能体现「模型是否知道自己会错」的任务是误分类预测（misclassification prediction）：把「模型将要答错」当作正类，看它的不确定性分数能不能提前预警。这里 DAB 的校准 AUROC 达到 0.930，几乎追平 5 模型深度集成（0.951），而把其它单次前向的确定性方法远远甩在身后（SNGP 0.897、DUQ 0.889、DUE 0.856、DDU 0.632）。下表汇总了 CIFAR-10 上各方法的表现。

表 1 CIFAR-10 误分类预测的校准 AUROC（越高越好）。横线上方是需要多次前向的集成方法，下方是单次前向的确定性方法（DUMs）。DAB 在单次前向这一档里明显领先，并逼近昂贵的深度集成。

方法	类型	校准 AUROC
Deep Ensemble (5 模型)	集成 / 多次前向	0.951
DAB (本文)	单次前向	0.930
SNGP	单次前向	0.897
DUQ	单次前向	0.889
DUE	单次前向	0.856
DDU	单次前向	0.632

码本学到的东西也可以直接看出来。作者统计了训练过程中，每个类别的 CIFAR-10 测试样本被分配到哪个质心（分配规则是：选统计距离最小的那个码）。随着训练推进，每个质心会逐渐「吸引」到同一个类别的样本，且所有质心都分到了非零数量的测试点，说明这些码确实有意义地表示数据，而不是退化成少数几个。




图 3 码本的定性可视化。横轴是类别标签（0-9），纵轴是 10 个质心，颜色表示被分到某质心的该类测试样本数量。从 Epoch 1 到 Epoch 200，深蓝格子逐渐收敛成近似一一对应的稀疏结构：每个质心主要吸引某一个类别，说明码本捕捉到了数据的类别结构。

这套方法也能扩展到大规模场景。在 ImageNet-1K 上，基于微调后的 ResNet-50，DAB 在误分类预测上以 0.868 对 0.861 略胜 5 模型集成，在把 ImageNet-O 与 ImageNet 区分开的 OOD 任务上以 AUROC 0.743 对 0.642 明显领先，而可训练参数只有约 36.6M，远少于集成的约 117.7M。需要如实指出的是，此设置下 DAB 的分类准确率（76.1%）略低于集成（78.4%），它换来的是可靠得多的不确定性和小得多的模型体积。

小结与边界

DAB 的核心贡献，是把「不确定性」这件事重新表述成「把训练数据压缩进一个学到的码本」：一旦有了码本，一个单一的不确定性网络就能用「新输入离码本有多远」来衡量自己的不确定性，从而在成本远低于集成的前提下，达到甚至超过集成的可靠性。因为这里的距离是统计意义上的、而非几何意义上的，DAB 给出的是一种统一的、类 GP 的不确定性视角，分类和回归任务都适用。

它的边界也值得记住：DAB 依旧需要在训练中引入码本和率失真约束（论文提供了一个可接到预训练特征提取器上的后验变体来缓解这一点）；在 ImageNet 这类大任务上，它在准确率上会对昂贵集成做出小幅让步，以换取更好的不确定性和更小的模型。对于真正在意「模型什么时候不该被信任」的部署场景，这通常是一笔划算的交易。