

ICLR 2024 | 给表格问答做「降噪」：与其删表格，不如给每个单元格打分

Adobe MDSR Lab 联合 IIT 提出 CABINET，用可微的相关性打分让一个 5.6 亿参数的小模型在三个表格问答基准上刷新 SoTA

让大语言模型读一张表格并回答问题，看起来是它的强项：表格结构清晰，答案往往就写在某几个单元格里。但真正的困难在于「找到那几个单元格」。对于任意一个问题，一张表里绝大多数内容都是无关的，它们对回答没有帮助，却会像噪声一样干扰模型的判断。而 LLM 恰恰对这种无关信息很敏感，表越大、无关内容越多，推理就越容易被带偏。

一个直觉的解法是「先把表格变小再回答」。以 DATER 为代表的方法就是这么做的：先用一个分解器把大表拆成一张小的子表，再让推理模型基于子表作答。问题是，这种「硬分解」不容错，一旦子表选错，有用的信息就被永久删掉了，后面的推理再聪明也无从补救。

来自 Adobe MDSR Lab、IIT Kharagpur 和 IIT Roorkee 的研究者在 ICLR 2024 上提出的 CABINET (Content Relevance-Based Noise Reduction)，换了一个更温和的思路：不删除任何表格内容，而是给每一部分内容学习一个「相关性权重」，把相关的部分放大、无关的部分压低。答题模型始终能看到整张表，只是被引导着去关注真正重要的单元格。




图 1 CABINET 与 DATER 的对比。面对同一个问题，DATER 通过硬分解抽出了错误的子表（丢失了有用信息），导致推理模型答错（38）；CABINET 不显式删除内容，而是给相关的表格部分更高的权重，让 QA LLM 答对（45）。

论文：<https://arxiv.org/abs/2402.01155>

代码：https://github.com/Sohanpatnaik106/CABINET_QA

问题：表格里的无关内容就是噪声

表格把信息组织在行和列里，但对某一个具体问题而言，真正含有答案的往往只是少数几个单元格，其余内容对这个问题来说都是无关的。已有研究表明，大语言模型很容易被这类干扰信息影响，导致表格推理的准确率下降；而且这个问题会随表格增大而恶化，因为大表里携带的无关内容更多。CABINET 要解决的正是这种脆弱性。

相比「硬分解」这种删内容的做法，CABINET 主张用一种软性的相关性加权：所有信息都保留在模型可见范围内，只是被赋予不同的权重。这样即使某个单元格被低估，它也不会像被删除那样彻底消失，模型仍有机会用到它。

方法：给每个 token 打一个相关性分数

CABINET 的整体流程可以顺着下图从左到右读。表格先被线性化成一个带表头标记 ([HEAD]) 和行标记 ([ROW]) 的字符串，与问题拼在一起，经过 QA LLM 的 embedding 层变成一串向量（步骤 1、2）。接着，一个无监督相关性打分器（Unsupervised Relevance Scorer, URS）读取这串向量，为每个表格 token 预测一个相关性分数（步骤 3）。与此同时，一个弱监督的解析语句生成器（Parsing Statement Generator）用自然语言描述「哪些行、哪些列与答案相关」，再由单元格高亮器把它转成一个基于单元格的相关性分数（步骤 4、5）。两路分数线性融合（步骤 6），用来给表格内容加权（步骤 7），最后送入 QA LLM 生成答案（步骤 8）。

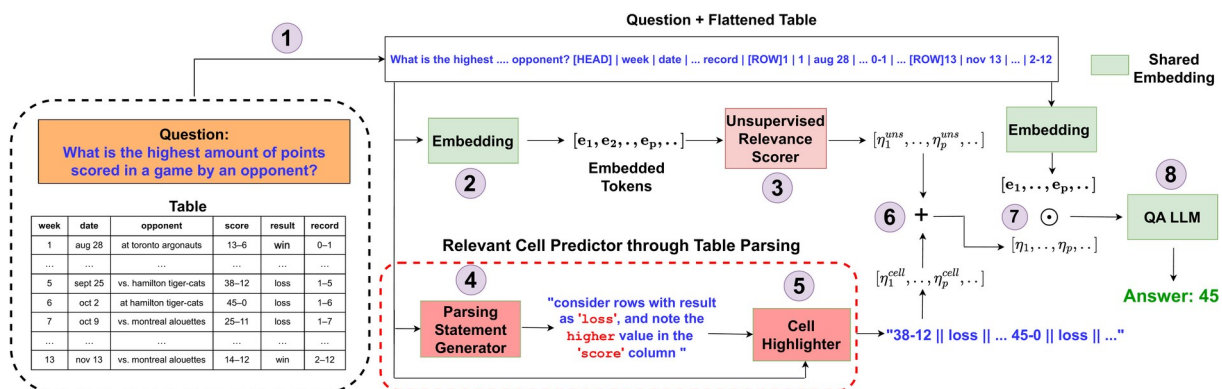


图 2 CABINET 的整体架构。上路是无监督相关性打分器（URS）给每个表格 token 打分；下路是弱监督的解析语句生成器 + 单元格高亮器给出基于单元格的分数。两路分数融合后对表格内容加权，再交给 QA LLM 作答。QA 主干为 OmniTab（5.6 亿参数）。

关键之处在于：没有任何标注告诉模型「哪些单元格是相关的」。CABINET 把相关性当作一个隐变量，用变分推断来估计，并给 URS 的表示空间加了三个损失来塑形：聚类损失（clustering）把 token 分成相关与不相关两簇，分离损失（separation）把两个簇的中心推开，稀疏化损失（sparsification）把无关 token 的分数压向 0、相关 token 的分数推向 1。每个 token 的 embedding 会乘上它的相关性分数，于是噪声单元格被「软性压低」而不是删除，整个系统通过答案生成的交叉熵损失端到端训练。

第二路组件负责补上 URS 可能漏掉的信号。解析语句生成器是一个微调过的 Flan T5-xl，仅用约 300 条人工标注「引导」出来（bootstrapping），它先写出一句判断相关行列的标准，例如「关注 result 为 loss 的行，并看 score 列里更大的值」；单元格高亮器再据此定位对应单元格，得到基于单元格的相关性分数。这一路提供的是「问题层面」的显式线索，与 URS 学到的隐式信号互补。

两路信号如何协同：一个可视化例子

下图用一个「两个半男人（two and a half men）拿了多少奖」的问题，展示了两路信号的分工。URS 会给那些确实与问题相关的行更高的分数（该剧获奖或被提名的行）；但它也会漏掉个别行，比如 2006 年金像奖最佳男主角（喜剧类）那一行。这时弱监督的解析语句模块补上了这些被 URS 忽略的单元格。右下角的 t-SNE 图进一步显示，URS 把表格 token 的隐表示分成了清晰的两簇（红色为相关、蓝色为无关），印证了三个聚类相关损失确实在起作用。

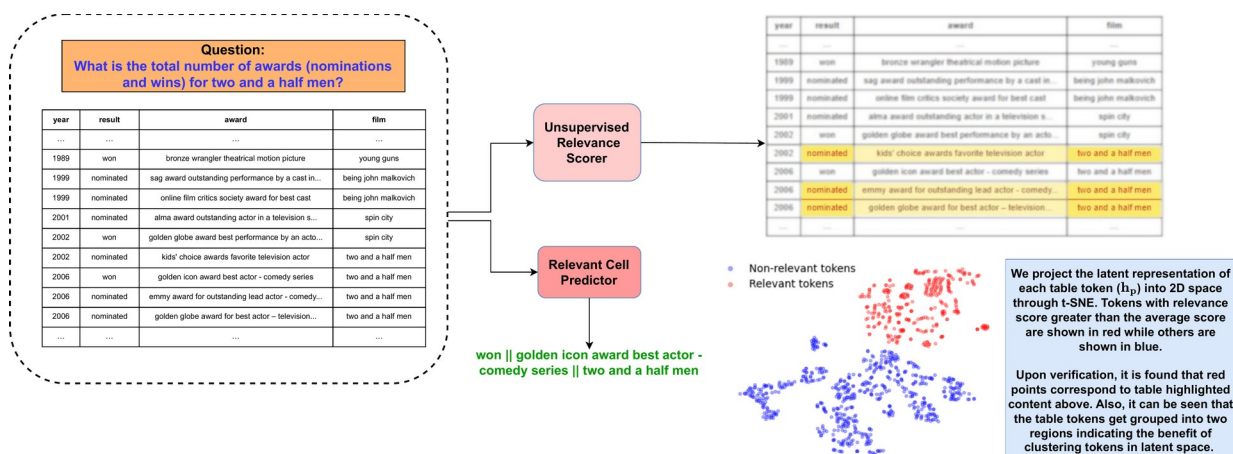


图 5 两路相关性信号的定性可视化。URS 高亮出与问题相关的行（黄色），解析语句模块补上 URS 漏掉的一行（2006 年金像奖最佳男主角，喜剧类）；右下 t-SNE 显示表格 token 的隐表示被清晰地分为相关（红）与不相关（蓝）两簇。

结果：5.6 亿参数刷新三个基准

CABINET 在三个具有挑战性的表格问答基准上评测：WikiTableQuestions (WikiTQ，需要组合推理，短答案，按精确匹配准确率评分)、WikiSQL（同样按准确率评分）、以及 FeTaQA（长的自由文本答案，按 Sacre-BLEU 评分）。作者还额外开源了约 300 条人工撰写的解析语句，用来引导弱监督模块。

在这三个基准上，CABINET 均刷新了 SoTA。尤其值得强调的是，这一切只用了一个 5.6 亿参数的模型（OmniTab 主干），却超过了基于 GPT-3、Codex 的大得多的上下文学习方法。在 WikiTQ 上，它相对 OmniTab、DATER、微调版 Flan T5-xl 分别领先 6.4、3.2、4.7 个百分点。

表 1 CABINET 在三个基准上的主要结果（均为新 SoTA）。

基准	评测指标	CABINET	相对最强基线
WikiTQ	精确匹配准确率	69.1%	较 OmniTab +6.4
FeTaQA	Sacre-BLEU	40.5	新 SoTA
WikiSQL	精确匹配准确率	89.5%	新 SoTA

不只是更准，还更抗噪

软加权带来的另一个好处是鲁棒性。作者对表格做了几种扰动：行添加（RA）、行置换（RP）、列置换（CP）、单元格替换（CR），再看模型性能相对下降多少。下图对比了 CABINET 与 OmniTab 在 WikiTQ 上的表现：在每一种扰动下，CABINET 的性能下降都明显更小。以最剧烈的行添加为例，OmniTab 掉了 18.89%，而 CABINET 只掉 11.46%。作者还观察到，随着表格变大，CABINET 相对基线的优势依然保持。




图 3 表格扰动下的相对性能下降（%），WikiTQ。RA 行添加、RP 行置换、CP 列置换、CR 单元格替换。绿色为 CABINET，红色为 OmniTAB；每种扰动下 CABINET 的性能下降都更小，说明它对噪声更鲁棒。

消融：两个组件缺一不可

消融实验确认了两点。第一，URS 的三个损失必须一起用才有效：同时施加聚类、簇心分离、稀疏化损失，能把 WikiTQ 准确率从 60.8% 提升到 65.6%，而任意子集带来的提升都有限。第二，两路相关性信号需要融合：把无监督分数按权重 0.7、单元格分数按权重 0.3 组合是最优的（69.1%）；如果只用单元格信号（ $\lambda_{uns}=0$ 、 $\lambda_{cell}=1$ ），准确率会崩到 37.6%。这说明无监督打分器是主要驱动力，解析语句模块是互补的辅助。

表 2 融合两路相关性信号的消融（WikiTQ）。无监督分数权重 λ_{uns} 与单元格分数权重 λ_{cell} 的不同组合。

λ_{uns}	λ_{cell}	WikiTQ 准确率
1.0	0.0	65.6%
0.7	0.3	69.1% (最优)
0.5	0.5	68.6%

小结

CABINET 的核心启示是：要回答关于一张表的问题，你并不需要先把表裁小。通过给每个单元格学一个相关性分数并做软加权，而不是硬分解、冒着丢失有用信息的风险，模型既能保留对全部数据的访问，又能被引导到真正重要的地方。把一个可微的无监督相关性打分器，和一个弱监督的解析语句单元格高亮器结合起来，比以往「删内容」的方法更准、也更抗噪，用一个 5.6 亿参数的紧凑模型就在三个表格问答基准上刷新了 SoTA。

当然，这套方法也有它的边界：URS 的相关性是无监督学出来的，弱监督模块依赖那约 300 条解析语句的引导，实验也主要围绕英文表格问答任务展开。但「软加权优于硬删除」这个思路，对于任何需要在噪声中定位少量相关信息结构化推理任务，都值得借鉴。