

NeurIPS 2023 | 让网络对尺度变化「真正」等变，误差精确为零

普渡大学用 Fourier 层重建每一层网络，使「缩放图像」和「跑网络」两个操作严格可交换，而不再只是近似成立

一只猫无论占满整个画面，还是远处几个像素的小点，它都还是一只猫。我们希望视觉网络也能这样：物体缩小，提取到的特征应当随之缩小，而预测出的类别保持不变。这一性质叫做尺度等变（scale-equivariance）。一类尺度等变 CNN 为此在一组不同尺寸的卷积核之间共享权重，用「同一个核、缩放到不同尺度」的方式来逼近它。问题很微妙但影响不小：这些方法是在连续域（continuous domain）里推导出来的，真正落到像素网格上实现时才做离散化，而离散化这一步会「漏」。最终得到的网络只是近似尺度等变，始终带着一个不大却顽固、怎么调都到不了零的误差。

普渡大学发表在 NeurIPS 2023 的这篇论文提出，这个残余误差不是调参问题，而是建模问题。对离散信号做降采样本质上是一次信号处理操作，而信号处理对此有一条硬规则：在丢弃采样点之前必须先做低通滤波，否则高频会「折叠」进低频、污染结果。连续域的推导里根本没有给这个抗混叠（anti-aliasing）滤波器留位置。论文的做法是：直接在离散域里定义降采样，从第一步就把抗混叠内建进去，再把网络的每一个组件都重建成遵守这条规则的 Fourier 层。回报是一族真正尺度等变的深度网络，端到端等变误差精确为零，靠的是构造本身而不是运气。




图 1 为什么普通 CNN 只是近似尺度等变。把一张高分辨率数字和它「理想降采样」后的版本送进同一个 CNN，得到的两张特征图并不一致（上、下两路，红叉标出）。我们真正想要的是反过来成立：对高分辨率特征做降采样，应当精确还原出直接由低分辨率输入算得的特征。构造一个满足这一点的网络，正是本文的目标。

问题：不够精确的「等变」

尺度等变的意思是：如果你缩放输入，网络的内部特征会以对应方式一起变换，而最终类别保持不变。近期的尺度等变网络，比如 SESN、DSS、DISCO，都通过跨尺度共享权重来追求这一点：同一个核缩放后作用在每个尺度上。在连续域里看，这个思路很干净。但真实图像活在离散网格上，连续核必须被采样，而这一采样又把连续数学从不需要操心的混叠（aliasing）重新引了回来。结果就是一个可测量的等变误差，在论文的表格里大约是零点几，这意味着这些方法所宣称的保证，实际上只近似成立。

论文的诊断是：缺失的关键一环是抗混叠。奈奎斯特采样定理（Nyquist sampling theorem）指出，当你对离散信号降采样时，必须先去掉更粗网格已无法表示的那些频率；跳过这一步，高频就会混叠进低频，就像电影里马车轮子看上去在倒转的那种效应。因为此前的工作是在连续域里做降采样的，就没有一个自然的位置来插入这个滤波器。而没把它处理对，恰恰就是那个残余误差的来源。

核心思路：先把降采样定义对，再服从一条频率规则

作者先把「降采样到底该是什么」钉死。他们将其定义为理想降采样（ideal downsampling）：先施加一个理想低通滤波器，把高于新网格奈奎斯特上限的所有频率清零，然后再抽样。图 2 把这个滤波画成频域里的逐点相乘——滤波器保留一段低频、丢掉其余部分。有了这个定义，抗混叠就不再是补在连续推导后面的马后炮，而正是网络所要等变的那个操作的定义本身。




图 2 理想降采样即频域滤波。信号频谱 X 与一个理想低通滤波器 H 逐点相乘， H 在一段低频上取 1、其余处取 0，最终只留下被保留的低频（ $H \odot X$ ）。在抽样之前先去掉高频，正是此前连续域方法无处安放的那一步抗混叠。

由这个定义出发，论文推导出它的核心条件，即 Claim 1：在理想降采样下，一个深度网络尺度等变，当且仅当每个输出频率只依赖于相等或更低的输入频率。直观地说，信息可以从低频流向高频，但绝不能反过来，这样一来「丢掉高频」这一步就能和「跑这一层」相交换。这条唯一

的规则——一个输出频率只读取相等或更低的输入频率——就成了每一层都必须满足的设计约束。

把网络重建为 Fourier 层

要强制这条频率规则，就得把每个标准组件重新设计。卷积变成一个空间局部（spatially-local）的 Fourier 层：它在频域里运算，却约束自己的核使学到的特征保持空间局部性，从而既保留了 CNN 那份有用的归纳偏置，又服从依赖结构。非线性逐频带施加，避免把高频重新混回低频。池化同样在频域里重新表达，以保持相同的结构。在这个等变特征提取器之上，是一个逐尺度分类器（per-scale classifier），它在每个尺度各预测一次，并通过 Fourier 零填充在各尺度间共享同一个 MLP。由于所有运算都在频域进行，每层的代价约为 $|A| N \log N + K N$ ，让整个设计保持实用。

还有一块拼图把预测质量和尺度绑在一起。作者加了一项 hinge 一致性损失（consistency loss），只要某张高分辨率图像被预测得比它自己降采样后的版本还差，就对模型施加惩罚。直觉很简单：更高的分辨率不该反而更差，于是这项损失促使高分辨率预测至少不弱于粗分辨率预测，在架构已经保证的精确等变之上，再鼓励出尺度一致的行为。

结果：误差精确为零，且越难的场景收益越大

模型在两个标准尺度等变基准上评测：MNIST-scale（分辨率从 8×8 到 28×28 ）和 STL10-scale（从 48 到 97），对比的基线包括 SESN、DSS、SI-CovNet、SS-CNN、DISCO 以及一个普通的 Fourier CNN。在理想降采样、覆盖全部尺度的 MNIST-scale 上，它取得 0.9889 的准确率和 0.9716 的尺度一致性，在每一项指标上都最好；而最关键的是，等变误差精确为 0.00，而 DISCO 这样的强基线仍有约 0.44。这个零不是四舍五入的结果，而是由构造保证的。

表 1 理想降采样（全部尺度）下 MNIST-scale 的准确率、尺度一致性与等变误差。本文模型在每一项指标上领先，其等变误差由构造精确为零，而最强的基线仍保留可测量的残余误差。

模型	准确率 $\uparrow$	尺度一致性 $\uparrow$	等变误差 $\downarrow$
CNN	0.9737	0.6621	—
SESN	0.9791	0.6640	—
DSS	0.9731	0.6503	—
DISCO	0.9856	0.5585	0.44
Fourier CNN	0.9713	0.2421	0.28
Ours	0.9889	0.9716	0.00

在更难的基准上，这个优势进一步拉开。在 STL10-scale 这个近似方法普遍吃力的自然彩色图像基准上，模型取得 0.7332 的准确率，而次好的 Fourier CNN 只有 0.5844，领先约 15 个百分点，且等变误差依然为零。它在非理想降采样下也退化得很平缓：当抗混叠滤波器不完美、出现 Gibbs 振铃时，它仍是最好的模型，准确率 0.9880、尺度一致性 0.9760，误差仅 0.05。它还是这组方法里最省数据的：在 MNIST-scale 上仅用 1000 个训练样本就达到 0.9606 的准确率，而 DISCO 为 0.9457。

一组特征可视化让人直观看到这些等变层到底学到了什么。无论理想还是非理想降采样，模型的特征图都勾勒出空间局部的结构——每个数字的轮廓和边缘，而不是普通 CNN 产生的那种弥散、依赖分辨率的模式。空间局部 Fourier 卷积确实在做它被设计出来要做的事。




图 3 理想（上方各行）与非理想（下方）降采样下学到的特征。从输入数字出发，模型在两种设定下都产生突出空间局部结构——数字轮廓与边缘——的特征图，说明空间局部 Fourier 卷积在保持精确尺度等变的同时，保留了类似 CNN 的归纳偏置。

消融：一致性损失确实有用

为验证一致性损失是在真正起作用、而不是搭个便车，作者把它去掉后在若干训练集规模上重训。准确率和尺度一致性在每个规模上都下降：5000 个样本时尺度一致性从 0.9296 掉到 0.9150，2500 个样本时从 0.8906 掉到 0.8633。这项损失稳定地改善了尺度一致性行为，因此保留在最终配方中。作者还指出，如果把非线性直接放到频域里施加，虽然能保持等变，却会损害分类效果，这也是他们改用空间域尺度等变非线性的原因。

结语

最值得记住的一点是：把尺度等变当作一个信号处理问题来对待。一旦你把降采样定义为理想的、带抗混叠的降采样，并要求每个输出频率只读取相等或更低的输入频率，就能用 Fourier 层拼出一个精确尺度等变的网络——误差在可证明的意义上为零，而不是像早期方法那样拖着一条小尾巴。而且这个保证并非以准确率为代价换来：模型追平或超过此前的尺度等变 CNN，并且明显更省数据，收益最大的恰是更难的自然图像场景。需要如实说明的边界是：精确为零的保证成立于理想降采样这一设定；在非理想降采样下会回来一个小误差，尽管模型依然领先。把离散信号处理这一步做对，正是把近似等变变成精确等变的关键。