

权重不必对称：Jacobian 稳态让平衡传播第一次跑上 ImageNet

ICLR 2024 · Friedrich Miescher 研究所与巴塞尔大学解耦并消除了平衡传播的两类梯度偏差

训练深度网络时，我们几乎默认要用反向传播（backpropagation）。但反向传播需要一条独立的线性反向通路，还要用到每个权重矩阵的精确转置，这在真实的物理神经系统里几乎无法实现。平衡传播（Equilibrium Propagation, EP）是一条颇具吸引力的替代路线：它属于基于能量的方法，只依靠网络自身朝平衡点弛豫的动力学来估计梯度，非常契合大脑或模拟/神经形态芯片这类物理载体。

问题在于，经典 EP 有两个近乎苛刻的前提。第一，权重必须严格对称，即前向连接与反向连接一一相等（ w_{ij} 等于 w_{ji} ）；第二，把网络推向目标的「nudge」教学信号必须无穷小。两者在真实硬件上都很难满足。更棘手的是，权重不对称到底会不会伤害学习，此前一直没有定论，因为它的影响总是和有限 nudge 带来的误差纠缠在一起，无法单独观察。

这为什么现在值得认真对待？答案是能耗。无论是生物大脑还是神经形态芯片，物理神经系统训练网络的能量成本都可能远低于数字硬件。而 EP 的非对称版本此前只在 MNIST 这类小任务上成功过，一到 CIFAR-10 就直接失败，且没人解释清楚原因。本文（ICLR 2024，作者 Axel Laborieux 与 Friedemann Zenke）把两类偏差干净地分开，并逐一消除：有限 nudge 偏差用一个 Cauchy 积分精确去除，权重不对称偏差则用一个作用在 Jacobian 上的「稳态损失」来抑制。结果是，非对称网络第一次被训练到了 ImageNet 32×32，且与理想对称情形只差很小一截。

论文与代码链接：arXiv 论文见 <https://arxiv.org/abs/2309.02214>。

背景：EP 为什么依赖对称，又为什么难分析

EP 的做法是让网络先在无教学信号时弛豫到一个「自由不动点」，再施加一个小 nudge 把输出往目标拉，比较两次平衡态，就能读出每个神经元应当承担的误差。这套推导成立的关键，是网络平衡点处的 Jacobian 对称——只有对称时，弛豫动力学隐含地完成了反向传播所需的转置操作。一旦前向与反向权重脱钩，Jacobian 就带上一个反对称分量，弛豫算出的误差方向随之偏离真正的梯度。




图 1 三类网络及其自由相后的 Jacobian：a) 能量型网络权重对称 (w_{ij} 等于 w_{ji})，Jacobian 对称；b) 前向、反向连接独立，Jacobian 不对称；c) 前馈网络的 Jacobian 为下三角。本文关注中间这种「有反馈但不对称」的情形。

但在实践中，这份偏差很难单独测量：只要 nudge 是有限大小，它本身就会引入另一种偏差，把权重不对称的贡献盖住。于是「非对称到底有多大害处」长期是一个悬而未决、也未被解释的失败模式。本文的第一步，就是把这两类来源在解析上彻底拆开，分别处理。

方法之一：用 Cauchy 积分精确消除有限 nudge 偏差

第一类偏差来自有限 nudge。作者沿用并推广了「全纯 EP (holomorphic EP, hEP)」的思路：把教学信号写成一个随时间振荡的复数信号 $\beta(t)$ ，再用复分析里的 Cauchy 积分，从网络的振荡响应里精确地把想要的导数还原出来。这一步的漂亮之处在于，无论 nudge 多大、也无论 Jacobian 是否对称，它都能给出无偏的误差估计；而且积分可以在多个振荡周期上连续估计，网络不必再切换「自由相」和「nudge 相」两个阶段。

读下面这张图时，可以先盯住两件事：一是曲线离黑色虚线（真实导数）有多近，二是它在教学幅度 $|\beta|$ 变大时掉得有多快。灰色的经典 EP 一旦 nudge 变大就迅速失真，而 Cauchy 积分估计 (hEP) 即便在大 nudge 下也几乎贴着真值。右侧两栏进一步说明，这个误差向量甚至可以在网络的连续振荡中在线读出，无需分相。




图2 分离有限 nudge 与 Jacobian 不对称两类偏差。a、b) 在对称与非对称 Jacobian 下，RBP 误差向量与经典 EP (灰)、全纯 EP (N=2 与 N=10) 所得误差向量的余弦相似度，随教学幅度 $|\beta|$ 的变化；经典 EP 随 nudge 增大迅速偏离黑色虚线代表的真实导数，hEP 则一直贴近。c、d) 两层 MLP 中余弦分布的核密度估计，随不对称与深度增加而变差。e、f) 由振荡信号在连续时间中在线估计自由不动点与误差向量。

方法之二：用稳态损失直接压低 Jacobian 的不对称

第二类偏差来自权重不对称。作者先给出一个定量刻画：误差的偏差随 Jacobian 反对称分量 A 线性增长，写成 $d_\beta u^* = \delta - 2S^{-1}A\delta + o(\cdot)$ ，其中 δ 是真正想要的误差向量， S 是 Jacobian 的对称部分。既然偏差正比于 A ，一个自然的想法就是直接把 A 压小。

为此作者提出一个「稳态损失 (homeostatic loss)」，它只惩罚 Jacobian 的反对称部分，可以用 Hutchinson 迹估计配合高斯噪声高效计算，再按系数 λ_{homeo} 加到交叉熵上一起训练。它的形式是 $L_{\text{homeo}} = E\|J_F \varepsilon\|^2 - \varepsilon^T J_F^2 \varepsilon$ (ε 为标准高斯噪声)。关键在于，这个损失作用在 Jacobian (也就是网络的「功能对称性」) 上，而不是强行让权重本身相等——因此即使是完全没有互反连接的结构也同样适用。

下面这张图从训练动力学的角度验证了这一点。上排用 RBP (近似反向传播) 训练，下排用 hEP 的精确误差 $d_\beta u^*$ 训练。值得对比的是：只有下排在训练中会主动让前向、反向权重的夹角变小 (即向对称靠拢)，而且训练损失对初始夹角敏感；上排则几乎不改变权重夹角。这说明 EP 的误差信号本身会推动网络走向更对称的功能状态。




图3 两层 MLP 在 Fashion MNIST 上的训练动力学，上排用 RBP、下排用 hEP 的精确误差 $\delta_\beta u^*$ 。a、b) 不同初始夹角下前向与反向权重夹角的演化；训练倾向于减小不对称。c、d) 学习曲线，只有 hEP 的训练损失依赖初始夹角。e、f) RBP 与 hEP 误差向量之间余弦相似度随训练的变化。

关键结果：稳态损失让非对称网络逼近对称上限

把两件事合起来——用 Cauchy 积分去掉 nudge 偏差、用稳态损失压低 Jacobian 不对称——非对称网络的表现发生了质变。下图给出三种不同结构（互反连接的多层网、输出直接回接首层的网、以及用于 CIFAR-10 的循环卷积网）在训练中的验证误差、Jacobian 对称度和逐层误差对齐度。共同的规律是：加了稳态损失（深红）后，Jacobian 对称度稳步上升，hEP 与 RBP 的误差向量逐层对齐，验证误差随之明显下降。




图4 稳态损失通过直接作用于 Jacobian 改善 hEP 训练。每一行对应一种「结构—数据集」组合：a–d) 互反连接的多层网在 Fashion MNIST 上的验证误差、Jacobian 对称度与逐层误差余弦；e–h) 输出层直接回接首层的结构；i–l) 用于 CIFAR-10 的循环卷积结构的验证误差、权重夹角与逐层误差余弦。深红为加入稳态损失，灰色为未加。

数字最能说明问题。在 CIFAR-10 上，不加稳态损失的非对称 hEP 只有 60.4% 的准确率；加入稳态损失后跃升到 84.3%，与完全对称的结构相比只差 4.3 个百分点，而这一切只需要近似的权重对称。更重要的是，这是该类方法第一次在 ImageNet 32×32 上训练成功，达到 31.4% 的 Top-1 与 55.2% 的 Top-5。下表汇总了几种变体在三个数据集上的 Top-1 准确率。

表 1 非对称网络用 hEP（本文）与 RBP 训练所得的 Top-1 验证准确率（%），三次随机种子平均。

方法	CIFAR-10	CIFAR-100	ImageNet 32×32
hEP (无稳态损失)	60.4	35.2	—
hEP (N=2, $ \beta =1$)	81.4	51.1	—
hEP (精确 $d_\beta u^*$)	84.3	53.8	31.4
RBP (近似反传)	87.8	60.8	—
对称 hEP (上限)	88.6	61.6	36.5

消融：两类偏差各自贡献多少

消融实验把两类偏差的贡献分别量化。在 Fashion MNIST 上，当 nudge 被故意放大到 $|\beta|=0.5$ 时，经典单边 EP 彻底崩掉，误差飙到 38.4%；换成六点的全纯估计（N=6），误差回到 14.3%，几乎等同于真实导数的 14.7%——这证明有限 nudge 偏差被完全消除。另一方面，把精确导数换成粗糙的两点估计（N=2），在 CIFAR-10 上会多付出约 2.9 个百分点，这部分正是残余的 nudge 偏差。而输出直接回接首层、完全没有互反连接的结构同样从稳态损失中获益，说明该损失针对的是功能对称性，而非权重对称性本身。

小结与边界

这篇论文给出的核心结论是：平衡传播其实并不需要严格对称的权重。只要用 Cauchy 积分精确消除有限 nudge 偏差，再用稳态损失去鼓励 Jacobian 的功能对称，非对称网络就能扩展到 ImageNet 级别的任务，且与理想对称情形只差很小一截。需要留意的是，与对称上限之间仍有可测量的差距，方法也引入了额外的振荡估计与稳态项开销，这些都是后续工作可以继续打磨的地方。

更长远地看，功能对称是一个比权重对称弱得多、也更容易实现的条件。这为在真实物理载体上训练神经网络提供了一条更具生物学合理性的路径，也隐约暗示：大脑或许正是依靠类似的稳态机制，在连接并不精确对称的前提下完成有效学习的。