

ICML 2023 | 让伪造语音检测器学新数据，也别忘了旧数据

中科院自动化所等提出 RAWM：无需回放旧样本的持续学习方法，把灾难性遗忘降到微调的约十分之一。

一个在自家评测集上近乎满分的伪造语音检测器，一旦听到来自另一个数据集的语音，往往就会失灵。它在某一批真实与合成语音上训练，学到的正是这一批数据里合成攻击的样子，等错误率（EER，即错误接受率与错误拒绝率相等的那个点）可以压得很低。可换成别处录制、由更新的合成工具生成的音频，同一个检测器的 EER 就可能上升两个数量级。

最直接的补救办法是在新数据上做微调（Fine-tune）。它对新数据有效，却会悄悄毁掉旧数据上的能力：网络把当初让它在原数据集上准确的特征覆盖掉了。这就是灾难性遗忘（catastrophic forgetting），而且是一个实打实的工程问题。深度伪造语音在不断演化，已经部署的检测器必须持续吸收新的攻击类型，但原始训练数据往往拿不到，比如厂商只发布了预训练检测器却不给出私有语料，或者一个公开模型只能微调、无法从头重训。你需要在不回放任何旧样本的前提下加入新知识。




图 1 RAWM 与 SGD、OWM 在参数空间中的对比。普通 SGD 微调得到的解 θ_{sgd} 深入“新数据”区域，却落在“旧数据”区域之外，旧知识因此丢失；OWM 得到的 θ_{owm} 进入了新旧重叠区，但没到达其中表现更好的子区域；RAWM 则把更新方向引导到 θ_{rawm} ，落在新旧数据集都表现良好的共享子区域内。

这篇发表于 ICML 2023、来自中科院自动化所等机构的论文提出的 Regularized Adaptive Weight Modification (RAWM, 正则化自适应权重修改) 正是为此而来。思路分两部分：让每一步权重更新的方向随当前批次里真实语音的占比自适应调整，再加入一个正则项，保住模型原有的推理行为。全程不存储、不回放任何旧样本。在四个伪造语音数据集上，RAWM 把遗忘降到朴素微调的约十分之一，同时把新数据集上的错误减半；同一套方法还能迁移到语音情感识别和图像识别。

论文：<https://arxiv.org/abs/2308.03300>

代码：<https://github.com/Cecile-hi/Regularized-Adaptive-Weight-Modification>

同域很强，跨数据集很脆

随着语音合成与语音转换生成的语音越来越接近真人，伪造语音检测变得至关重要。难点在于泛化。一个在 ASVspoof2019LA 上训练的检测器，在自家评测集上的 EER 只有 0.258，但换成其他条件的音频，错误率会急剧上升，在收录真实世界深度伪造的 In-the-Wild 集上高达 91.473。以往的跨数据集方案，如集成学习、领域自适应，都依赖旧数据集的样本，而这恰恰是检测器发布后、原始语料不可得时最缺的东西。

于是问题变得非常务实：在留不住旧数据的情况下，如何在新数据上微调而不遗忘旧数据？Orthogonal Weight Modification (OWM, 正交权重修改) 已经给出了一种无需回放的答案，它把每一步更新约束到不扰动“既往输入所张成子空间”的方向上。但 OWM 对所有输入一视同仁，而在伪造语音检测里，这样会白白浪费掉一条可用的规律。

RAWM 利用的那条规律

真实语音在不同数据集之间往往长得很像：它本就是真人音频，特征分布跨数据集几乎不变。真正在变的是伪造语音，因为每个数据集用的合成与转换攻击各不相同。这种不对称是一条可利用的规律。如果一个训练批次以真实语音为主，模型看到的大多是它已经理解的内容，更新就应当偏向保住旧知识；如果批次以伪造语音为主，更新就应当偏向学习新攻击。而像 OWM 那样对每一步更新施加同样约束的方法，无法表达这种区别。

方法：两个部件

第一个部件是自适应权重修改 (AWM)。RAWM 从 OWM 的投影算子 P 出发， P 把更新方向推离“既往输入子空间”。在此之上，RAWM 构造第二个投影算子 Q ，它与 P 正交，并按系数 β （当前批次中真实语音与伪造语音的数量之比）缩放。两个投影算子归一化后合成单一的修改方向 R ，真正的权重步长沿 R 前进。具体来说，批次以真实语音为主时， R 偏向保住旧知识的方向；批次以伪造语音为主时， R 偏向学习新数据。决定更新方向的是批次成分，而不是一条固定规则。

第二个部件是正则化，用来对付更难的情形。少数数据集录制真实语音时的声学条件差异极大，“分布相似”的假设就不再成立。针对这些情形，RAWM 加入一个类似知识蒸馏的项：冻结的预训练模型充当教师，微调中的模型充当学生，一个改写过的交叉熵损失迫使学生的软化输出去匹配教师的软化输出。这样即便新数据集在声学上格格不入，也能保住旧的推理分布。一个系数 η 在新旧数据之间分配注意力；作者发现 $\eta = 0.50$ ，即对新旧同等关注时，效果最好。

两个部件在设计上是互补的。自适应权重修改利用的是新旧真实语音确实相似的情形，而正则项覆盖的是它们并不相似的情形。二者都不存储任何一个旧样本。

结果：新旧数据集上同时保持低错误

核心实验让一个基于 Wav2vec 2.0 的检测器走完一条四数据集顺序训练的链路，从 ASVspoof2019LA (S) 到 ASVspoof2015 (T1)、VCC2020 (T2)、In-the-Wild (T3)，再在四者上分别评测。指标是越低越好的 EER (百分比)。表 1 的对比很鲜明。朴素微调学会了最后一个数据集，却把源数据集毁掉；即便是专门的持续学习方法，也留下明显的差距。RAWM 则同时在每个评测集上保持最低或接近最低的错误，逼近“能同时看到全部数据”的 Train-on-All 联合训练上界。

表 1 四数据集顺序训练 (S -> T1 -> T2 -> T3) 下各评测集上的等错误率 (EER, %, 越低越好)。基线严重退化，而 RAWM 在新旧数据集上都保持低错误率；Train-on-All 为联合训练的性能上界。

Method	S	T1	T2	T3
Baseline	0.258	24.532	46.503	91.473
Train-on-All	1.324	0.561	3.579	2.008
Fine-tune	7.068	2.841	5.674	4.543
EWC	5.569	2.444	6.510	5.129
OWM	4.083	2.167	6.480	5.472
LwF	2.714	1.621	4.875	4.325
DFWF	3.476	3.735	7.345	6.114
RAWM (Ours)	1.508	0.641	3.850	3.163

把基线那一行读作“什么都不做的代价”，把 RAWM 那一行读作“用 RAWM 的代价”：源数据集上的错误维持在接近原始的 1.508，后面三个数据集稳定在 3 到 4 附近，而基线已经退化到 90 以上。与 EWC、OWM、LwF 以及专为伪造语音设计的 DFWF 相比，RAWM 是唯一能在源集和每个目标集上同时保持竞争力、而不是拆东墙补西墙的方法。

少样本与跨任务同样成立

持续学习最有用的场景往往是新数据稀缺，所以作者还测了一个少样本设置：先在 S 上训练，再仅用 T1 的 100 个样本适应。微调会在这一小撮新样本上过拟合并严重遗忘 S，而 RAWM 学会了 T1，几乎不扰动源数据集。

表 2 少样本持续学习：先在 S 上训练，再仅用 T1 的 100 个样本适应，并在两者上评测 (EER %, 越低越好)。RAWM 在几乎不扰动 S 的前提下学好了 T1。

Method	S	T1
--------	---	----

Baseline	0.258	24.532
Train-on-All	0.279	0.291
Fine-tune	7.951	0.617
EWC	2.972	0.619
OWM	2.683	0.617
LwF	3.198	0.542
DFWF	1.975	0.733
RAWM (Ours)	0.923	0.312

这套机制并不局限于伪造检测。由于它依赖的规律，即部分类别在数据集之间保持相似、另一些则不断变化，普遍存在于许多问题中，RAWM 也能迁移到按 MSP-Podcast、IEMOCAP 顺序训练的四类语音情感识别，以及 CLEAR-10 图像识别基准。在情感识别上，它在源任务和目标任务上都取得了持续学习方法中最高的准确率。

表 3 跨任务泛化：四类语音情感识别准确率（%，越高越好），按 MSP-Podcast -> IEMOCAP 顺序训练。在所有持续学习方法中，RAWM 既最好地保住源任务，又学好了目标任务。

Method	MSP-Podcast	IEMOCAP
Baseline	54.446	30.043
Train-on-All	54.396	57.262
Fine-tune	24.094	50.379
EWC	35.819	48.698
OWM	32.267	48.162
LwF	38.800	44.034
RAWM (Ours)	41.995	54.229

两个部件各自的贡献

消融实验把两个部件拆开来看，结论很干净。当新旧数据集的特征分布相似时，自适应权重修改承担了大部分工作，去掉它错误率会明显上升。当两个数据集的声学条件差异很大时，正则项就成了克服遗忘的关键。在完整的四数据集链路上，去掉自适应权重修改比去掉正则化更伤性能，因此它是主要驱动力，而正则化是应对那些声学上格格不入的困难情形的重要补充。

为什么重要

RAWM 的实用价值在于，它正好契合真实部署所面对的约束。你可以在不留任何旧数据的前提下，教一个已发布的伪造语音检测器学习新数据集，同时不必眼睁睁看着它在原始数据上的准确率崩塌。它靠的是两个不贵的想法：让权重更新随每个批次真实语音的占比自适应，并用正则化让模型记住自己先前的行为。诚实地说，边界在于自适应部分依赖真实语音在数据集之间保持相似；一旦这个假设变弱，就由正则项来承担，这也是为什么两个部件缺一不可。而同一套方法能延伸到情感识别与图像识别，说明它所依赖的那种不对称，即稳定的类别与变化的类别并存，比伪造语音本身要普遍得多。